Математический анализ в методах машинного обучения

Вейгандт В., Зайцев Н., Горобец О., Козлов В., Шагеев Э.

2026

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 1
Постановка задачи машинного обучения

Обучение с учителем: постановка задачи

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение

Пусть (X, Y) — случайная пара с неизвестным совместным распределением $P_{\mathsf{X},Y}$, где $\mathsf{X} \in \mathcal{X}$ — объект, а $Y \in \mathcal{Y}$ — его ответ.

Определение

Обучающей выборкой называется набор реализаций

$$D_n = \{(x_i, y_i)\}_{i=1}^n, \qquad (\mathsf{X}_i, Y_i) \overset{\text{iid}}{\sim} P_{\mathsf{X},Y}.$$

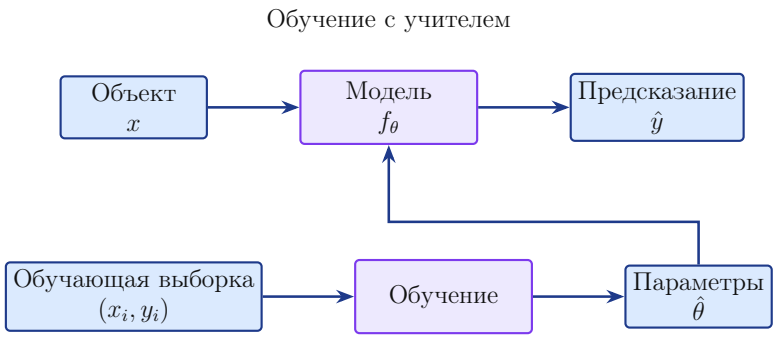
Здесь (X_i, Y_i) — независимые одинаково распределённые случайные пары, а (x_i, y_i) — наблюдаемые значения.

Задача

По выборке D_n построить функцию

$$f : \mathcal{X} \to \widehat{\mathcal{Y}},$$

для прогнозирования новых объектов из того же распределения. Здесь $\widehat{\mathcal{Y}}$ — пространство прогнозов (в частности, вероятностей классов).



Признаки и матричное представление выборки

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение
Числовым *признаковым описанием* i-го объекта называется вектор

$$x_i = (x_{i1}, \ldots, x_{id})^T \in \mathbb{R}^d,$$

где x_{ij} — значение j-го признака у i-го объекта.
Выборку удобно записывать в виде матрицы объектов–признаков

$$X = \begin{pmatrix} x_1^T \\ \vdots \\ x_n^T \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1d} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{nd} \end{pmatrix} \in \mathbb{R}^{n \times d}, \qquad y = (y_1, \ldots, y_n)^T.$$

Определение

- $\mathcal{Y} = \mathbb{R}$ — *regression* (регрессия);
- $\mathcal{Y} = \{1, \ldots, K\}$ — *classification* (классификация).

Пример Цена квартиры — регрессия; определение класса изображения — классификация.

Модель и алгоритм обучения

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Параметрическая модель* — семейство функций

$$\mathcal{F} = \{f_\theta : \mathcal{X} \to \widehat{\mathcal{Y}} \mid \theta \in \Theta\},$$

где Θ — пространство параметров. При фиксированном θ получаем прогноз $\hat{y} = f_\theta(x)$.

Пример Прямые $f_{w,b}(x) = wx + b$ образуют семейство с параметрами $\theta = (w, b)^T \in \mathbb{R}^2$.

Определение *Алгоритм обучения* выбирает параметры по данным:

$$\boxed{A : (\mathcal{X} \times \mathcal{Y})^n \to \Theta, \qquad \hat{\theta} = A(D_n)}.$$

Следствие Результат обучения — конкретная функция $f_{\hat{\theta}}$ из семейства $\mathcal{F}$.

Замечание Модель отвечает на вопрос «что можно построить?», алгоритм — «как выбрать параметры по выборке?».

Функция потерь: как измерить ошибку?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Функция потерь* задаёт стоимость ошибки прогноза:

$$\ell : \mathcal{Y} \times \widehat{\mathcal{Y}} \to \mathbb{R}_{\geq 0}, \qquad (y, \hat{y}) \mapsto \ell(y, \hat{y}).$$

Пример В регрессии при числовом прогнозе $\hat{y}$:

$$\boxed{\ell(y, \hat{y}) = (y - \hat{y})^2}.$$

В классификации при прогнозировании *класса* $\hat{c} \in \mathcal{Y}$:

$$\boxed{\ell(y, \hat{c}) = \mathbf{1}\{y \neq \hat{c}\}}.$$

Здесь $\mathbf{1}\{A\} = 1$, когда условие A верно, и 0 иначе. Если модель выдаёт *вероятность* класса, вместо 0/1-потери удобно использовать BCE (глава 2).

Замечание Потеря для обучения и метрика итогового качества не обязаны совпадать: классификатор может обучаться по BCE, а оцениваться по доле правильных ответов (accuracy).

Истинный риск: ошибка на новых объектах

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Пусть случайные данные (X, Y) имеют неизвестное распределение $P_{\mathsf{X},Y}$.

Определение *Истинный риск* — математическое ожидание потери на новом случайном объекте:

$$\boxed{R(\theta) = \mathbb{E}_{(\mathsf{X},Y)\sim P_{\mathbf{X},Y}}\big[\ell(Y, f_\theta(\mathsf{X}))\big]}.$$

Замечание $\mathbb{E}$ означает усреднение по распределению возможных новых объектов и их ответов, а не по одной наблюдаемой таблице.

Задача Идеально хотелось бы найти $\hat{\theta} \in \arg\min_{\theta\in\Theta} R(\theta)$. Но $P_{\mathsf{X},Y}$ неизвестно, поэтому вычислить $R(\theta)$ точно обычно нельзя.

Следствие Вместо истинного риска используют *эмпирический* — усреднение потерь по имеющимся данным.

Эмпирический риск: что известно по выборке?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение Для $D_n = \{(x_i, y_i)\}_{i=1}^n$ *эмпирический риск* равен

$$\boxed{\widehat{R}_n(\theta) = \frac{1}{n}\sum_{i=1}^{n} \ell\big(y_i, f_\theta(x_i)\big)}.$$

Это вычисляемая функция параметров при фиксированной выборке.

Утверждение При *фиксированном* θ и конечном математическом ожидании закон больших чисел даёт

$$\widehat{R}_n(\theta) \longrightarrow R(\theta), \qquad n \to \infty.$$

Замечание Для параметров $\hat{\theta}$, выбранных *по этой же выборке*, такого вывода автоматически нет. Поэтому качество проверяют на отдельных данных.

Идея Подбор параметров превращается в задачу минимизации конкретной функции $\widehat{R}_n$.

Принцип ERM: обучение как оптимизация

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Empirical Risk Minimization (ERM)* — выбор параметров с наименьшей средней потерей на обучающей выборке:

$$\boxed{\hat{\theta} \in \arg\min_{\theta \in \Theta} \widehat{R}_n(\theta)}.$$

Здесь arg min обозначает *множество параметров, на которых достигается минимум*, а не значение функции в минимуме.

Пример Для прямой $f_{w,b}(x) = wx + b$ нужно подобрать два числа w, b, уменьшая среднюю квадратичную ошибку:

$$\widehat{R}_n(w, b) = \frac{1}{n} \sum_{i=1}^{n} (wx_i + b - y_i)^2.$$

Следствие Если $\Theta \subseteq \mathbb{R}^m$, то $\widehat{R}_n : \Theta \to \mathbb{R}$ — *функция нескольких переменных*.

Замечание Минимальная ошибка на обучающих данных не означает автоматически минимальную ошибку на новых объектах.

Обобщающая способность и переобучение

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение

Generalization (обобщающая способность) — способность модели, обученной на D_{train}, сохранять качество на новых объектах из того же распределения.

Практически сравнивают ошибку на обучающей и независимой выборках:

$$\widehat{R}_{\text{train}}(\hat{\theta}), \qquad \widehat{R}_{\text{test}}(\hat{\theta}).$$

Определение

Overfitting (переобучение) обычно проявляется как ситуация, когда

$$\widehat{R}_{\text{train}}(\hat{\theta}) \ll \widehat{R}_{\text{test}}(\hat{\theta}).$$

Underfitting (недообучение) — ситуация, когда обе ошибки остаются большими.

Замечание

Минимизация train loss — средство, а не конечная цель: требуется малый истинный риск $R(\hat{\theta})$. Разность $\widehat{R}_{\text{test}}(\hat{\theta}) - \widehat{R}_{\text{train}}(\hat{\theta})$ называют *разрывом обобщения*; большой положительный разрыв сигнализирует о проблеме.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Train, Validation и Test

Для независимого контроля качества данные разделяют:

$$D = D_{\text{train}} \sqcup D_{\text{validation}} \sqcup D_{\text{test}}.$$

- D_{train} — поиск параметров модели $\hat{\theta}$;
- $D_{\text{validation}}$ — выбор гиперпараметров (настроек, не входящих в θ), архитектуры и варианта модели;
- D_{test} — итоговая оценка качества после завершения выбора.

Замечание

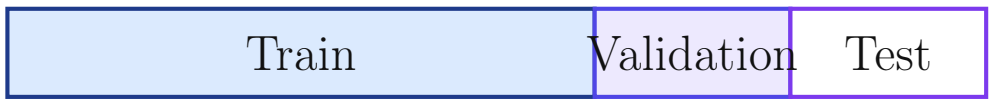
Test-выборка не должна использоваться при подборе модели: иначе она перестаёт быть независимой оценкой качества.

Задача

В следующих главах обозначим $L(\theta) = \widehat{R}_{\text{train}}(\theta)$. Общий цикл:

$$D_{\text{train}} \to \mathcal{F} \to \ell \to \min L(\theta) \to \text{validation} \to \text{test}.$$

Разбиение выборки



Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 2
Линейные модели

Linear Regression: определение модели

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Задача По $x \in \mathbb{R}^d$ предсказать число $y \in \mathbb{R}$.
Определение *Линейная регрессия* (Linear Regression):

$$f_{w,b}(x) = w^T x + b = \sum_{j=1}^{d} w_j x_j + b, \qquad w \in \mathbb{R}^d, \quad b \in \mathbb{R}.$$

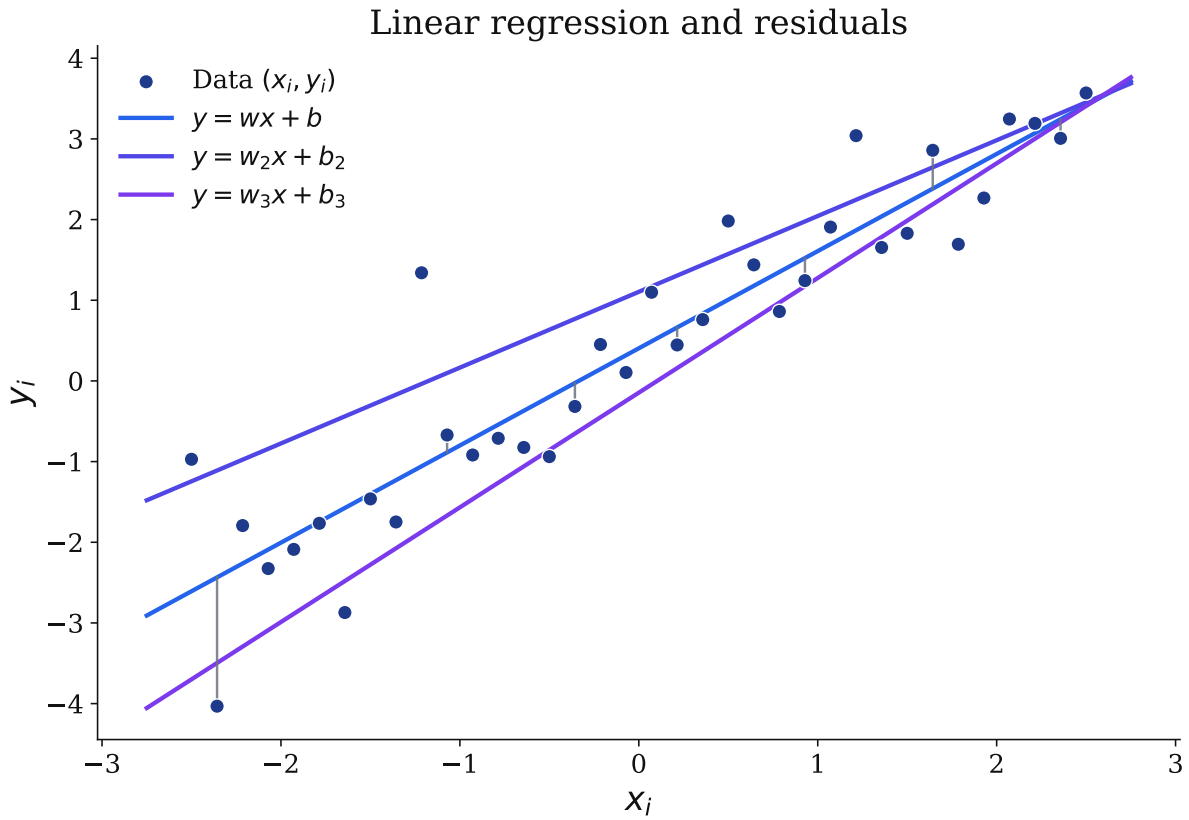
Здесь w_j — коэффициенты признаков, b — свободный член.
Определение Для единой записи вводят *фиктивный признак* $x_0 = 1$:

$$\widetilde{x} = (1, x_1, \ldots, x_d)^T, \qquad \theta = (b, w_1, \ldots, w_d)^T, \qquad f_\theta(\widetilde{x}) = \widetilde{x}^T \theta.$$

Итак, $\widetilde{x}, \theta \in \mathbb{R}^{d+1}$. Для выборки обозначим через $\widetilde{X}$ матрицу строк $\widetilde{x}_i^T$.
Пример При $d = 1$ получаем прямую $\hat{y} = wx + b$; например, $w = 2$, $b = 1$ дают $f(3) = 2 \cdot 3 + 1 = 7$.
Замечание Линейность здесь означает линейность *по параметрам*: $\theta_0 + \theta_1 x + \theta_2 x^2$ также линейна по θ.

Геометрия линейной регрессии: данные и остатки

Каждая точка (x_i, y_i) — наблюдение; линия — прогноз $\hat{y}_i = wx_i + b$. При изменении w, b меняются прогнозы и ошибки.



Замечание Вертикальное отклонение точки от прямой — остаток $r_i = y_i - \hat{y}_i$; минимизировать будем *сумму квадратов* таких отклонений.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Остатки и Mean Squared Error

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Остаток* (residual) на i-м объекте:

$$r_i = y_i - \hat{y}_i = y_i - f_\theta(\widetilde{x}_i).$$

Определение Квадратичная потеря и её среднее по выборке:

$$\ell(y_i, \hat{y}_i) = (y_i - \hat{y}_i)^2, \qquad \boxed{L(\theta) = \mathrm{MSE}(\theta) = \frac{1}{n}\sum_{i=1}^{n} r_i^2}.$$

Пример Пусть $x = (0, 1, 2)$, $y = (1, 2, 2)$, а $f(x) = x + 1$. Тогда

$$\hat{y} = (1, 2, 3), \quad r = (0, 0, -1), \quad L = \frac{0^2 + 0^2 + (-1)^2}{3} = \frac{1}{3}.$$

Замечание Возведение в квадрат убирает знак ошибок и сильнее штрафует большие отклонения: $|r| = 2$ даёт потерю 4, а $|r| = 1$ — 1.

Задача Найти $\hat{\theta} \in \arg\min_\theta L(\theta)$.

Матричная запись MSE

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Расширенная матрица $\widetilde{X}$ содержит единичный первый столбец и d исходных признаков:

$$\widetilde{X} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1d} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n1} & \cdots & x_{nd} \end{pmatrix} \in \mathbb{R}^{n\times(d+1)}, \quad \theta \in \mathbb{R}^{d+1}.$$

Поэтому вектор всех предсказаний и остатков имеет вид

$$\hat{y} = \widetilde{X}\theta \in \mathbb{R}^n, \qquad r = y - \widetilde{X}\theta \in \mathbb{R}^n.$$

Определение *Евклидова норма* вектора $r = (r_1, \ldots, r_n)^T$ — его длина: $\|r\|_2 = \sqrt{r_1^2 + \cdots + r_n^2}$. Поэтому $\|r\|_2^2 = r^T r = \sum_i r_i^2$ и

$$\boxed{L(\theta) = \frac{1}{n}\|y - \widetilde{X}\theta\|_2^2 = \frac{1}{n}(y - \widetilde{X}\theta)^T(y - \widetilde{X}\theta)}.$$

Следствие Это функция от $(d+1)$ переменной, а не от объектов выборки: при обучении меняется θ, тогда как X и y зафиксированы.

MSE как функция нескольких переменных

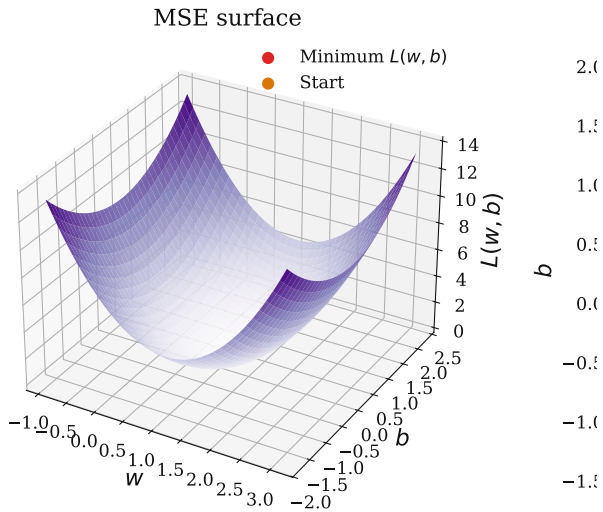
Для единственного признака $\theta = (b, w)$ и

$$L(w, b) = \frac{1}{n} \sum_{i=1}^{n} (y_i - wx_i - b)^2, \qquad L : \mathbb{R}^2 \to \mathbb{R}.$$

При каждом (w, b) выбирается своя прямая и вычисляется её ошибка.

Утверждение $L(w, b)$ — квадратичная функция по двум параметрам; её график — поверхность в пространстве (w, b, L).

Замечание Точки минимума соответствуют параметрам прямой, наилучшей по MSE. Как найти их численно, разберём в главе 3.



МатАн. Проект. Машинное обучение

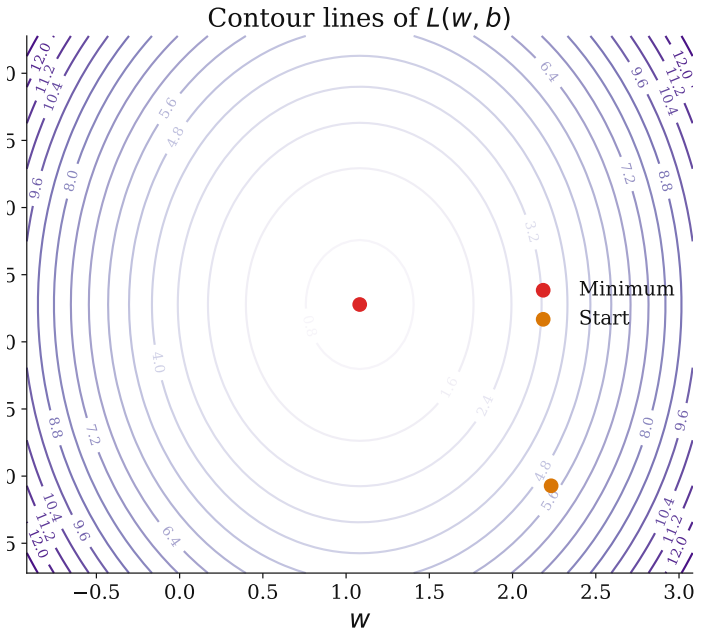
Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Линии уровня MSE: геометрический смысл

Определение *Линия уровня* функции $L(w, b)$ при $c \in \mathbb{R}$:

$$\mathcal{C}_c = \{(w, b) : L(w, b) = c\}.$$

Чем ближе линия уровня к минимуму, тем меньшей сумме квадратов остатков соответствуют параметры.



Замечание В точках, где $\nabla L \neq 0$, градиент перпендикулярен линии уровня: при движении вдоль неё значение L локально не меняется.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Как дифференцировать MSE: случай $d = 1$

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Для $f_{w,b}(x) = wx + b$ положим $e_i = wx_i + b - y_i$. Тогда $L(w, b) = \frac{1}{n}\sum_i e_i^2$.
По *правилу цепочки*, поскольку $\partial e_i/\partial w = x_i$, а $\partial e_i/\partial b = 1$,

$$\frac{\partial e_i^2}{\partial w} = 2e_i x_i, \qquad \frac{\partial e_i^2}{\partial b} = 2e_i.$$

Утверждение Частные производные функции потерь:

$$\boxed{\frac{\partial L}{\partial w} = \frac{2}{n}\sum_{i=1}^{n}(wx_i + b - y_i)x_i},$$

$$\boxed{\frac{\partial L}{\partial b} = \frac{2}{n}\sum_{i=1}^{n}(wx_i + b - y_i)}.$$

Замечание Градиент $\nabla L = (\partial L/\partial b, \partial L/\partial w)^T$ показывает, как ошибка меняется при малом изменении каждого параметра.

Градиент MSE в общем случае

Запишем $e_i = \widetilde{x}_i^T\theta - y_i$; тогда

$$L(\theta) = \frac{1}{n}\sum_{i=1}^{n} e_i^2, \qquad \frac{\partial e_i}{\partial \theta_j} = \widetilde{x}_{ij}, \quad j = 0, \ldots, d.$$

Снова применяем правило цепочки:

$$\frac{\partial L}{\partial \theta_j} = \frac{1}{n}\sum_i 2e_i\frac{\partial e_i}{\partial \theta_j} = \frac{2}{n}\sum_i \widetilde{x}_{ij}(\widetilde{x}_i^T\theta - y_i).$$

Здесь $\widetilde{X}^T(\widetilde{X}\theta - y)$ — вектор, j-я компонента которого равна сумме в правой части без множителя $2/n$.

Утверждение Собирая частные производные, получаем

$$\boxed{\nabla_\theta L(\theta) = \frac{2}{n}\widetilde{X}^T(\widetilde{X}\theta - y)} \quad \in \mathbb{R}^{d+1}.$$

Следствие Минимум гладкой функции (во внутренней точке) может достигаться только при $\nabla_\theta L = 0$.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Logistic Regression: зачем нужна сигмоида

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Задача Предсказать класс $Y \in \{0, 1\}$ и вероятность $p_\theta(x) = P_\theta(Y = 1 \mid X = x)$.

Определение Сначала вычисляется *линейный score*

$$z = w^T x + b = \widetilde{x}^T \theta \in \mathbb{R}.$$

Но z не обязан принадлежать $[0, 1]$, поэтому сам по себе не может быть вероятностью.

Определение *Odds* (шансы) события при вероятности p равны $p/(1-p)$. *Log-odds* — их логарифм:

$$\operatorname{logit}(p) = \log \frac{p}{1-p}.$$

Утверждение В *логистической регрессии* принимают модель

$$\boxed{\operatorname{logit}(p_\theta(x)) = w^T x + b = z}.$$

Пример При $p = 3/4$ шансы равны 3, а log-odds $= \log 3$.

Вывод сигмоиды из log-odds

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Предположим, что $\log \frac{p}{1-p} = z$. Выразим p:

$$\log \frac{p}{1-p} = z \quad \Longrightarrow \quad \frac{p}{1-p} = e^z,$$

$$p = e^z(1-p) \quad \Longrightarrow \quad p(1+e^z) = e^z,$$

$$\boxed{p = \frac{e^z}{1+e^z} = \frac{1}{1+e^{-z}} = \sigma(z)}.$$

Определение $\sigma : \mathbb{R} \to (0,1)$ — *sigmoid* (логистическая функция).
Утверждение $\sigma(0) = 1/2$, $\lim_{z\to-\infty} \sigma(z) = 0$, $\lim_{z\to+\infty} \sigma(z) = 1$.
По правилу цепочки

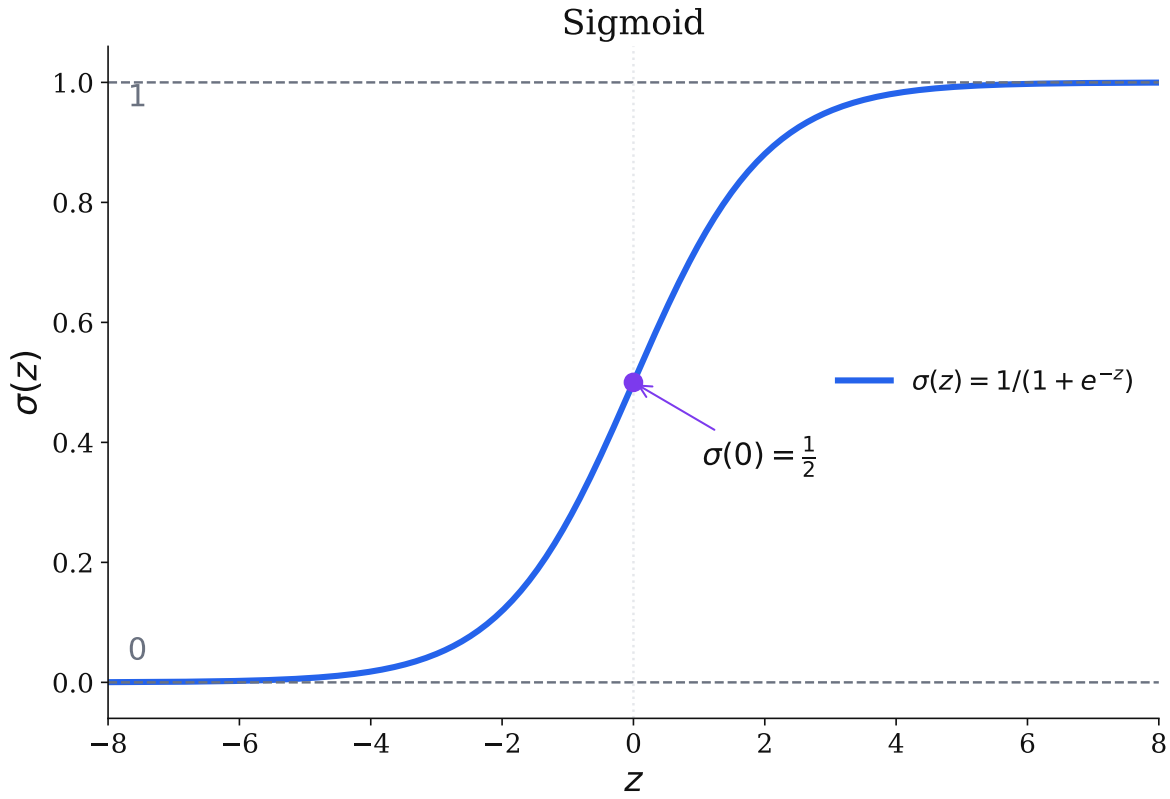
$$\boxed{\sigma'(z) = \frac{e^{-z}}{(1+e^{-z})^2} = \sigma(z)\big(1-\sigma(z)\big) > 0}.$$

Поэтому вероятность класса 1 растёт вместе со score z.

График сигмоиды

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Утверждение Линейный score z переводится в вероятность $p = \sigma(z)$; центральная точка графика имеет координаты $(0, 1/2)$.



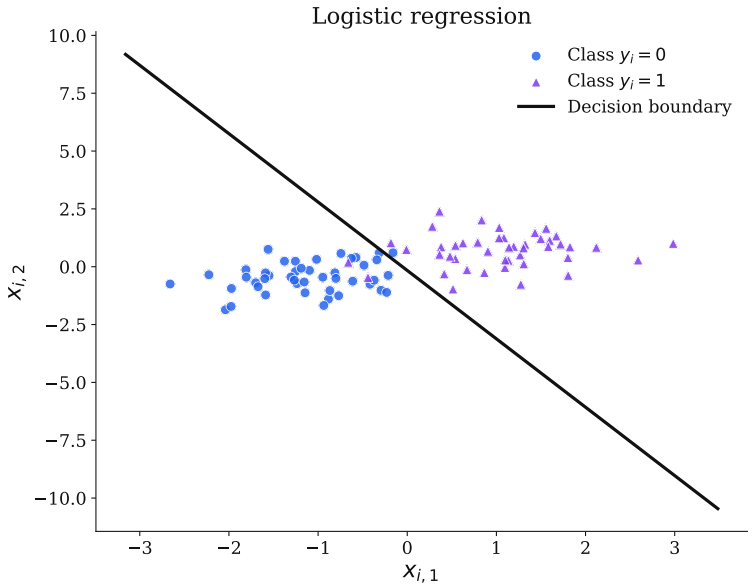
Пример Если $z = \log 3$, то $p = 3/4$; если $z = -\log 3$, то $p = 1/4$.

Геометрия логистической классификации

При пороге $1/2$ и монотонности σ:

$$\widehat{y} = 1 \iff p_\theta(x) \geq \tfrac{1}{2} \iff w^T x + b \geq 0.$$

Определение Граница решения: $\{x : w^T x + b = 0\}$ — гиперплоскость (если $w \neq 0$).



Замечание На графике показана линейная граница, хотя сама вероятность $p_\theta(x) = \sigma(w^T x + b)$ нелинейна по x. Например, для $w = (1, -1)^T$, $b = 0$ граница имеет вид $x_1 = x_2$.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Модель Бернулли и функция правдоподобия

Для объекта x_i обозначим $p_i = \sigma(\widetilde{x}_i^T \theta)$.

Определение При фиксированном x_i модель задаёт

$$Y_i \mid X_i = x_i \sim \text{Bern}(p_i), \qquad P_\theta(Y_i = y_i \mid x_i) = p_i^{y_i}(1 - p_i)^{1-y_i}.$$

Действительно, если $y_i = 1$, получаем p_i; если $y_i = 0$, получаем $1 - p_i$.

При условной независимости ответов *likelihood* (правдоподобие) всей наблюдаемой выборки равно

$$\boxed{\mathcal{L}(\theta) = \prod_{i=1}^{n} p_i^{y_i}(1 - p_i)^{1-y_i}}.$$

Задача *Maximum Likelihood Estimation* (MLE):

$$\hat{\theta} \in \arg\max_{\theta} \mathcal{L}(\theta).$$

Замечание $\mathcal{L}(\theta)$ рассматривается как функция параметров: ответы y_i уже известны, изменяются только p_i.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вывод Binary Cross-Entropy из MLE

Логарифм строго возрастает, поэтому максимумы $\mathcal{L}$ и $\log \mathcal{L}$ достигаются при тех же параметрах.
Применяем $\log(ab) = \log a + \log b$ и $\log(a^c) = c \log a$:

$$\log \mathcal{L}(\theta) = \sum_{i=1}^{n} \Big(y_i \log p_i + (1 - y_i) \log(1 - p_i) \Big).$$

Чтобы получить *задачу минимизации*, меняем знак и делим на n (положительный множитель не меняет оптимум):

$$\boxed{L(\theta) = -\frac{1}{n} \sum_{i=1}^{n} \Big[y_i \log p_i + (1 - y_i) \log(1 - p_i) \Big]}.$$

Определение L — *Binary Cross-Entropy* (BCE), или средняя отрицательная логарифмическая вероятность правильного ответа.
Пример Для одного наблюдения с $y = 1$ потеря равна $-\log p$: прогноз $p = 0.9$ даёт примерно 0.105, а $p = 0.1$ — примерно 2.303. Уверенная ошибка наказывается сильнее.
Следствие $\arg\max_\theta \mathcal{L}(\theta) = \arg\min_\theta L(\theta)$.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Градиент BCE: правило цепочки

Для одного объекта положим $z_i = \widetilde{x}_i^T\theta$, $p_i = \sigma(z_i)$ и

$$\ell_i = -y_i \log p_i - (1 - y_i)\log(1 - p_i).$$

Последовательно дифференцируем:

$$\frac{\partial \ell_i}{\partial p_i} = -\frac{y_i}{p_i} + \frac{1 - y_i}{1 - p_i} = \frac{p_i - y_i}{p_i(1 - p_i)},$$

$$\frac{\partial p_i}{\partial z_i} = p_i(1 - p_i), \qquad \boxed{\frac{\partial \ell_i}{\partial z_i} = p_i - y_i}.$$

Ещё один шаг по правилу цепочки:

$$\frac{\partial z_i}{\partial \theta_j} = \widetilde{x}_{ij} \quad \Longrightarrow \quad \frac{\partial \ell_i}{\partial \theta_j} = (p_i - y_i)\widetilde{x}_{ij}.$$

Утверждение Для всей выборки

$$\boxed{\nabla_\theta L(\theta) = \frac{1}{n}\widetilde{X}^T(p - y)}, \qquad p = (p_1, \ldots, p_n)^T.$$

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 3
Градиентные методы оптимизации

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Зачем нужна численная оптимизация

В предыдущей главе обучение свелось к поиску минимума эмпирического риска:

$$\boxed{\hat{\theta} \in \arg\min_{\theta \in \Theta} L(\theta)}, \qquad L : \mathbb{R}^m \to \mathbb{R}.$$

Пример Для рассмотренных линейных моделей

$$L_{\text{MSE}}(\theta) = \frac{1}{n}\|\widetilde{X}\theta - y\|_2^2,$$

$$L_{\text{BCE}}(\theta) = -\frac{1}{n}\sum_{i=1}^{n}\big[y_i \log p_i + (1 - y_i)\log(1 - p_i)\big].$$

Для MSE функция потерь квадратичная; для BCE общего явного решения нет.

Задача Построить последовательность $\theta_0, \theta_1, \ldots$, вдоль которой значение функции потерь становится меньше.

Идея Если известны частные производные L, можно использовать локальную информацию о её изменении, не решая уравнение минимума явно. Следующий шаг — выбрать направление, в котором линейное приближение L убывает быстрее всего.

Скалярное произведение и длина вектора

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Перед геометрией градиента уточним обозначения для $u, v \in \mathbb{R}^m$.

Определение *Скалярное произведение* — число

$$\boxed{\langle u, v \rangle = u^T v = \sum_{j=1}^{m} u_j v_j}.$$

Определение *Евклидова норма* — длина вектора:

$$\boxed{\|v\|_2 = \sqrt{\langle v, v \rangle} = \sqrt{v_1^2 + \cdots + v_m^2}}.$$

Пример Для $v = (3, 4)^T$ получаем $\|v\|_2 = 5$; единичный вектор в этом направлении равен $v/\|v\|_2 = (3/5, 4/5)^T$.

Замечание *Единичным* называется вектор с нормой 1.

Неравенство Коши–Буняковского: $|\langle u, v \rangle| \leq \|u\|_2 \|v\|_2$.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Почему именно антиградиент?

Пусть $L : \mathbb{R}^m \to \mathbb{R}$ дифференцируема, а ∇L — вектор её частных производных.

Определение *Производная по направлению* единичного вектора v, $\|v\|_2 = 1$, задаётся равенством

$$D_v L(\theta) = \langle \nabla L(\theta), v \rangle.$$

По неравенству Коши–Буняковского

$$-\|\nabla L(\theta)\|_2 \le D_v L(\theta) \le \|\nabla L(\theta)\|_2.$$

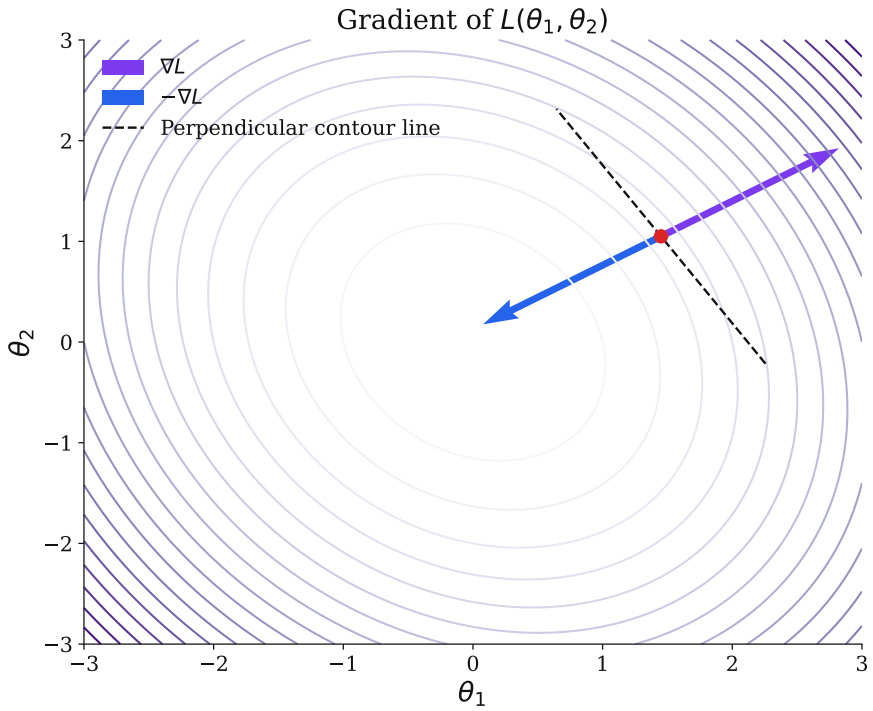
Утверждение При $\nabla L(\theta) \neq 0$ наибольшее *локальное* убывание среди единичных направлений достигается при

$$\boxed{v_{\min} = -\frac{\nabla L(\theta)}{\|\nabla L(\theta)\|_2}}.$$

Замечание При $\Delta\theta = -\eta \nabla L(\theta)$ линейное приближение даёт изменение $-\eta \|\nabla L(\theta)\|_2^2 < 0$ при $\nabla L \neq 0$. Реальный конечный шаг может вести себя иначе: вывод локальный.

Геометрия градиента и линий уровня

На карте линий уровня $L(\theta) = c$ градиент в регулярной точке перпендикулярен линии уровня и направлен в сторону возрастания L. Антиградиент показывает направление наиболее быстрого *локального* убывания.



Замечание Изображена геометрия одного шага; траектория метода складывается из многих таких шагов.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Gradient Descent: формула и алгоритм

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Gradient Descent (градиентный спуск)* — итерационный метод, в котором

$$\boxed{\theta_{t+1} = \theta_t - \eta_t \nabla L(\theta_t)}, \qquad \eta_t > 0.$$

Здесь $\theta_t \in \mathbb{R}^m$ — текущие параметры, η_t — *learning rate* (размер шага обучения).

Алгоритм

1. Задать начальное приближение θ_0 и правило выбора η_t.
2. Вычислить $g_t = \nabla L(\theta_t)$.
3. Обновить параметры: $\theta_{t+1} = \theta_t - \eta_t g_t$.
4. Повторять до выполнения критерия остановки.

Замечание Возможные критерии: малость $\|g_t\|$, изменение $L(\theta_t)$ или ограничение числа итераций. Ненулевой шаг сам по себе не гарантирует уменьшения функции.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Пример: несколько итераций вручную

Пример Минимизируем $L(u) = (u-2)^2$ из точки $u_0 = 0$ при постоянном шаге $\eta = \frac{1}{4}$.

$$L'(u) = 2(u-2), \qquad u_{t+1} = u_t - \tfrac{1}{4}\,2(u_t - 2) = \tfrac{1}{2}u_t + 1.$$

t	u_t	$L'(u_t)$	$L(u_t)$
0	0	-4	4
1	1	-2	1
2	$\frac{3}{2}$	-1	$\frac{1}{4}$
3	$\frac{7}{4}$	$-\frac{1}{2}$	$\frac{1}{16}$

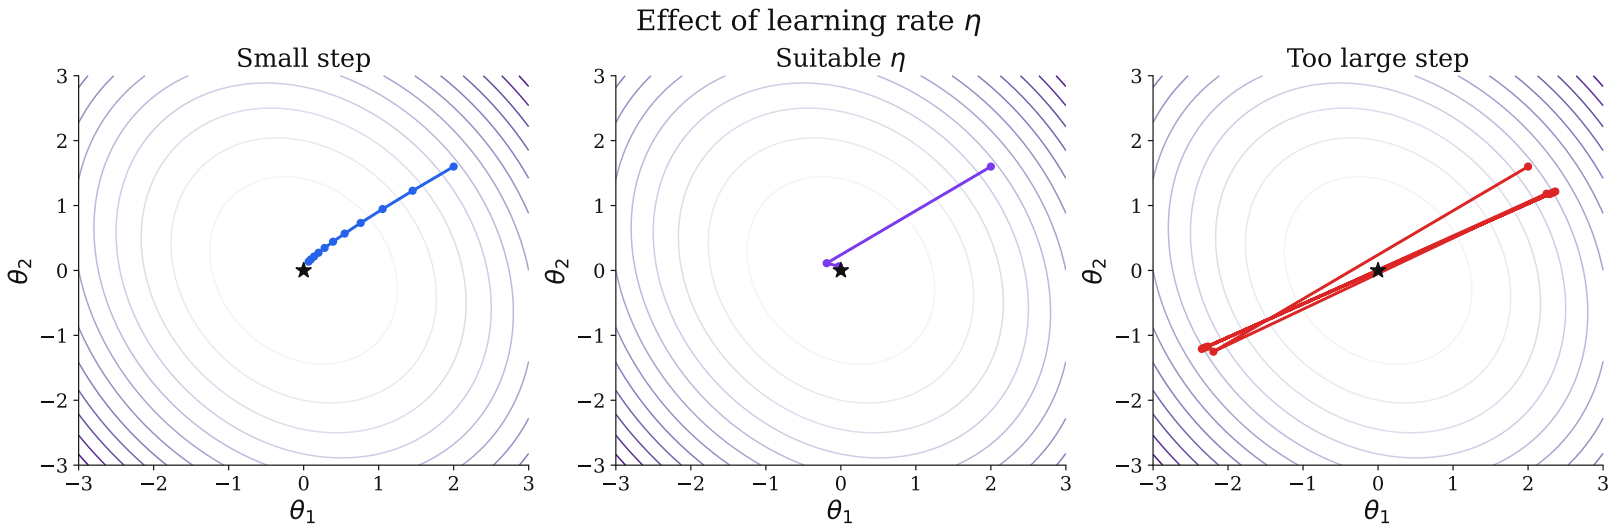
Следствие Каждый шаг сокращает расстояние до $u^* = 2$ вдвое; ошибка по функции уменьшается вчетверо.

$$u_t = 2 - 2\left(\tfrac{1}{2}\right)^t, \qquad L(u_t) = 4\left(\tfrac{1}{4}\right)^t \to 0.$$

Влияние learning rate: иллюстрация

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Слишком малый шаг замедляет движение, слишком большой может приводить к перескакиванию через минимум и расходимости.



Замечание На схеме показаны возможные режимы траекторий; поведение зависит также от геометрии конкретной функции потерь.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Полный и стохастический градиенты

Эмпирический риск является средним по выборке:

$$L(\theta) = \frac{1}{n}\sum_{i=1}^{n} \ell_i(\theta), \qquad \ell_i(\theta) = \ell(y_i, f_\theta(x_i)).$$

Определение При *Batch Gradient Descent* используется градиент всей суммы:

$$g_t = \nabla L(\theta_t) = \frac{1}{n}\sum_{i=1}^{n} \nabla \ell_i(\theta_t).$$

Определение В *Mini-batch SGD* вычисляют приближение по случайной подвыборке индексов B_t:

$$\boxed{g_t = \frac{1}{|B_t|}\sum_{i\in B_t} \nabla \ell_i(\theta_t)}, \qquad \theta_{t+1} = \theta_t - \eta_t g_t.$$

При равномерном выборе индексов такое среднее в среднем направлено как полный градиент.

Замечание Mini-batch дешевле одной полной итерации, но даёт шумное направление. Далее g_t — вычисленный на шаге градиент (полный или по mini-batch).

Momentum: зачем учитывать предыдущие шаги?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вытянутые линии уровня означают разные масштабы изменения функции по разным направлениям. Обычный GD может сильно колебаться поперёк узкой долины и медленно идти вдоль неё.

Идея Сохранять накопленное направление движения, сглаживая изменения градиента между итерациями.

Определение *Momentum (метод момента)*:

$$v_{t+1} = \beta v_t + g_t, \qquad v_0 = 0,$$
$$\theta_{t+1} = \theta_t - \eta v_{t+1}, \qquad 0 \le \beta < 1.$$

Здесь v_t — накопленное направление, β — коэффициент сохранения предыдущего направления.

Замечание Если $\beta = 0$, получаем обычный GD. При близких направлениях градиентов они накапливаются; при чередовании знаков в одной координате — частично компенсируются.

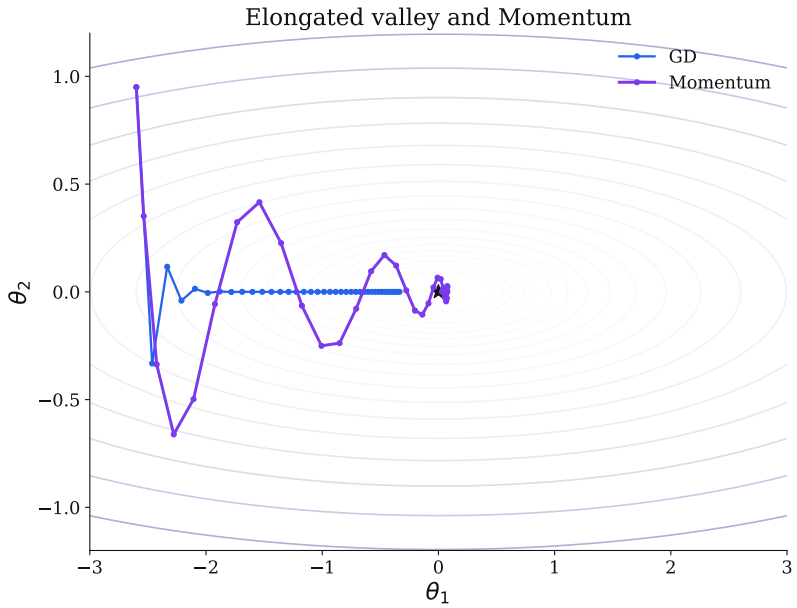
Momentum: геометрия узкой долины

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Пример Для $L(u, v) = 10u^2 + v^2$ имеем

$$\nabla L(u, v) = (20u, 2v)^T.$$

Изменение вдоль координаты u намного резче; обычный GD с заметным шагом может многократно пересекать долину поперёк.



Следствие Momentum накапливает устойчивое направление вдоль долины и частично гасит чередующиеся поперечные шаги.

Nesterov Momentum: шаг с опережением

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Идея Обычный Momentum вычисляет градиент в θ_t, а затем делает инерционный шаг. Метод Нестерова сначала учитывает предполагаемое перемещение по инерции.

Определение *Nesterov Momentum (метод Нестерова)* в одной из стандартных форм записи:

$$\begin{aligned} \theta_t^{\text{look}} &= \theta_t - \eta\beta v_t, \\ g_t &= \nabla L(\theta_t^{\text{look}}), \\ v_{t+1} &= \beta v_t + g_t, \\ \theta_{t+1} &= \theta_t - \eta v_{t+1}. \end{aligned}$$

Для Momentum градиент берётся в θ_t, для Nesterov — в θ_t^{look}.

Замечание При $\beta = 0$ обе формулы переходят в обычный GD. Термин «опережение» описывает *место вычисления градиента*, а не предсказание точного положения минимума.

AdaGrad: накопление квадратов градиентов

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *AdaGrad (адаптивный градиентный метод)* хранит сумму квадратов предыдущих градиентов. Здесь $u \odot v = (u_1 v_1, \ldots, u_m v_m)^T$ — *покоординатное произведение*:

$$G_{t+1} = G_t + g_t \odot g_t, \qquad G_0 = 0,$$
$$\theta_{t+1} = \theta_t - \eta \frac{g_t}{\sqrt{G_{t+1}} + \varepsilon}.$$

Квадратный корень, деление и сложение с $\varepsilon > 0$ выполняются по координатам.

Пример Если первый градиент $g_0 = (2, 1)^T$, то $G_1 = (4, 1)^T$. При малом ε масштабы шага равны приблизительно $\eta/2$ и η.

Следствие Для координаты j эффективный шаг имеет масштаб

$$\eta_{t,j} = \frac{\eta}{\sqrt{G_{t+1,j}} + \varepsilon}.$$

Поскольку $G_{t,j}$ не убывает, этот масштаб может со временем стать очень малым — главный недостаток AdaGrad.

RMSProp: не суммировать всю историю

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Идея В AdaGrad квадрат градиента накапливается навсегда. Заменим сумму *экспоненциальным скользящим средним*, в котором давние градиенты постепенно забываются.

Определение *RMSProp*:

$$s_{t+1} = \rho s_t + (1-\rho)(g_t \odot g_t), \qquad s_0 = 0,$$
$$\theta_{t+1} = \theta_t - \eta \frac{g_t}{\sqrt{s_{t+1}} + \varepsilon}, \qquad 0 \leq \rho < 1.$$

Замечание При постоянном масштабе градиентов s_t стабилизируется, а не растёт без ограничения, как сумма в AdaGrad. Поэтому масштаб шага может сохраняться и на поздних итерациях.

Adam: инерция и адаптивный масштаб

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Идея Momentum сглаживает направление градиента, RMSProp — его покоординатный масштаб. *Adam* объединяет эти идеи.
При $g_t = \nabla L(\theta_t)$, $m_0 = s_0 = 0$:

$$m_{t+1} = \beta_1 m_t + (1 - \beta_1) g_t,$$
$$s_{t+1} = \beta_2 s_t + (1 - \beta_2)(g_t \odot g_t).$$

Поправки на нулевую инициализацию:

$$\widehat{m}_{t+1} = \frac{m_{t+1}}{1 - \beta_1^{t+1}}, \qquad \widehat{s}_{t+1} = \frac{s_{t+1}}{1 - \beta_2^{t+1}}.$$

Определение Шаг Adam ($\varepsilon > 0$):

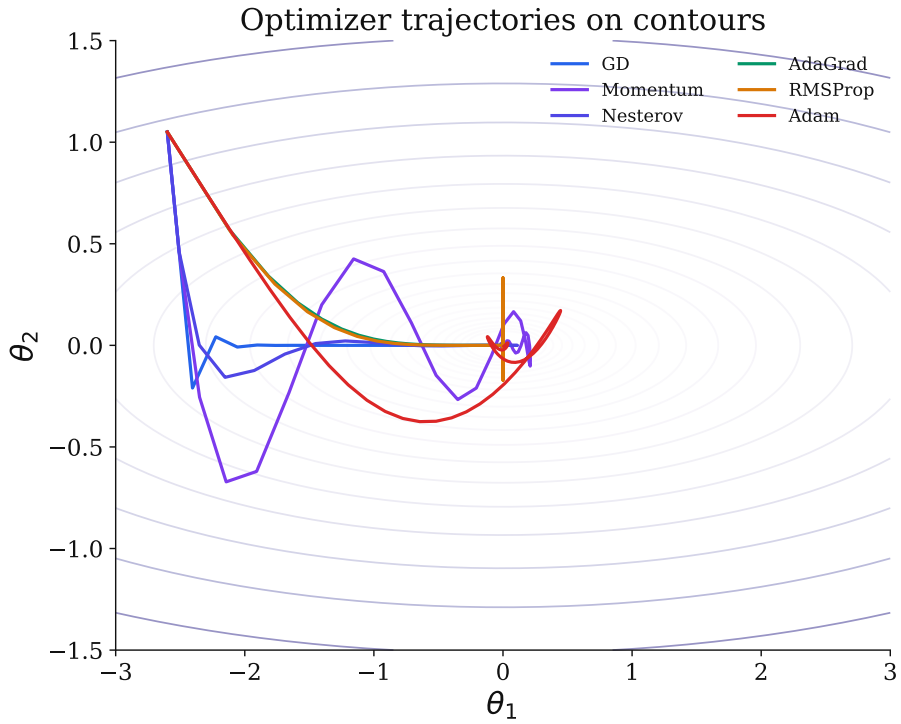
$$\boxed{\theta_{t+1} = \theta_t - \eta \frac{\widehat{m}_{t+1}}{\sqrt{\widehat{s}_{t+1}} + \varepsilon}}.$$

Замечание Квадраты, корни, деление и прибавление ε в формулах векторов выполняются покоординатно; $\odot$ — покоординатное произведение. Adam не гарантирует превосходства на любой задаче.

Траектории методов на линиях уровня

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

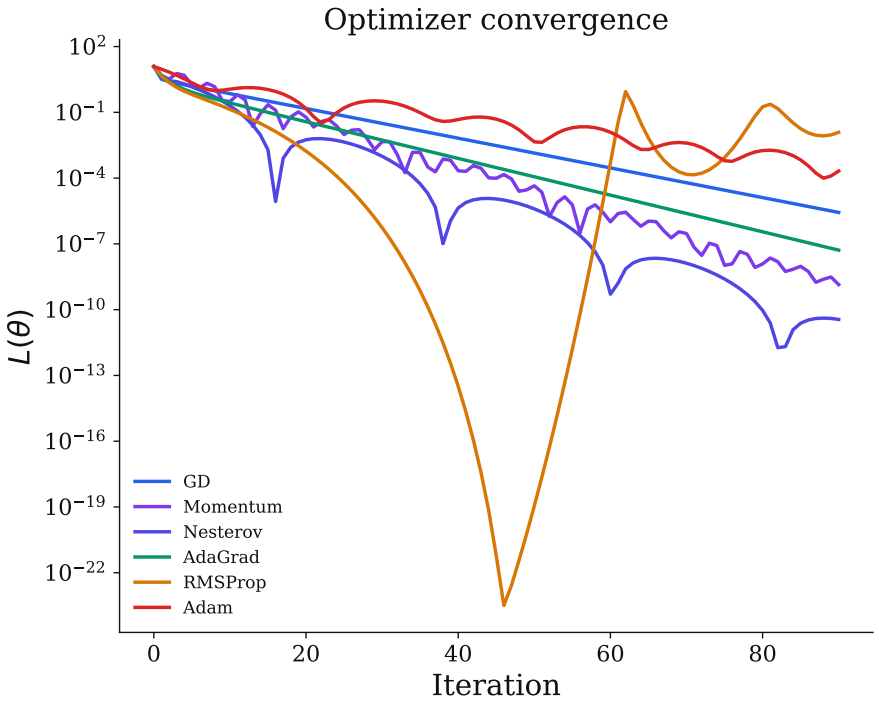
На одной функции и из одной стартовой точки методы могут выбирать разные направления и длины шагов.



Замечание Это учебная иллюстрация конкретного эксперимента, а не доказательство, что один алгоритм всегда быстрее другого.

Сравнение оптимизаторов по функции потерь

Для объективного сравнения задают одинаковые данные, начальную точку и критерий остановки; параметры методов при этом требуют подбора.



Замечание На графике показана зависимость $L(\theta_t)$ от номера итерации для конкретных настроек. Ускорение на этой задаче не гарантирует превосходства метода на другой функции.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 4
Решающие деревья и ансамбли

Что меняется при переходе от линейной модели к дереву?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Задача Построить правило, которое умеет выбирать разные ответы в разных областях пространства признаков.
Линейная модель использует одну формулу $f_\theta(x)$ для всей области. Дерево вместо этого последовательно проверяет условия на признаки:

$$x_j \leq t \quad \text{или} \quad x_j > t.$$

Определение *Решающее дерево* (Decision Tree) — модель из внутренних вершин с условиями и листьев с прогнозами.
Пример Для стоимости жилья: «площадь > 50?» — затем «район центральный?» — в достигнутом листе прогноз среднего значения цены.
Замечание Сами признаки, пороги и структура дерева *выбираются* по обучающей выборке. Это дискретная задача, не похожая на настройку коэффициентов прямой.

Один split: формальное разбиение выборки

Пусть $S \subseteq D_{\text{train}}$ — объекты, попавшие в текущую вершину дерева.

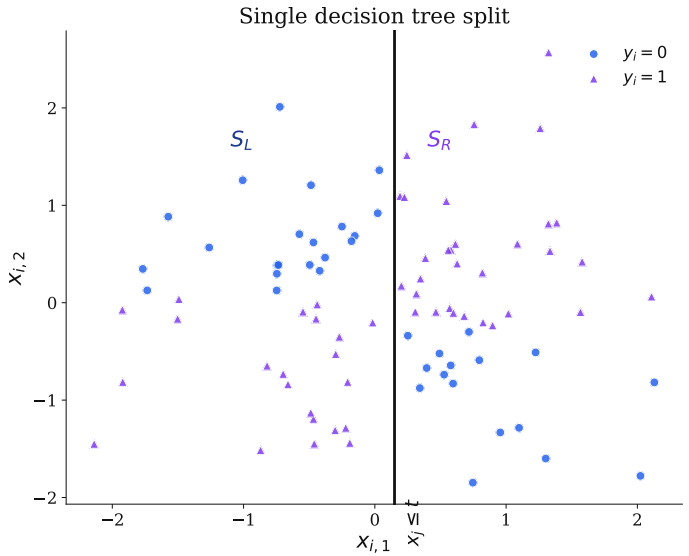
Определение Пара (j, t) определяет два непересекающихся множества:

$$S_L(j,t) = \{(x_i, y_i) \in S : x_{ij} \le t\},$$

$$S_R(j,t) = \{(x_i, y_i) \in S : x_{ij} > t\}.$$

Вместе они образуют $S = S_L \sqcup S_R$.

Замечание Для числовых признаков достаточно проверять пороги между соседними различными отсортированными значениями признака.



Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Регрессия: оцениваем разброс ответов через MSE

Задача Если ответы y_i — вещественные числа (например, цены квартир), дереву нужно разбивать объекты на группы с близкими значениями y_i.

Определение Для непустой вершины S обозначим средний ответ

$$\bar{y}_S = \frac{1}{|S|} \sum_{(x_i, y_i) \in S} y_i.$$

Её *неоднородностью* можно считать среднюю квадратичную ошибку относительно этого среднего:

$$\boxed{H_{\text{reg}}(S) = \frac{1}{|S|} \sum_{(x_i, y_i) \in S} (y_i - \bar{y}_S)^2.}$$

Идея Эта формула — знакомая MSE из главы 2. Только здесь предсказание внутри вершины постоянно и равно $\bar{y}_S$.

Пример Для ответов $1, 1, 5, 5$ имеем $\bar{y}_S = 3$ и

$$H_{\text{reg}}(S) = \frac{(1-3)^2 + (1-3)^2 + (5-3)^2 + (5-3)^2}{4} = 4.$$

Если разделить объекты на группы $(1, 1)$ и $(5, 5)$, то MSE в каждой из двух новых вершин равна нулю.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Классификация: индекс Джини

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Задача Для классификации ответы — номера классов, поэтому обычная MSE между их номерами зависит от произвольной нумерации. Вместо неё оцениваем *смешанность классов* в вершине.

Определение Пусть $p_k(S)$ — доля объектов класса k среди объектов вершины S, причём $\sum_{k=1}^{K} p_k(S) = 1$. *Индекс Джини* задаётся формулой

$$\boxed{H_{\text{Gini}}(S) = 1 - \sum_{k=1}^{K} p_k(S)^2.}$$

Идея Это вероятность того, что два *независимых* случайных выбора класса по распределению $(p_1, \ldots, p_K)$ дадут разные классы.

Пример Для двух классов с долями p и $1 - p$:

$$H_{\text{Gini}} = 1 - p^2 - (1 - p)^2 = 2p(1 - p).$$

При $p = 1/2$ получаем $H_{\text{Gini}} = 1/2$, а при $p = 0$ или $p = 1$ неоднородность равна нулю: все объекты одного класса.

Классификация: энтропия Шеннона

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение Ещё одна мера неоднородности — *энтропия Шеннона*:

$$H_{\text{ent}}(S) = -\sum_{k=1}^{K} p_k(S) \ln p_k(S).$$

Здесь ln — натуральный логарифм, а $0 \ln 0$ по определению считается равным нулю.

Идея Величина $-\ln p_k$ показывает, насколько неожиданно появление класса k. Энтропия — среднее значение этой неопределённости по всем классам.

Пример Для двух классов:

$$H_{\text{ent}}(1/2, 1/2) = \ln 2, \qquad H_{\text{ent}}(1, 0) = 0.$$

Замечание И Джини, и энтропия равны нулю в полностью однородной вершине и максимальны, когда классы представлены поровну. Они измеряют одну идею, но численно различаются и могут выбирать разные разбиения.

Общий критерий качества разбиения

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение Теперь можно обозначить выбранную меру неоднородности одной буквой $H(S)$:

$$H(S) = \begin{cases} H_{\text{reg}}(S), & \text{регрессия (MSE)}, \\ H_{\text{Gini}}(S) \text{ или } H_{\text{ent}}(S), & \text{классификация}. \end{cases}$$

Пусть проверка $x_j \leq t$ разделила вершину S на непустые $S_L = S_L(j,t)$ и $S_R = S_R(j,t)$. *Уменьшение неоднородности* при этом разбиении:

$$\boxed{Q(S,j,t) = H(S) - \frac{|S_L|}{|S|} H(S_L) - \frac{|S_R|}{|S|} H(S_R).}$$

Идея Из неоднородности *до* разбиения вычитается средняя неоднородность *после*, причём вес каждой группы — доля объектов в ней: $|S_L|/|S|$ и $|S_R|/|S|$.

Следствие Хорошее разбиение уменьшает неоднородность и даёт большое значение $Q(S,j,t)$.

Как дерево выбирает лучшее разбиение?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Алгоритм В каждой вершине рассматриваются допустимые признаки j и пороги t. Для каждой пары вычисляется $Q(S, j, t)$, после чего выбирается

$$\boxed{(j^*, t^*) \in \arg\max_{j,t} Q(S, j, t).}$$

Пример Рассмотрим две ситуации:

- Если после разбиения каждая дочерняя вершина столь же неоднородна, как исходная, то $Q(S, j, t) = 0$: качество не улучшилось.
- Если дочерние вершины стали однороднее, то $Q(S, j, t) > 0$; более высокий Q означает более удачный split.

Замечание Пустая дочерняя вершина недопустима. Для MSE, индекса Джини и энтропии Шеннона взвешенная неоднородность при разбиении не возрастает, поэтому $Q(S, j, t) \geq 0$.

Замечание Это *жадное* решение: выбирается лучшее разбиение текущей вершины, а не глобально оптимальное дерево.

Числовой пример критерия Джини

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Пример В корне находятся четыре объекта: два класса 0 и два класса 1.

$$H_{\text{Gini}}(S) = 1 - \left(\tfrac{2}{4}\right)^2 - \left(\tfrac{2}{4}\right)^2 = \tfrac{1}{2}.$$

Предположим, порог разделяет их на *чистые* группы: слева оба объекта класса 0, справа оба класса 1.

$$H(S_L) = H(S_R) = 0, \qquad Q(S, j, t) = \tfrac{1}{2} - 0 = \boxed{\tfrac{1}{2}}.$$

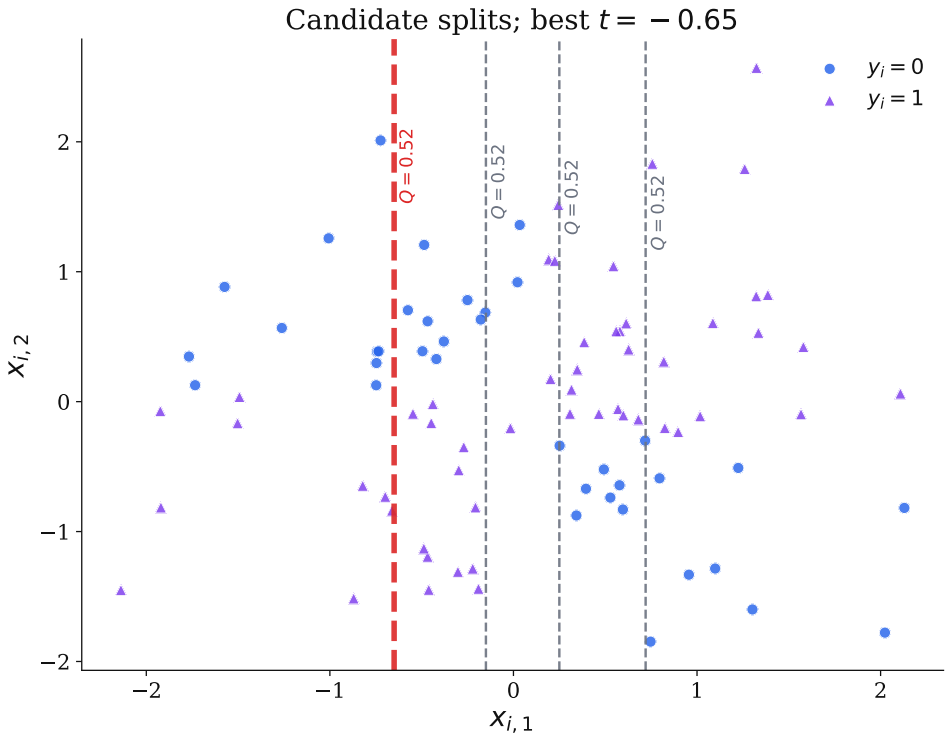
Если же каждый дочерний узел снова содержит по одному объекту каждого класса, то

$$Q(S, j, t) = \tfrac{1}{2} - \tfrac{2}{4} \cdot \tfrac{1}{2} - \tfrac{2}{4} \cdot \tfrac{1}{2} = 0.$$

Следствие Хороший split делает ответы дочерних вершин более однородными. Например, если в одном дочернем узле доли классов $3/4$ и $1/4$, то $H_{\text{Gini}} = 1 - (3/4)^2 - (1/4)^2 = 3/8 < 1/2$.

Как выбирается порог среди кандидатов?

Для фиксированного признака алгоритм сравнивает возможные пороги t и выбирает тот, который сильнее уменьшает неоднородность $H(S)$.



Замечание На рисунке показан один иллюстративный набор данных. Результат сравнения зависит от выбранного критерия и состава вершины.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Как дерево строится: жадный алгоритм

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Алгоритм

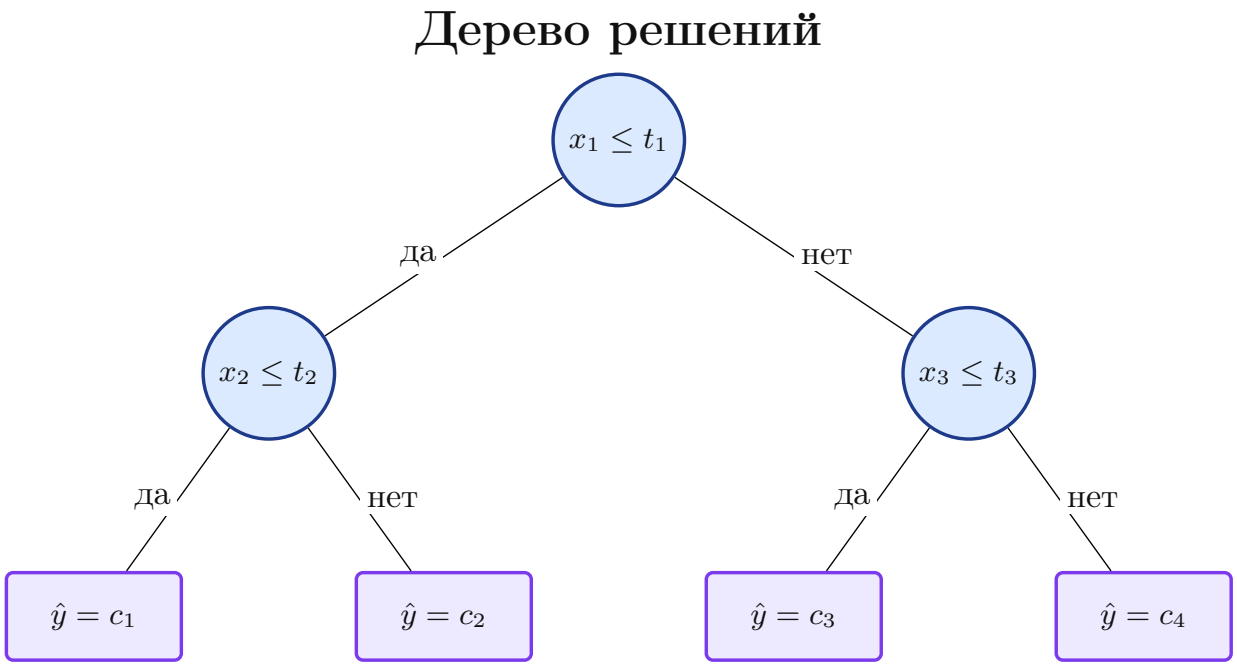
1. Положить $S = D_{\text{train}}$ в корень.
2. В вершине перебрать допустимые признаки j и пороги t.
3. Вычислить $Q(S, j, t)$, выбрать максимальное улучшение.
4. Разделить объекты на S_L и S_R и повторить рекурсивно.
5. Остановиться при малом числе объектов, предельной глубине или отсутствии улучшения.

Замечание В листьях возвращается среднее y для регрессии или наиболее частый класс для классификации. **Следствие** Глубина дерева контролирует сложность модели: слишком глубокое дерево может подогнать и шум обучающей выборки.

Структура обученного дерева

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Внутренняя вершина хранит условие $x_j \leq t$, а лист — прогноз. Для нового объекта последовательно проверяем условия от корня до листа.



Замечание В отличие от линейной регрессии дерево задаёт кусочно-постоянную функцию на областях пространства признаков.

Bootstrap: как Random Forest получает разные деревья?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Bootstrap-выборка* — новая выборка размера n, полученная из n исходных объектов случайными выборами *с возвращением*.

Пример Из объектов с номерами $1, 2, 3, 4, 5$ можно получить индексы $(2, 2, 3, 5, 5)$: объекты 2 и 5 повторились, а 1 и 4 не попали в данную выборку.

Алгоритм В *Random Forest (случайном лесе)*:

1. Для каждого дерева независимо создают bootstrap-выборку.
2. В каждой вершине случайно выбирают часть признаков и среди них ищут лучшее разбиение.
3. Объединяют прогнозы деревьев (среднее или голосование).

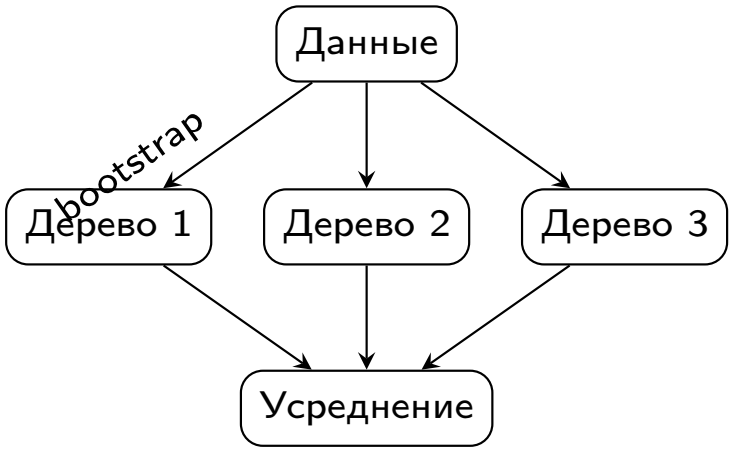
Замечание Эти две случайности уменьшают сходство деревьев. Их усреднение помогает снизить разброс предсказаний, но не гарантирует улучшения на любой выборке.

Random Forest и Gradient Boosting: разная логика

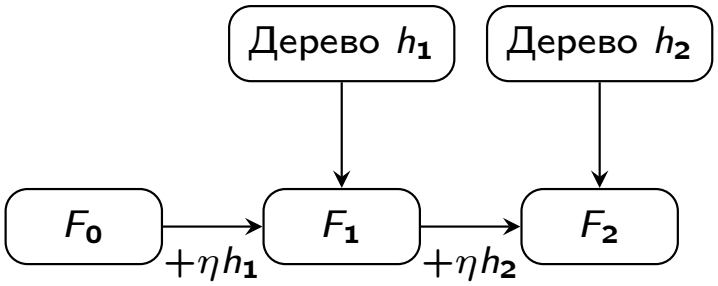
Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Утверждение *Random Forest* обучает деревья независимо и объединяет их ответы. *Gradient Boosting* обучает их последовательно: каждое новое дерево дополняет уже построенную модель.

Random Forest



Gradient Boosting



следующее дерево зависит от текущих ошибок

Forest (регрессия): $F(x) = \frac{1}{M}\sum_{m=1}^{M} h_m(x)$, Boosting: $F_m = F_{m-1} + \eta h_m$.

Замечание Для классификации лес использует голосование или усреднение вероятностей; деревья бустинга зависят от предыдущих.

Gradient Boosting: последовательное исправление ошибок

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Градиентный бустинг* строит последовательность функций

$$\boxed{F_m(x) = F_{m-1}(x) + \eta h_m(x)}, \qquad \eta > 0,$$

где F_{m-1} — ансамбль, h_m — новое дерево, η — шаг.

Замечание Здесь обновляется функция F, а не вектор параметров θ.

Задача Пусть на выборке оптимизируется

$$L(F) = \frac{1}{n}\sum_{i=1}^{n} \ell\big(y_i, F(x_i)\big).$$

Для дифференцируемой потери на шаге m определяют *псевдоостатки*

$$\boxed{r_i^{(m)} = -\left.\frac{\partial \ell(y_i, z)}{\partial z}\right|_{z=F_{m-\mathbf{1}}(x_i)}}.$$

Дерево h_m обучается приближать значения $r_i^{(m)}$.

При MSE бустинг приближает обычные остатки

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Возьмём квадратичную потерю (как в главе 2):

$$\ell(y,z) = (y-z)^2, \qquad -\frac{\partial \ell(y,z)}{\partial z} = 2(y-z).$$

Следовательно,

$$r_i^{(m)} = 2\big(y_i - F_{m-1}(x_i)\big).$$

Множитель 2 можно учесть при подборе масштаба поправки. Содержательно дерево учится предсказывать остатки текущей модели.

Пример Если $y_i = 10$, а $F_{m-1}(x_i) = 7$, то остаток 3; новое дерево должно предложить положительную поправку.

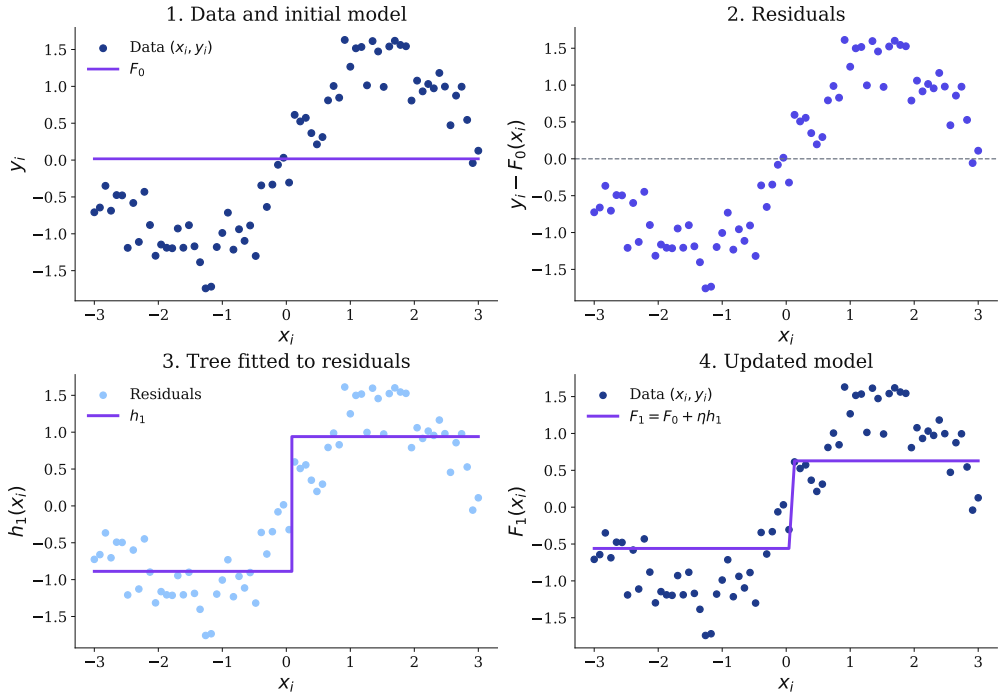
Следствие Обычный GD меняет вектор θ по антиградиенту; Gradient Boosting строит новое направление в пространстве прогнозов посредством дерева h_m.

Gradient Boosting: последовательность поправок

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Идея Начальная функция F_0 постепенно улучшается добавлением новых деревьев h_m:

$$F_m(x) = F_0(x) + \eta \sum_{k=1}^{m} h_k(x).$$

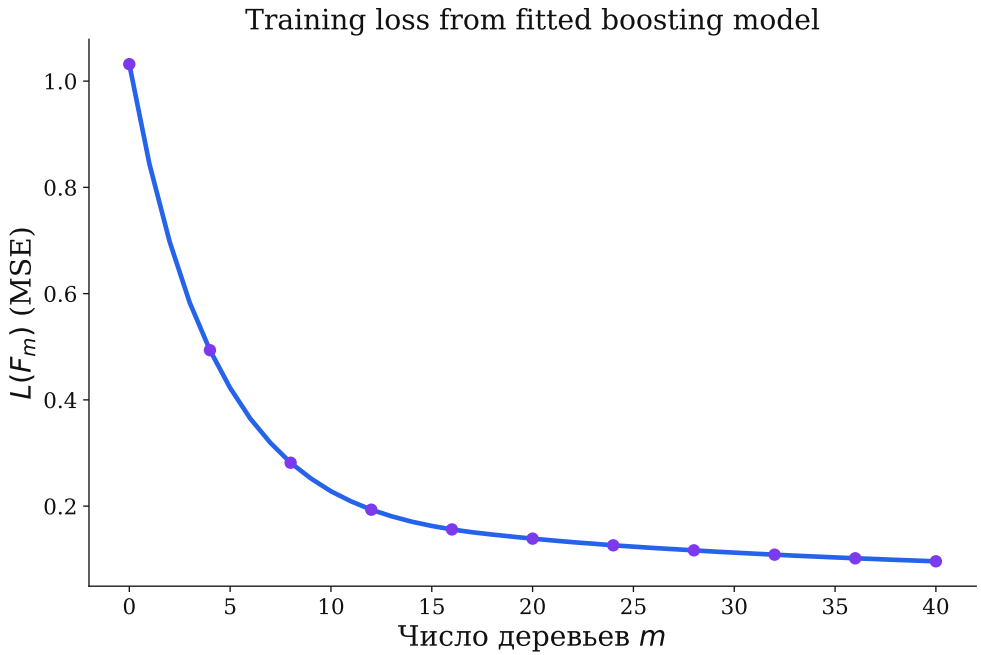


Замечание Каждая поправка обучается на псевдоостатках предыдущей модели.

Gradient Boosting: как меняется ошибка

Качество ансамбля на обучающей выборке оценивают той же функцией эмпирического риска:

$$L(F_m) = \frac{1}{n} \sum_{i=1}^{n} \ell\big(y_i, F_m(x_i)\big).$$



Замечание График иллюстрирует один эксперимент. Убывание ошибки на каждой итерации не гарантировано для произвольного шага и структуры деревьев.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 5
Нейронные сети

От линейной модели к искусственному нейрону

В главе 2 предсказание имело вид $w^T x + b$. *Искусственный нейрон* добавляет к этой величине нелинейное преобразование:

$$\boxed{z = w^T x + b, \qquad a = \varphi(z)}.$$

Определение w — веса признаков, b — смещение (bias), φ — *функция активации*.

Пример $x = (2, 1)^T$, $w = (0.5, -1)^T$, $b = 0.5$:

$$z = 0.5 \cdot 2 - 1 \cdot 1 + 0.5 = 0.5.$$

При $\varphi(z) = \max(0, z)$ получаем $a = 0.5$.

Замечание Веса и смещения будут обучаемыми параметрами; вектор всех параметров по-прежнему обозначается θ. По правилу цепочки для дифференцируемой φ:

$$\nabla_w a = \varphi'(z) x, \qquad \frac{\partial a}{\partial b} = \varphi'(z).$$

Так простая модель уже требует производных для настройки своих весов.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Почему нейрону нужна нелинейная активация?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Композиция двух аффинных преобразований остаётся аффинной:

$$z_1 = W_1 x + b_1, \qquad z_2 = W_2 z_1 + b_2,$$

$$z_2 = (W_2 W_1)x + (W_2 b_1 + b_2).$$

Без активаций несколько слоёв эквивалентны одному.
Определение Примеры активаций:

$$\mathrm{ReLU}(z) = \max(0, z), \qquad \sigma(z) = \frac{1}{1 + e^{-z}},$$

$$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}.$$

Следствие Нелинейности позволяют сети выражать зависимости, которые нельзя представить одной линейной моделью исходных признаков. **Замечание** Для сигмоиды $\sigma'(z) = \sigma(z)(1 - \sigma(z))$; для ReLU производная равна 0 при $z < 0$ и 1 при $z > 0$ (в нуле обычная производная не существует).

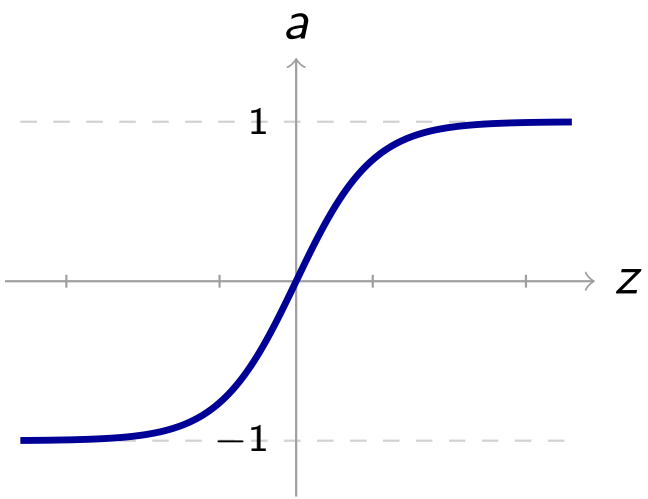
Геометрия функций активации

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Идея Нелинейность меняет форму зависимости между входом и выходом нейрона; именно поэтому последовательность слоёв уже нельзя заменить одной аффинной функцией.

Гиперболический тангенс

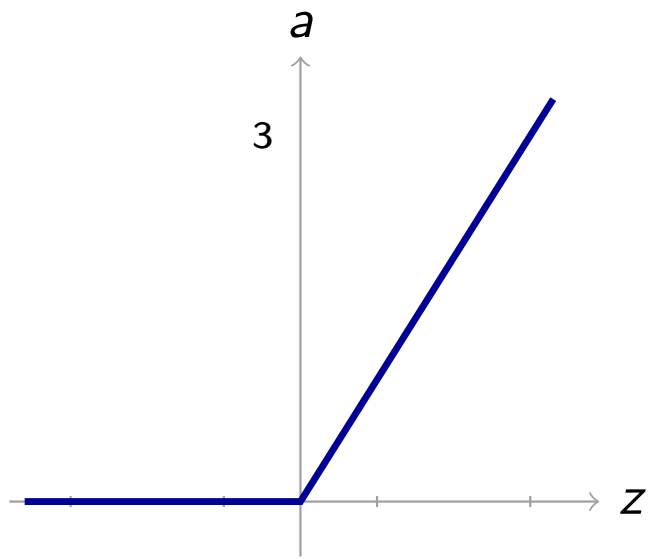
$$\varphi(z) = \tanh z$$



Плавная активация,
$-1 < \tanh z < 1$.

ReLU

$$\varphi(z) = \max(0, z)$$



Обнуляет отрицательные входы.

Замечание Производная ReLU равна нулю при $z < 0$ и единице при $z > 0$; в точке $z = 0$ обычная производная не существует.

Многослойная сеть: последовательность функций

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Multilayer Perceptron* (MLP) — композиция слоёв, каждый из которых применяет линейное преобразование и нелинейность.

Обозначим вход $a^{(0)} = x$. Для слоя $\ell = 1, \ldots, L$:

$$\boxed{z^{(\ell)} = W^{(\ell)} a^{(\ell-1)} + b^{(\ell)}},$$

$$\boxed{a^{(\ell)} = \varphi_\ell(z^{(\ell)})}.$$

Размеры: $W^{(\ell)} \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$, $b^{(\ell)} \in \mathbb{R}^{d_\ell}$.

Замечание Все $W^{(\ell)}$ и $b^{(\ell)}$ составляют один вектор параметров θ.

Например, для двух слоёв:

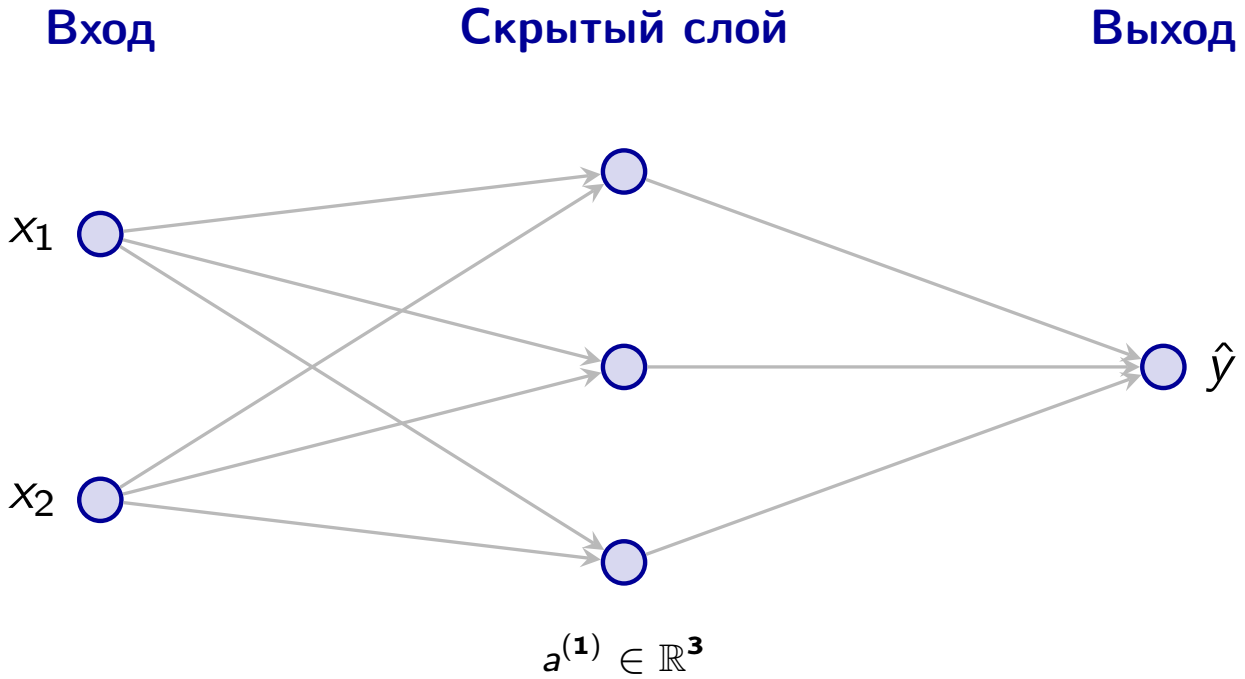
$$f_\theta(x) = \varphi_2\Big(W^{(2)}\varphi_1(W^{(1)}x + b^{(1)}) + b^{(2)}\Big).$$

Выход $f_\theta(x)$ — результат последнего слоя.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Схема MLP: как формулы соответствуют слоям

Пусть два входных признака поступают в скрытый слой из трёх нейронов, а затем — в один выходной нейрон.



Утверждение Размерности определяют форму матриц:

$$W^{(1)} \in \mathbb{R}^{3\times 2}, \qquad W^{(2)} \in \mathbb{R}^{1\times 3}, \qquad f_\theta(x) = \varphi_2\Big(W^{(2)} a^{(1)} + b^{(2)}\Big).$$

Замечание Линии — отдельные обучаемые веса. В скрытом слое вычисляются признаки $a^{(1)}$, которых не было в исходной выборке.

Прямой проход: расчёт двухслойной сети

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Пример Возьмём $x = (1, 2)^T$, два нейрона в скрытом слое и один вероятностный выход. Пусть

$$W^{(1)} = \begin{pmatrix} 1 & -1 \\ 0 & 1 \end{pmatrix}, \quad b^{(1)} = \begin{pmatrix} 0 \\ -1 \end{pmatrix}, \quad W^{(2)} = \begin{pmatrix} 2 & -1 \end{pmatrix}, \quad b^{(2)} = \tfrac{1}{2}.$$

Алгоритм *Forward pass* (прямое распространение):

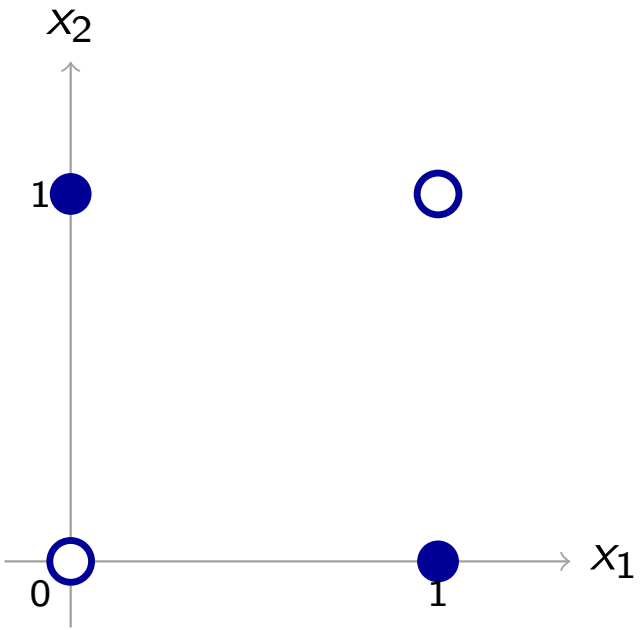
$$\begin{aligned} z^{(1)} &= W^{(1)}x + b^{(1)} = (-1, 1)^T, \\ a^{(1)} &= \mathrm{ReLU}(z^{(1)}) = (0, 1)^T, \\ z^{(2)} &= W^{(2)}a^{(1)} + b^{(2)} = -\tfrac{1}{2}, \\ p &= \sigma(z^{(2)}) \approx 0.378. \end{aligned}$$

Замечание На каждом слое размерности матриц согласованы: $W^{(1)} \in \mathbb{R}^{2\times 2}$, $W^{(2)} \in \mathbb{R}^{1\times 2}$. Если $y = 0$, то BCE $= -\log(1 - p) \approx 0.474$.

Пример: задача XOR и роль скрытого слоя

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Задача Для $x_1, x_2 \in \{0, 1\}$ предсказать 1, если входы различаются, и 0 иначе (XOR).



• — класс 1; ∘ — класс 0.

Утверждение Одна прямая не может отделить закрашенные точки от незакрашенных: классы линейно неразделимы. **Пример** Построим сеть с двумя скрытыми ReLU-нейронами:

$$h_1 = \mathrm{ReLU}(x_1 + x_2),$$
$$h_2 = \mathrm{ReLU}(x_1 + x_2 - 1),$$
$$f(x) = h_1 - 2h_2.$$

Следствие При $x_1 + x_2 = 0, 1, 2$ функция выдаёт соответственно $0, 1, 0$. Нелинейный скрытый слой решает задачу, недоступную одной линейной границе.

Пример архитектуры: распознавание цифр

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Изображение 28×28 в оттенках серого представляют вектором $x \in \mathbb{R}^{784}$ (например, яркости от 0 до 1).
Возможная MLP-архитектура:

$$\boxed{784 \longrightarrow 128 \longrightarrow 64 \longrightarrow 10}.$$

Определение 784 — размер входа, 128 и 64 — числа нейронов скрытых слоёв, 10 — числа выходных оценок классов.
Пример Количество обучаемых весов и смещений:

$$(784 \cdot 128 + 128) + (128 \cdot 64 + 64) + (64 \cdot 10 + 10) = 109\,386.$$

Замечание Это лишь пример архитектуры из исходного материала по нейросетям, а не требование для распознавания цифр. Большая сеть не гарантирует лучшего качества.

Scores и Softmax: как сеть выдаёт вероятности?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Score* (также *logit*) $z_k \in \mathbb{R}$ — вещественная оценка класса k *до* перевода в вероятность. Она может быть отрицательной и не обязана лежать между 0 и 1.

Определение *Softmax* преобразует вектор $z = (z_1, \ldots, z_K)^T$ в распределение по K классам:

$$\boxed{p_k = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}}}, \qquad 0 < p_k < 1, \quad \sum_{k=1}^{K} p_k = 1.$$

Пример Если $z = (0, \log 2, \log 3)^T$, то

$$(e^{z_1}, e^{z_2}, e^{z_3}) = (1, 2, 3), \qquad p = \left(\tfrac{1}{6}, \tfrac{2}{6}, \tfrac{3}{6}\right)^T.$$

Замечание Чем больше score класса относительно остальных, тем больше его вероятность. Прибавление одной константы ко всем z_k не изменяет результат Softmax.

Выход сети и функция потерь

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Разные задачи требуют разных интерпретаций выхода сети и разных функций потерь.

Определение *Регрессия:* прогноз — число $\hat{y} = f_\theta(x) \in \mathbb{R}$.

Например,

$$\boxed{\ell_{\text{MSE}}(y, \hat{y}) = (y - \hat{y})^2}.$$

Определение *Бинарная классификация:* $p = \sigma(z)$ — вероятность класса 1, $y \in \{0, 1\}$. Используется

$$\boxed{\ell_{\text{BCE}}(y, p) = -y \log p - (1 - y) \log(1 - p)}.$$

Определение *Многоклассовая классификация:* $p = \text{softmax}(z)$ — распределение по K классам. При правильном классе $y \in \{1, \ldots, K\}$:

$$\boxed{\ell_{\text{CE}}(y, p) = -\log p_y}.$$

Замечание Общий принцип из главы 1 сохраняется: прогноз $\to$ потеря $\to$ минимизация эмпирического риска.

Softmax и Cross-Entropy: производная по score

Для многоклассовой классификации $z = (z_1, \ldots, z_K)^T$ — выходные *scores*, $p_k = e^{z_k} / \sum_j e^{z_j}$ — вероятности. Потеря при правильном классе y равна

$$\ell(z, y) = -\log p_y = -z_y + \log\left(\sum_{j=1}^{K} e^{z_j}\right).$$

Утверждение Производная по каждой компоненте score:

$$\frac{\partial \ell}{\partial z_k} = -\mathbf{1}\{k = y\} + \frac{e^{z_k}}{\sum_j e^{z_j}}$$
$$= \boxed{p_k - \mathbf{1}\{k = y\}}.$$

Пример При $p = (0.1, 0.7, 0.2)$ и правильном классе $y = 2$:

$$\nabla_z \ell = (0.1, -0.3, 0.2)^T.$$

Следствие Как и в логистической регрессии, производная имеет форму «прогноз минус правильный ответ» (здесь последний закодирован единицей в компоненте нужного класса).

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Обучение нейросети: тот же Gradient Descent

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вектор θ содержит все веса и смещения, а $L(\theta)$ — среднюю потерю на обучающей выборке:

$$\hat{\theta} \in \arg\min_{\theta} L(\theta).$$

Алгоритм Один шаг обучения включает три разные операции:

1. *Forward pass*: вычислить прогнозы $f_{\theta_t}(x_i)$.
2. *Backpropagation*: найти производные ошибки по всем весам и смещениям.
3. *Оптимизатор* (GD/Adam): использовать эти производные для обновления θ_{t+1}.

Утверждение Например, при градиентном спуске

$$\boxed{\theta_{t+1} = \theta_t - \eta g_t},$$

где g_t — градиент выбранной на шаге функции потерь.

Замечание Backpropagation *вычисляет* градиент; оптимизатор *использует* его для изменения параметров.

Mini-batch: градиент и его оценка

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Mini-batch* B_t — небольшая случайная группа объектов из обучающей выборки. Её функция потерь:

$$\boxed{L_{B_t}(\theta) = \frac{1}{|B_t|} \sum_{i \in B_t} \ell(y_i, f_\theta(x_i))}.$$

Утверждение Backpropagation вычисляет градиент именно этой функции:

$$\boxed{g_t = \nabla L_{B_t}(\theta_t)}.$$

Поэтому для выбранного набора объектов градиент вычисляется *точно* (с учётом точности арифметики), но обычно $g_t \neq \nabla L(\theta_t)$ для полной выборки.

Определение *Эпоха (epoch)* — один проход по всем объектам обучающей выборки, обычно состоящий из многих mini-batch-шагов.

Следствие Случайность появляется из выбора mini-batch, а не из самого правила цепочки.

Backpropagation: применение правила цепочки

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Backpropagation* (обратное распространение ошибки) — эффективное вычисление градиентов по весам сети с помощью правила цепочки.

Пример Для цепочки

$$h = \tanh(wx + b), \quad \hat{y} = vh + c, \quad \ell = (\hat{y} - y)^2$$

вклад веса w в ошибку составляет

$$\frac{\partial \ell}{\partial w} = \underbrace{2(\hat{y} - y)}_{\partial \ell / \partial \hat{y}} \cdot \underbrace{v}_{\partial \hat{y} / \partial h} \cdot \underbrace{(1 - h^2)}_{\partial h / \partial (wx+b)} \cdot \underbrace{x}_{\partial (wx+b) / \partial w}.$$

Следствие Производные передаются от выхода к ранним слоям; промежуточные вычисления переиспользуются.

Замечание Backpropagation *вычисляет* градиент, а оптимизатор *обновляет* параметры по нему.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Backpropagation: числовой пример

Пример Рассмотрим простую сеть с одним скрытым нейроном:

$$h = \mathrm{ReLU}(wx + b), \quad \hat{y} = vh + c, \quad \ell = (\hat{y} - y)^2.$$

Пусть $x = 2$, $w = 1$, $b = 0$, $v = 3$, $c = 0$, $y = 4$.

$$h = 2, \qquad \hat{y} = 6, \qquad \ell = (6 - 4)^2 = 4.$$

Алгоритм Двигаемся от потери к ранним параметрам:

$$\frac{\partial \ell}{\partial \hat{y}} = 2(\hat{y} - y) = 4,$$

$$\frac{\partial \ell}{\partial v} = 4h = 8, \qquad \frac{\partial \ell}{\partial c} = 4,$$

$$\frac{\partial \ell}{\partial h} = 4v = 12,$$

$$\frac{\partial \ell}{\partial w} = 12 \cdot \mathrm{ReLU}'(2) \cdot x = 24, \quad \frac{\partial \ell}{\partial b} = 12.$$

Следствие Каждая производная использует уже найденную производную на следующем участке цепочки. Именно это делает backpropagation вычислительно эффективным.

Что в Backpropagation идёт «назад»?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Идея На прямом проходе сеть вычисляет выходы слоёв $a^{(1)}, \ldots, a^{(L)}$ и потерю ℓ. На обратном проходе выясняет, *какие промежуточные значения сильнее влияют на эту потерю*.

Определение *Сигнал ошибки слоя* — вектор чувствительностей

$$\boxed{\delta^{(\ell)} = \nabla_{z^{(\ell)}} \ell}, \qquad \delta_j^{(\ell)} = \frac{\partial \ell}{\partial z_j^{(\ell)}}.$$

Утверждение Для малого изменения выхода линейной части слоя

$$\Delta \ell \approx \left\langle \delta^{(\ell)}, \Delta z^{(\ell)} \right\rangle.$$

Положительная компонента $\delta_j^{(\ell)}$ означает, что увеличение $z_j^{(\ell)}$ локально повышает потерю; отрицательная — понижает.

Замечание $\delta^{(\ell)}$ — *не* разность «ответ минус прогноз», а производная потери по сигналам слоя. Поэтому её можно вычислять последовательно от выхода ко входу.

Матрица Якоби: правило цепочки для векторов

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение Для дифференцируемого отображения $F : \mathbb{R}^d \to \mathbb{R}^m$ *матрица Якоби* содержит все частные производные его компонент:

$$\boxed{J_F(x) = \left(\frac{\partial F_i}{\partial x_j}\right)_{\substack{1 \le i \le m \\ 1 \le j \le d}} \in \mathbb{R}^{m \times d}}.$$

Пример Если $F(x_1, x_2) = (x_1 + x_2, x_1 x_2)^T$, то

$$J_F(x) = \begin{pmatrix} 1 & 1 \\ x_2 & x_1 \end{pmatrix}.$$

Утверждение Для скалярной функции $g : \mathbb{R}^m \to \mathbb{R}$ многомерное правило цепочки имеет вид

$$\boxed{\nabla_x (g \circ F)(x) = J_F(x)^T \nabla g\big(F(x)\big)}.$$

Следствие На обратном проходе производные умножаются на транспонированный Якобиан очередного слоя. Отсюда и возникает рекуррентная формула Backpropagation.

Backpropagation: производные целого слоя

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Используем введённый сигнал ошибки слоя $\delta^{(\ell)} = \nabla_{z^{(\ell)}} \ell$. Символ $\odot$ обозначает покоординатное произведение векторов.

Утверждение Если активации применяются покоординатно, то правило цепочки даёт

$$\boxed{\delta^{(\ell)} = \left(W^{(\ell+1)}\right)^T \delta^{(\ell+1)} \odot \varphi_\ell'\left(z^{(\ell)}\right)}.$$

Из $z^{(\ell)} = W^{(\ell)} a^{(\ell-1)} + b^{(\ell)}$ следует

$$\boxed{\frac{\partial \ell}{\partial W^{(\ell)}} = \delta^{(\ell)} \left(a^{(\ell-1)}\right)^T}, \qquad \frac{\partial \ell}{\partial b^{(\ell)}} = \delta^{(\ell)}.$$

Замечание Так градиенты вычисляются от выхода сети ко входу; их усредняют по mini-batch и передают оптимизатору из главы 3.

Почему в глубоких сетях затухает градиент?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Затухание градиента* (vanishing gradient) — ситуация, когда производные ошибки по параметрам ранних слоёв становятся очень малы.

Идея При многократном применении правила цепочки возникает произведение производных последующих слоёв:

$$\frac{\partial \ell}{\partial h_1} = \frac{\partial \ell}{\partial h_L} \prod_{j=2}^{L} \frac{\partial h_j}{\partial h_{j-1}} \qquad \text{(для скалярной цепочки)}.$$

Если множители по модулю меньше 1, произведение может быстро уменьшаться. Например, $0.5^{10} \approx 0.001$ — за десять слоёв масштаб градиента уменьшился почти в тысячу раз.

Замечание Для векторных слоёв вместо произведения чисел возникают произведения матриц Якоби, определённых ранее. Не всякая глубокая сеть страдает от затухания градиента.

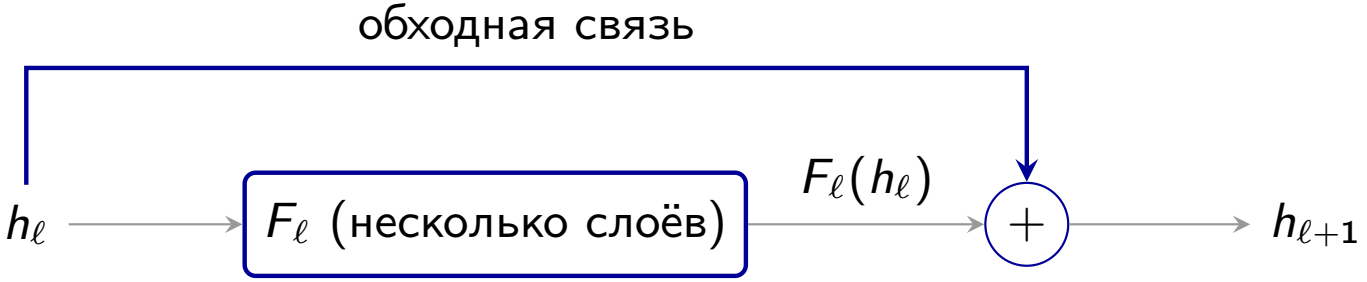
Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

ResNet: остаточные связи и путь для градиента

Определение *Остаточный блок* (residual block) вычисляет

$$\boxed{h_{\ell+1} = h_\ell + F_\ell(h_\ell)},$$

где F_ℓ — несколько обучаемых преобразований, а сложение требует согласованных размерностей.



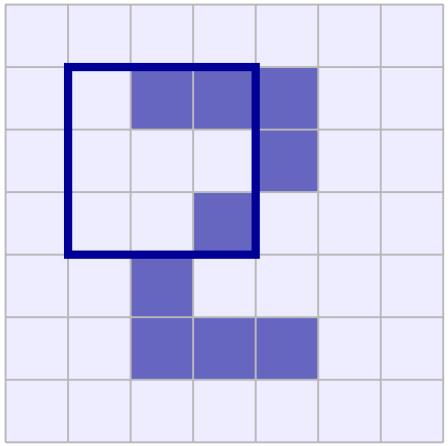
Утверждение В скалярном случае $dh_{\ell+1}/dh_\ell = 1 + F'_\ell(h_\ell)$; для векторного входа якобиан блока равен

$$\boxed{J(h_\ell) = I + J_{F_\ell}(h_\ell)}.$$

Замечание Добавка I создаёт прямой путь для передачи производных через блок и часто облегчает обучение глубоких сетей. Она не гарантирует полного отсутствия затухания градиентов.

CNN: локальные фильтры и общие веса

Определение *Convolutional Neural Network* (CNN, свёрточная сеть) обрабатывает локальные участки изображения обучаемыми фильтрами.



Выделен участок 3×3.

Идея Один фильтр последовательно перемещается по изображению и применяет *те же самые веса* к разным участкам. Это позволяет выделять локальные детали: штрихи, границы и более сложные сочетания.

Утверждение Для матрицы пикселей A и фильтра $K \in \mathbb{R}^{r \times r}$ отклик в позиции (u, v) равен

$$\boxed{B_{u,v} = \sum_{i=0}^{r-1} \sum_{j=0}^{r-1} K_{ij} A_{u+i,v+j}}.$$

Замечание В ML это обычно кросс-корреляция (без переворота ядра). При шаге 1 и отсутствии дополнения выход имеет размер $(H - r + 1) \times (W - r + 1)$.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

CNN: как фильтр обнаруживает границу

Пример Возьмём фрагмент изображения размером 3×3 и фильтр, сравнивающий левый и правый столбцы:

Участок изображения

$$A = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \end{pmatrix}$$

Веса фильтра

$$K = \begin{pmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 1 & 0 & -1 \end{pmatrix}$$

Алгоритм Перемножим соответствующие элементы и сложим:

$$s = \sum_{i=1}^{3} \sum_{j=1}^{3} A_{ij} K_{ij} = 1 + 1 + 1 = 3.$$

Следствие Если бы весь участок имел одинаковую яркость c, получилось бы $s = c \sum_{i,j} K_{ij} = 0$. Ненулевой отклик отражает перепад яркости между его краями. **Замечание** Перемещая этот фильтр по изображению, получаем *карту признака*. В примере веса заданы вручную; в обучаемой CNN они подбираются по данным.

CNN: почему общие веса экономят параметры?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Разделение весов* (weight sharing) означает, что один фильтр K применяется во всех положениях изображения.

Пример На входе изображение 28×28 с одним каналом. Применим 8 фильтров 3×3, каждый с одним смещением:

$$\boxed{N_{\text{params}} = 8(3 \cdot 3 + 1) = 80}.$$

Без дополнения и при шаге 1 получим 8 карт размером 26×26, то есть 5408 выходных значений.

Если бы у каждого положения был *собственный* фильтр, пришлось бы хранить $80 \cdot 26^2 = 54080$ параметров.

Следствие Общие веса резко уменьшают число параметров и позволяют применять один и тот же детектор признака в разных частях изображения.

Замечание Для нескольких входных каналов формула числа параметров меняется: один фильтр охватывает все входные каналы.

Как CNN получает итоговый ответ

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Карта признака* (feature map) — значения отклика фильтра во всех доступных положениях. Несколько фильтров дают несколько карт.
Обычно вслед за фильтрами применяют ReLU, а размер карт иногда уменьшают с помощью *pooling*.
Пример Max pooling по области 2×2:

$$\begin{pmatrix} 1 & 3 \\ 0 & 2 \end{pmatrix} \longmapsto \max\{1, 3, 0, 2\} = 3.$$

Следствие Слои CNN постепенно формируют признаки от локальных штрихов к более сложным структурам, а последний классификационный слой (например, с softmax) выдаёт распределение по классам.
Замечание Фильтры и выходные слои обучаются совместно методом backpropagation и оптимизатором из главы 3.

Нейросети: где здесь математический анализ?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Утверждение Нейронная сеть — параметризованная композиция функций:

$$f_\theta = F_L \circ F_{L-1} \circ \cdots \circ F_1, \qquad \theta = \{W^{(\ell)}, b^{(\ell)}\}_{\ell=1}^{L}.$$

Цель обучения *та же*, что в главе 1:

$$\hat{\theta} \in \arg\min_\theta \frac{1}{n} \sum_{i=1}^{n} \ell\big(y_i, f_\theta(x_i)\big).$$

Алгоритм Вычислительный цикл:

1. Прямой проход — последовательное вычисление композиции.
2. Backpropagation — правило цепочки для всех параметров.
3. GD/Adam — численное обновление параметров по градиенту.

Следствие В отличие от линейной регрессии сеть может строить сложные нелинейные зависимости, но математически обучение снова сводится к производным и оптимизации.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 6
Муравьиный алгоритм

Задача коммивояжёра: точная постановка

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Задача Для N городов найти *кратчайший замкнутый маршрут*, который посещает каждый город ровно один раз до возвращения в исходный город.

Определение Рассмотрим полный неориентированный взвешенный граф $G = (V, E)$, где $V = \{1, \ldots, N\}$ — города, $d_{ij} = d_{ji} > 0$ — длина ребра между разными городами.

Определение Маршрут задаётся перестановкой $\pi = (\pi_1, \ldots, \pi_N)$ вершин. Его длина:

$$\boxed{C(\pi) = \sum_{k=1}^{N-1} d_{\pi_k, \pi_{k+1}} + d_{\pi_N, \pi_1}}.$$

Последнее слагаемое — возвращение в начальный город.

Задача Найти $\pi^* \in \arg\min_\pi C(\pi)$.

Замечание Искомая переменная — перестановка, а не вектор вещественных параметров. Поэтому обычный градиентный спуск по π здесь неприменим; ACO ищет хороший маршрут вероятностно.

Ant Colony Optimization: вероятностный выбор маршрута

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Задача Для задачи коммивояжёра найти допустимый тур π с малой длиной $C(\pi)$, не перебирая все перестановки вершин.

Определение *Ant Colony Optimization* (муравьиный алгоритм) — *стохастическая метаэвристика*: алгоритм случайного поиска, использующий правила выбора и подкрепления удачных вариантов. Вероятность ребра зависит от феромона $\tau_{ij} > 0$ и привлекательности $\nu_{ij} > 0$.

$$\boxed{P_{ij} = \frac{\tau_{ij}^{\alpha} \nu_{ij}^{\beta}}{\sum_{k \in A_i} \tau_{ik}^{\alpha} \nu_{ik}^{\beta}}}, \qquad A_i \text{ — ещё не посещённые города.}$$

Пример Для расстояний $d_{ij} > 0$ берут $\nu_{ij} = 1/d_{ij}$. Если два ребра имеют $\tau_1 = 2$, $\tau_2 = 1$, $\nu_1 = \nu_2 = 1$, $\alpha = \beta = 1$, то $P_1 = \frac{2}{2+1} = \frac{2}{3}$.

Замечание Параметры $\alpha, \beta \geq 0$ управляют влиянием феромона и длины. В отличие от GD здесь оптимизируется дискретный маршрут, а не дифференцируемая функция параметров.

Ant Colony Optimization: обновление феромона

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

После построения маршрутов на итерации t уровни феромона меняются:

$$\boxed{\tau_{ij}^{(t+1)} = (1 - \rho_{\text{evap}})\tau_{ij}^{(t)} + \Delta\tau_{ij}^{(t)}},$$

где $0 < \rho_{\text{evap}} < 1$ — доля испарения, $\Delta\tau_{ij}^{(t)}$ — добавка от найденных маршрутов.

Пример В простой версии для построенных маршрутов π_k длины L_k:

$$\Delta\tau_{ij}^{(t)} = \sum_{k:\,(i,j)\in\pi_k} \frac{\kappa}{L_k}.$$

Для маршрутов длины 4 и 8 вклад каждого ребра первого вдвое больше. Так короткие пути получают подкрепление.

Следствие Случайный поиск сочетает исследование новых маршрутов и усиление уже найденных удачных решений.

Муравьиный алгоритм: полный цикл поиска

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Задача Найти хороший маршрут среди большого числа дискретных вариантов без перебора всех перестановок вершин.

Алгоритм

1. Задать начальные значения $\tau_{ij} > 0$ на доступных рёбрах.
2. Каждый «муравей» посещает все города без повторений, выбирая очередной по P_{ij}, и возвращается в стартовый город.
3. Посчитать длину L_k маршрута каждого муравья.
4. Испарить часть феромона и подкрепить рёбра найденных путей: $\tau_{ij} \leftarrow (1 - \rho_{\text{evap}})\tau_{ij} + \Delta\tau_{ij}$.
5. Повторить построение маршрутов и запомнить лучший найденный.

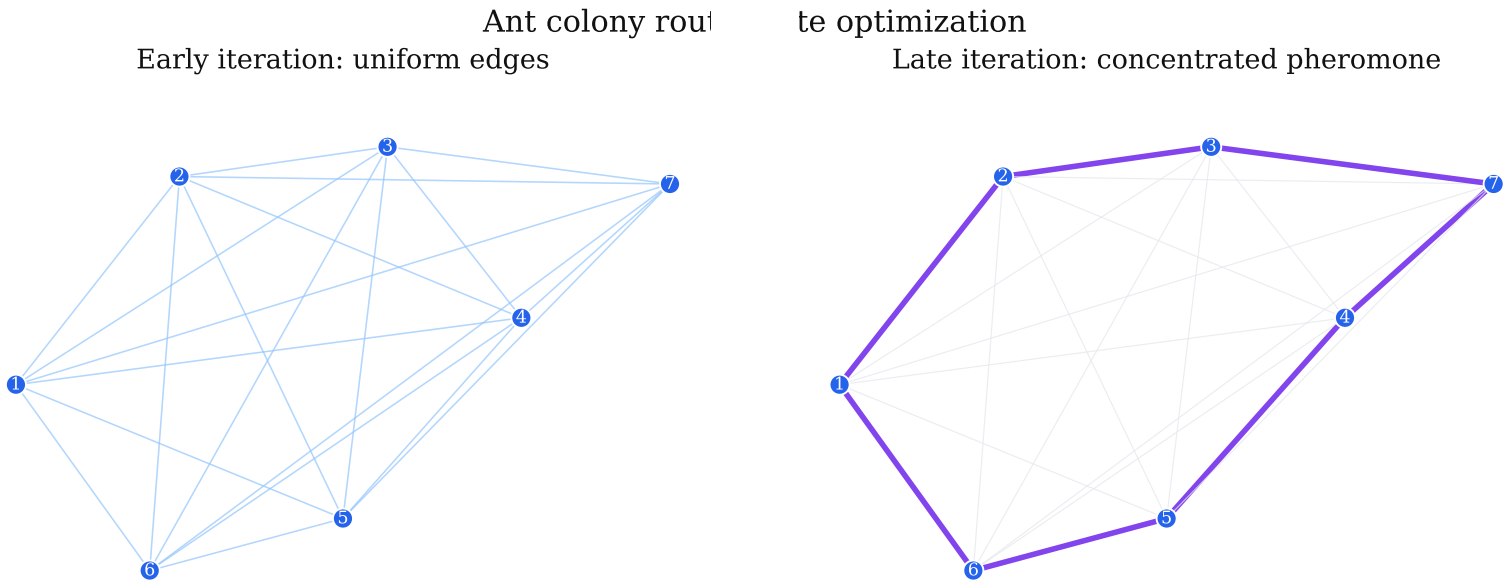
Замечание Чем короче маршрут, тем сильнее подкрепление в рассмотренной версии алгоритма. Но случайность оставляет ненулевой шанс исследования других допустимых продолжений.

Следствие Это пример оптимизации *без градиентов*: ищем удачную комбинацию дискретных решений, а не минимум дифференцируемой функции.

Муравьиный алгоритм: как усиливается маршрут

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

В начале поиск распределён по многим рёбрам; после нескольких итераций усиливаются пути, чаще встречающиеся в удачных маршрутах.



Начальные значения феромона Усиленный найденный маршрут

Замечание Из-за случайного выбора алгоритм не гарантирует глобально кратчайший путь за конечное число шагов.

Итоги: единая математическая логика

1. *Постановка:* данные D_{train}, модель f_θ, потеря ℓ и задача $\min_\theta L(\theta)$.
2. *Линейные модели:* MSE и BCE приводят к градиентам по параметрам.
3. *Оптимизация:* GD и его модификации используют локальную информацию о $L(\theta)$.
4. *Деревья и ансамбли:* дискретные разбиения и функциональная идея антиградиента в бустинге.
5. *Нейросети:* композиции функций, правило цепочки и обратное распространение градиента.
6. *Муравьиный алгоритм:* вероятностный поиск маршрута, подкрепление удачных решений и испарение феромона без вычисления градиента.

Следствие Общая линия лекции — постановка задачи, выбор класса моделей, функция потерь и способ её уменьшения. В нейросетях матанализ особенно нагляден: производные композиции позволяют обучать сразу множество взаимосвязанных параметров. Муравьиный алгоритм показывает альтернативу для дискретного поиска.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Основные источники

- Школа анализа данных Яндекса. *Учебник по машинному обучению*.
- Броиловский А. *Обзор задач машинного обучения*. ШАД СПб, 2026.
- Овчаров С. *Линейная регрессия и основы оптимизации*. ШАД СПб, 2026.
- Овчаров С. *Логистическая регрессия и классификация*. ШАД СПб, 2026.
- Zhang A., Lipton Z. C., Li M., Smola A. J. *Dive into Deep Learning*. Разделы об оптимизации, MLP, CNN и ResNet.
- Dorigo M., Stützle T. *Ant Colony Optimization*. MIT Press, 2004.
- Материалы проекта *«Математический анализ в методах машинного обучения»* и визуализации участников.

Материалы проекта на GitHub

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Исходный код и дополнительные материалы

https://github.com/Z4Y4T/ml_project