Математический анализ в методах машинного обучения

Вейгандт В., Зайцев Н., Горобец О., Козлов В., Шагеев Э.

2026

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 1
Постановка задачи машинного обучения

Обучение с учителем

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение

Пусть $\mathcal{X}$ — множество объектов, $\mathcal{Y}$ — множество допустимых ответов. *Обучающей выборкой* называется конечный набор

$$D = \{(x_i, y_i)\}_{i=1}^{n}, \qquad x_i \in \mathcal{X}, \quad y_i \in \mathcal{Y}.$$

Определение

В задаче *supervised learning* (обучения с учителем) по выборке D требуется построить алгоритм

$$f : \mathcal{X} \to \mathcal{Y},$$

который по описанию нового объекта x предсказывает соответствующий ответ.

Замечание

Правильные ответы y_i известны только для обучающих объектов; качество модели определяется её способностью переносить найденную закономерность на новые данные.

Признаковое описание задачи

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение

Числовым *признаковым описанием* объекта называется вектор

$$x = (x_1, \ldots, x_d)^T \in \mathbb{R}^d,$$

где координаты $x_1, \ldots, x_d$ называются признаками объекта.
Таким образом, обучающая выборка имеет вид

$$D = \{(x_i, y_i)\}_{i=1}^n, \qquad x_i \in \mathbb{R}^d.$$

Определение

- если $\mathcal{Y} = \mathbb{R}$, рассматривается задача *регрессии*;
- если $\mathcal{Y} = \{1, \ldots, K\}$, рассматривается задача *классификации*.

Замечание

После перехода к признакам каждый объект соответствует точке в d-мерном пространстве, а обучение сводится к поиску зависимости между координатами этой точки и ответом y.

Модель как параметризованное семейство

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение

Параметрической моделью называется семейство отображений

$$\mathcal{F} = \{f_\theta : \mathcal{X} \to \mathcal{Y} \mid \theta \in \Theta\},$$

где Θ — пространство параметров, а θ — вектор параметров модели.

Если $\Theta \subseteq \mathbb{R}^m$, то

$$\theta = (\theta_1, \ldots, \theta_m)^T.$$

Пример. Для семейства прямых

$$f_{w,b}(x) = wx + b$$

пространство параметров равно $\Theta = \mathbb{R}^2$, а $\theta = (w, b)^T$.

Замечание

До обучения задано всё семейство $\mathcal{F}$; результат обучения — конкретная функция $f_{\hat{\theta}}$ с найденным набором параметров $\hat{\theta}$.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Функция потерь и эмпирический риск

Определение

Функцией потерь называется отображение

$$\ell : \mathcal{Y} \times \mathcal{Y} \to \mathbb{R}_{\geq 0},$$

где $\ell(y, \hat{y})$ измеряет ошибку одного предсказания $\hat{y}$ при истинном ответе y.

Определение

Эмпирическим риском модели f_θ на выборке D называется

$$L_D(\theta) = \frac{1}{n} \sum_{i=1}^{n} \ell\big(y_i, f_\theta(x_i)\big).$$

После фиксации выборки D величина L_D зависит только от параметров модели. Если $\Theta \subseteq \mathbb{R}^m$, то

$$\boxed{L_D : \mathbb{R}^m \to \mathbb{R}}$$

является функцией нескольких переменных.

Замечание

Именно эта функция связывает постановку задачи машинного обучения с задачей исследования и минимизации функций нескольких переменных.

Обучение модели

Определение

Обучением параметрической модели называется задача поиска параметров

$$\boxed{\hat{\theta} \in \arg\min_{\theta \in \Theta} L_D(\theta)}.$$

В развёрнутом виде:

$$\hat{\theta} \in \arg\min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^{n} \ell\big(y_i, f_\theta(x_i)\big).$$

Следствие

При $\Theta \subseteq \mathbb{R}^m$ задача обучения становится задачей оптимизации функции нескольких переменных $L_D(\theta)$.

Замечание

Разные алгоритмы машинного обучения отличаются выбором семейства $\mathcal{F}$, функции потерь ℓ и метода решения полученной задачи оптимизации.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Обучающая, валидационная и тестовая выборки

Для оценки способности модели работать на новых данных исходный набор объектов разделяют на непересекающиеся части:

$$D = D_{\text{train}} \sqcup D_{\text{validation}} \sqcup D_{\text{test}}.$$

- D_{train} используется для определения параметров $\hat{\theta}$;
- $D_{\text{validation}}$ — для выбора гиперпараметров и сравнения вариантов модели;
- D_{test} — для итоговой оценки качества после завершения обучения.

Определение

Ошибка на обучающей выборке:

$$L_{\text{train}}(\hat{\theta}).$$

Ошибка на тестовой выборке определяется той же функцией потерь, но на объектах, не участвовавших в подборе параметров.

Замечание

Малое значение L_{train} не гарантирует малого значения тестовой ошибки: модель должна не только описывать обучающие объекты, но и *обобщать* найденную зависимость.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 2
Линейные модели

Linear Regression (линейная регрессия)

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение

Линейной регрессионной моделью называется функция

$$f_\theta(x) = x^T\theta, \qquad x, \theta \in \mathbb{R}^d.$$

Свободный коэффициент можно включить в вектор параметров, добавив к признаковому вектору единичную координату.
Для одного признака получаем

$$\hat{y} = f_{w,b}(x) = wx + b.$$

Замечание

Слово «линейная» относится к зависимости от параметров.
Например,

$$\hat{y} = \theta_0 + \theta_1 x + \theta_2 x^2$$

остаётся линейной моделью по параметрам $\theta_0, \theta_1, \theta_2$.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Mean Squared Error (среднеквадратичная ошибка)

Для объекта (x_i, y_i) определим остаток

$$r_i = y_i - f_\theta(x_i).$$

Определение

Квадратичная функция потерь:

$$\ell(y, \hat{y}) = (y - \hat{y})^2.$$

Соответствующий эмпирический риск имеет вид

$$L(\theta) = \frac{1}{n} \sum_{i=1}^{n} \left(y_i - x_i^T \theta\right)^2.$$

Если строки матрицы $X \in \mathbb{R}^{n \times d}$ равны x_i^T, а $Y = (y_1, \ldots, y_n)^T$, то

$$\boxed{L(\theta) = \frac{1}{n} \| Y - X\theta \|_2^2}.$$

Замечание

Возведение остатка в квадрат исключает взаимную компенсацию положительных и отрицательных ошибок и сильнее штрафует большие отклонения.

MSE как функция нескольких переменных

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Для модели одного признака

$$f_{w,b}(x) = wx + b$$

функция потерь принимает вид

$$L(w, b) = \frac{1}{n}\sum_{i=1}^{n}(y_i - wx_i - b)^2.$$

Следовательно,

$$L : \mathbb{R}^2 \to \mathbb{R}.$$

Множества

$$\{(w, b) : L(w, b) = C\}$$

являются линиями уровня функции потерь.

Следствие Минимум поверхности соответствует параметрам наилучшей прямой в смысле MSE.

Градиент MSE

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Утверждение

Для

$$L(\theta) = \frac{1}{n}\|Y - X\theta\|_2^2$$

градиент по параметрам равен

$$\boxed{\nabla_\theta L(\theta) = \frac{2}{n}X^T(X\theta - Y)}.$$

В координатной форме

$$\nabla L(\theta) = \begin{pmatrix} \frac{\partial L}{\partial \theta_1} \\ \vdots \\ \frac{\partial L}{\partial \theta_d} \end{pmatrix}.$$

Замечание

Частная производная $\partial L/\partial \theta_j$ характеризует локальную чувствительность ошибки к изменению j-го параметра при фиксированных остальных. Градиент объединяет эти величины в один вектор.

Logistic Regression (логистическая регрессия)

Рассмотрим бинарную классификацию:

$$y \in \{0, 1\}.$$

Линейный score

$$z = x^T \theta$$

принимает произвольные вещественные значения и потому не может непосредственно интерпретироваться как вероятность.

Определение

В *Logistic Regression* вероятность класса 1 задаётся

$$p_\theta(x) = P_\theta(Y = 1 \mid x) = \sigma(x^T \theta),$$

где

$$\boxed{\sigma(z) = \frac{1}{1 + e^{-z}}}.$$

При стандартном пороге $1/2$

$$\hat{y} = \mathbb{I}\{p_\theta(x) \geq 1/2\}.$$

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Maximum Likelihood и Cross-Entropy

Пусть

$$p_i = p_\theta(x_i) = P_\theta(Y_i = 1 \mid x_i).$$

Тогда вероятность наблюдать ответ $y_i \in \{0, 1\}$ равна

$$p_i^{y_i}(1 - p_i)^{1-y_i}.$$

При условной независимости наблюдений функция правдоподобия:

$$\mathcal{L}(\theta) = \prod_{i=1}^{n} p_i^{y_i}(1 - p_i)^{1-y_i}.$$

Утверждение

Максимизация $\mathcal{L}(\theta)$ эквивалентна минимизации отрицательного среднего лог-правдоподобия:

$$\boxed{L(\theta) = -\frac{1}{n}\sum_{i=1}^{n} [y_i \log p_i + (1 - y_i)\log(1 - p_i)]}.$$

Определение Эта функция называется *binary cross-entropy* (бинарной кросс-энтропией).

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 3
Градиентные методы оптимизации

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Геометрический смысл градиента

Пусть

$$L : \mathbb{R}^d \to \mathbb{R}$$

дифференцируема в точке θ.

Утверждение

Производная L по единичному направлению v, $\|v\| = 1$, равна

$$D_v L(\theta) = \langle \nabla L(\theta), v \rangle.$$

Из неравенства Коши–Буняковского

$$-\|\nabla L(\theta)\| \leq D_v L(\theta) \leq \|\nabla L(\theta)\|.$$

Наибольшее локальное убывание достигается в направлении

$$\boxed{v = -\frac{\nabla L(\theta)}{\|\nabla L(\theta)\|}}.$$

Замечание Градиент ортогонален линии уровня в регулярной точке функции.

Gradient Descent (градиентный спуск)

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение

Gradient Descent задаётся последовательностью

$$\boxed{\theta_{t+1} = \theta_t - \eta_t \nabla L(\theta_t)},$$

где $\eta_t > 0$ — *learning rate* (скорость обучения).
На каждой итерации выполняются два шага:

1. вычисляется градиент $\nabla L(\theta_t)$;
2. параметры изменяются в направлении антиградиента.

Замечание

Метод использует только локальную информацию о функции L и не требует явного аналитического выражения точки минимума.

Следствие

При удачном выборе η_t последовательность $L(\theta_t)$ должна уменьшаться, а параметры θ_t — приближаться к стационарной точке.

Влияние learning rate

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Значение η определяет длину шага вдоль антиградиента.
Для одномерной функции

$$f(u) = u^2$$

итерация Gradient Descent принимает вид

$$u_{t+1} = u_t - 2\eta u_t = (1 - 2\eta)u_t.$$

Отсюда непосредственно видно, что характер последовательности зависит от η.

- малое η — устойчивое, но медленное уменьшение ошибки;
- умеренное η — быстрая сходимость;
- большое η — колебания около минимума;
- чрезмерно большое η — расходимость.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Momentum и Nesterov

Пусть $g_t = \nabla L(\theta_t)$.

Определение **Momentum (метод момента)**

$$v_t = \beta v_{t-1} + g_t, \qquad \theta_{t+1} = \theta_t - \eta v_t, \qquad 0 \leq \beta < 1.$$

Вектор v_t аккумулирует информацию о предыдущих направлениях движения. Это уменьшает поперечные колебания в вытянутых долинах функции потерь.

Определение **Nesterov Momentum (метод Нестерова)**

$$g_t = \nabla L(\theta_t - \eta\beta v_{t-1}),$$

$$v_t = \beta v_{t-1} + g_t, \qquad \theta_{t+1} = \theta_t - \eta v_t.$$

Замечание В методе Нестерова градиент вычисляется в точке, учитывающей предполагаемое движение по накопленному импульсу.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

AdaGrad и RMSProp

Пусть $g_t = \nabla L(\theta_t)$, а $\odot$ обозначает покоординатное умножение.

Определение **AdaGrad**

$$G_t = G_{t-1} + g_t \odot g_t,$$

$$\theta_{t+1} = \theta_t - \eta \frac{g_t}{\sqrt{G_t} + \varepsilon}.$$

Эффективный размер шага автоматически уменьшается по координатам, где накоплены большие значения градиента.

Определение **RMSProp**

$$s_t = \rho s_{t-1} + (1-\rho) g_t \odot g_t,$$

$$\theta_{t+1} = \theta_t - \eta \frac{g_t}{\sqrt{s_t} + \varepsilon}.$$

Замечание

В AdaGrad сумма квадратов градиентов монотонно растёт, поэтому шаг может стать слишком малым. RMSProp заменяет полное накопление экспоненциальным скользящим средним.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Adam

Определение

Adam использует экспоненциальные средние первого и второго моментов градиента:

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t,$$

$$v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t \odot g_t.$$

Для компенсации начальных значений $m_0 = v_0 = 0$ применяются поправки

$$\hat{m}_t = \frac{m_t}{1-\beta_1^t}, \qquad \hat{v}_t = \frac{v_t}{1-\beta_2^t}.$$

Итоговое обновление:

$$\boxed{\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}}.$$

Замечание

Первый момент задаёт сглаженное направление движения, второй — адаптивный масштаб шага по отдельным координатам.

Сравнение градиентных методов

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Для корректного сравнения оптимизаторы запускаются

- на одной функции потерь;
- из одной стартовой точки;
- при фиксированных гиперпараметрах каждого метода.

Сравниваются

GD, Momentum, Nesterov, AdaGrad, RMSProp, Adam.

Основные характеристики:

- траектория параметров на линиях уровня;
- скорость уменьшения $L(\theta_t)$;
- число итераций до заданной точности;
- устойчивость к различному масштабу координат.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 4
Решающие деревья и Gradient Boosting

Decision Tree (решающее дерево)

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение

Внутренняя вершина решающего дерева содержит предикат

$$x_j \leq t,$$

где j — номер признака, t — порог.
Для множества объектов S предикат определяет разбиение

$$S_L(j,t) = \{(x_i, y_i) \in S : x_{ij} \leq t\},$$

$$S_R(j,t) = \{(x_i, y_i) \in S : x_{ij} > t\}.$$

Внутренние вершины задают последовательность условий, а листья содержат итоговое предсказание модели.

Замечание

В отличие от линейных моделей, структура дерева сама является частью решения: необходимо выбрать признаки, пороги и глубину разбиений.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Критерий разбиения

Пусть $H(S)$ — мера неоднородности ответов объектов, попавших в вершину.

Определение

Качеством разбиения (j, t) назовём уменьшение неоднородности

$$Q(S, j, t) = H(S) - \frac{|S_L|}{|S|} H(S_L) - \frac{|S_R|}{|S|} H(S_R).$$

На каждом шаге выбирается

$$\boxed{(j^*, t^*) \in \arg\max_{j,t} Q(S, j, t)}.$$

Замечание

Это локальная задача оптимизации: алгоритм не ищет сразу оптимальное дерево целиком, а выбирает наилучшее разбиение в текущей вершине.

Следствие

Такое построение называется *жадным*: каждый шаг оптимален относительно текущей вершины, но не обязан давать глобально оптимальную структуру дерева.

Критерии для регрессии и классификации

Регрессия

В качестве неоднородности можно использовать дисперсию ответов в вершине:

$$H_{\mathrm{MSE}}(S) = \frac{1}{|S|} \sum_{(x_i, y_i) \in S} (y_i - \bar{y}_S)^2,$$

где

$$\bar{y}_S = \frac{1}{|S|} \sum_{(x_i, y_i) \in S} y_i.$$

Предсказанием листа обычно является $\bar{y}_S$.

Классификация

Критерий Джини:

$$G(S) = 1 - \sum_{k=1}^{K} p_k^2.$$

Энтропия:

$$H(S) = -\sum_{k=1}^{K} p_k \log p_k.$$

Здесь p_k — доля объектов класса k в вершине.

Замечание

Хороший split уменьшает неоднородность ответов в дочерних вершинах по сравнению с исходной вершиной.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Жадное построение дерева

Утверждение

Полный перебор всех возможных структур дерева практически неосуществим, поэтому дерево строится рекурсивно и жадно.

1. В текущую вершину приходит множество объектов S.
2. Перебираются допустимые признаки j и пороги t.
3. Для каждого кандидата вычисляется $Q(S, j, t)$.
4. Выбирается локально лучшее разбиение (j^*, t^*).
5. Процедура повторяется в дочерних вершинах.

Рост дерева ограничивают, например,

- максимальной глубиной;
- минимальным числом объектов в вершине;
- минимальным улучшением критерия.

Замечание

Параметры дерева включают дискретный выбор признака и структуры, поэтому производная по этим величинам в обычном смысле не определена. Gradient Descent непосредственно к построению дерева не применяется.

Random Forest и Gradient Boosting

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Random Forest (случайный лес)

Строится множество деревьев

$$h_1, \ldots, h_M,$$

после чего их ответы агрегируются усреднением или голосованием.

Для уменьшения корреляции между деревьями используются

- bootstrap-выборки объектов;
- случайные подмножества признаков при выборе split'a.

Gradient Boosting (градиентный бустинг)

Строится последовательность композиций

$$F_0 \to F_1 \to \cdots \to F_M.$$

Каждое следующее дерево зависит от уже построенного ансамбля и исправляет его текущую ошибку.

Замечание

Random Forest строит разнообразные деревья преимущественно независимо; Gradient Boosting строит деревья последовательно.

Gradient Boosting (градиентный бустинг)

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Пусть после $m-1$ шагов построена композиция F_{m-1}.

Определение

Следующая модель добавляется по правилу

$$\boxed{F_m(x) = F_{m-1}(x) + \eta h_m(x)},$$

где h_m — новое дерево, а $\eta > 0$ — шаг бустинга.

Для дифференцируемой функции потерь вводятся *псевдоостатки*

$$\boxed{r_i^{(m)} = -\left.\frac{\partial \ell(y_i, F(x_i))}{\partial F(x_i)}\right|_{F=F_{m-1}}}.$$

Новое дерево обучается приближать значения $r_i^{(m)}$ на обучающих объектах.

Замечание

Величина η играет роль шага: малое значение делает обновления более осторожными, но требует большего числа деревьев.

Gradient Boosting как спуск в пространстве функций

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Для квадратичной функции потерь

$$\ell(y, F) = (y - F)^2$$

имеем

$$-\frac{\partial \ell(y, F)}{\partial F} = 2(y - F).$$

Следовательно, отрицательный градиент пропорционален обычному остатку

$$y_i - F_{m-1}(x_i).$$

Следствие

При MSE очередное дерево обучается приближать ошибки текущего ансамбля.

Замечание

В Gradient Descent изменяется конечномерный вектор параметров θ; в Gradient Boosting последовательно изменяется функция F посредством добавления новых базовых моделей h_m.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 5
Дополнительные методы

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Principal Component Analysis (метод главных компонент)

Пусть строки матрицы X содержат центрированные объекты, а

$$C = \frac{1}{N} X^T X$$

— ковариационная матрица.

Для единичного направления w проекция объекта x равна $w^T x$, а дисперсия проекций определяется величиной $w^T C w$.

Определение

Первая главная компонента задаётся задачей

$$\boxed{\max_{\|w\|=1} w^T C w}.$$

Утверждение

Решением является собственный вектор матрицы C, соответствующий наибольшему собственному значению.

Замечание

PCA выбирает ортогональные направления максимальной дисперсии и позволяет оставить первые компоненты, отбросив направления с относительно малой вариативностью.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Monte Carlo (метод Монте-Карло)

Рассмотрим интеграл

$$I = \int_a^b f(x)\,dx.$$

Если $X \sim U(a, b)$, то

$$\mathbb{E}[f(X)] = \frac{1}{b-a}\int_a^b f(x)\,dx,$$

поэтому

$$I = (b-a)\mathbb{E}[f(X)].$$

Определение

Для независимых $X_1, \ldots, X_N \sim U(a, b)$ оценка Монте-Карло имеет вид

$$\boxed{\hat{I}_N = \frac{b-a}{N}\sum_{i=1}^{N} f(X_i)}.$$

Замечание

В основе метода лежит замена математического ожидания выборочным средним. При увеличении N оценка стабилизируется в соответствии с законом больших чисел.

Ant Colony Optimization (муравьиный алгоритм)

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Рассмотрим граф, в котором из вершины i допустимы переходы в вершины $j \in A_i$.

Определение

Вероятность перехода по ребру (i, j) задаётся

$$P_{ij} = \frac{\tau_{ij}^{\alpha} \eta_{ij}^{\beta}}{\sum\limits_{k \in A_i} \tau_{ik}^{\alpha} \eta_{ik}^{\beta}},$$

где τ_{ij} — накопленный феромон, η_{ij} — локальная привлекательность перехода, а α, β задают их относительное влияние.

После итерации феромон обновляется:

$$\boxed{\tau_{ij} \leftarrow (1 - \rho)\tau_{ij} + \Delta\tau_{ij}}.$$

Замечание

Испарение $(1 - \rho)\tau_{ij}$ препятствует бесконечному накоплению старой информации, а $\Delta\tau_{ij}$ усиливает рёбра, участвовавшие в более качественных решениях.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 6
Практическая часть

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Программная реализация

Практическая часть реализуется на языке Python.

- `NumPy` — матричные и векторные вычисления;
- `Matplotlib` — построение статических графиков;
- `Manim` — математические анимации;
- `scikit-learn` — дополнительная проверка полученных результатов.

Утверждение

Основные алгоритмы реализуются самостоятельно, чтобы контролировать

- вычисление градиентов и обновление параметров;
- выбор split'ов решающего дерева;
- построение последовательности деревьев в Gradient Boosting.

Для сравнения методов фиксируются исходные данные, стартовые точки и параметры эксперимента.

Замечание

Такой подход позволяет сопоставлять не только итоговые значения loss, но и сами траектории и промежуточные состояния алгоритмов.

`PLACEHOLDER: ссылка на репозиторий`

Эксперимент: Linear Regression

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Рассматривается синтетическая выборка одного признака и модель

$$\hat{y} = wx + b.$$

Функция потерь:

$$L(w, b) = \frac{1}{n} \sum_{i=1}^{n} (y_i - wx_i - b)^2.$$

В эксперименте фиксируются

- поверхность и линии уровня $L(w, b)$;
- начальная точка (w_0, b_0);
- последовательность параметров (w_t, b_t);
- изменение прямой $wx + b$ в процессе оптимизации.

Эксперимент: сравнение оптимизаторов

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

На одной двумерной функции из одной начальной точки запускаются

GD, Momentum, Nesterov, AdaGrad, RMSProp, Adam.

Для каждого метода сохраняются

- последовательность параметров θ_t;
- значения $L(\theta_t)$;
- число итераций;
- расстояние до известной точки минимума.

Замечание

Сравнение траекторий показывает геометрическое различие методов, а график $L(\theta_t)$ позволяет сравнить скорость уменьшения функции потерь.

Эксперимент: Decision Tree

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

На небольшом двумерном наборе данных вручную воспроизводятся первые шаги жадного построения дерева.
Для текущей вершины S вычисляются значения

$$Q(S, j, t)$$

для допустимых признаков и порогов, после чего выбирается

$$(j^*, t^*) \in \arg\max_{j,t} Q(S, j, t).$$

В эксперименте сохраняются

- кандидатные split'ы;
- значения критерия для каждого кандидата;
- выбранная граница;
- итоговая структура дерева.

Эксперимент: Gradient Boosting

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Строится последовательность композиций

$$F_0, F_1, \ldots, F_M, \qquad F_m = F_{m-1} + \eta h_m.$$

На каждом шаге сохраняются

- текущие предсказания $F_{m-1}(x_i)$;
- residuals или pseudo-residuals $r_i^{(m)}$;
- новое дерево h_m;
- значение общей функции потерь.

Утверждение

Основной наблюдаемый эффект — последовательное уменьшение ошибки ансамбля за счёт добавления моделей, приближающих антиградиент функции потерь.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Итоги

1. Обучение параметрической модели формулируется как задача
$$\hat{\theta} \in \arg\min_{\theta} L_D(\theta).$$
2. Для гладких функций потерь естественно возникают функции нескольких переменных, частные производные, градиент, линии уровня и численные методы поиска минимума.
3. Linear Regression и Logistic Regression различаются видом модели и функции потерь, но сохраняют общую постановку оптимизации.
4. Decision Tree использует дискретное жадное построение структуры, тогда как Gradient Boosting возвращает идею антиградиента на уровне последовательного построения функции.
5. PCA, Monte Carlo и Ant Colony Optimization иллюстрируют использование линейной алгебры, вероятностных методов и метаэвристической оптимизации.

Следствие

Математический анализ возникает в машинном обучении не как отдельный набор формул, а как естественный язык постановки и решения задач обучения.

Основные источники

- Школа анализа данных Яндекса. *Учебник по машинному обучению*.
- Броиловский А. *Обзор задач машинного обучения*. ШАД СПб, 2026.
- Овчаров С. *Линейная регрессия и основы оптимизации*. ШАД СПб, 2026.
- Овчаров С. *Логистическая регрессия и классификация*. ШАД СПб, 2026.
- Zhang A., Lipton Z. C., Li M., Smola A. J. *Dive into Deep Learning: Optimization Algorithms*.
- Материалы проекта *«Математический анализ в методах машинного обучения»*.

Замечание

В презентации используются собственные вычислительные эксперименты и визуализации, построенные по результатам программной реализации рассматриваемых методов.