Математический анализ в методах машинного обучения

Вейгандт В., Зайцев Н., Горобец О., Козлов В., Шагеев Э.

2026

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 1
Постановка задачи машинного обучения

Обучение с учителем: постановка задачи

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение

Пусть (X, Y) — случайная пара с неизвестным совместным распределением $P_{\mathsf{X},Y}$, где $\mathsf{X} \in \mathcal{X}$ — объект, а $Y \in \mathcal{Y}$ — его ответ.

Определение

Обучающей выборкой называется набор реализаций

$$D_n = \{(x_i, y_i)\}_{i=1}^{n}, \qquad (\mathsf{X}_i, Y_i) \overset{\text{iid}}{\sim} P_{\mathsf{X},Y}.$$

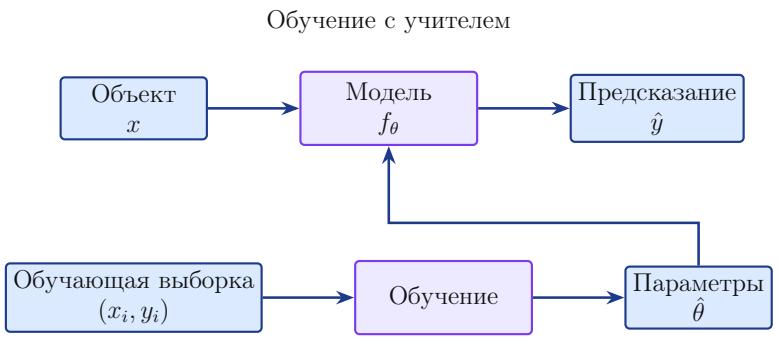
Здесь (X_i, Y_i) — независимые одинаково распределённые случайные пары, а (x_i, y_i) — наблюдаемые значения.

Задача

По выборке D_n построить функцию

$$f : \mathcal{X} \to \widehat{\mathcal{Y}},$$

для прогнозирования новых объектов из того же распределения. Здесь $\widehat{\mathcal{Y}}$ — пространство прогнозов (в частности, вероятностей классов).



Признаки и матричное представление выборки

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение
Числовым *признаковым описанием* i-го объекта называется вектор

$$x_i = (x_{i1}, \ldots, x_{id})^T \in \mathbb{R}^d,$$

где x_{ij} — значение j-го признака у i-го объекта.
Выборку удобно записывать в виде матрицы объектов–признаков

$$X = \begin{pmatrix} x_1^T \\ \vdots \\ x_n^T \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1d} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{nd} \end{pmatrix} \in \mathbb{R}^{n \times d}, \qquad y = (y_1, \ldots, y_n)^T.$$

Определение

- $\mathcal{Y} = \mathbb{R}$ — *regression* (регрессия);
- $\mathcal{Y} = \{1, \ldots, K\}$ — *classification* (классификация).

Пример Цена квартиры — регрессия; определение класса изображения — классификация.

Модель и алгоритм обучения

Определение

Параметрической моделью называется семейство функций

$$\mathcal{F} = \{f_\theta : \mathcal{X} \to \widehat{\mathcal{Y}} \mid \theta \in \Theta\},$$

где Θ — пространство параметров модели.
Для объекта x_i модель выдаёт предсказание

$$\hat{y}_i = f_\theta(x_i).$$

Пример

Семейство прямых

$$f_{w,b}(x) = wx + b, \qquad \theta = (w, b)^T \in \mathbb{R}^2,$$

содержит бесконечно много моделей; обучение должно выбрать одну из них.

Определение

Алгоритм обучения — правило, которое по выборке D_n выбирает параметры $\hat{\theta} = A(D_n)$, а значит, конкретную функцию $f_{\hat{\theta}}$.

Замечание

Модель и алгоритм обучения — разные объекты: $\mathcal{F}$ задаёт, *что* можно получить, алгоритм — *как* это найти. Формально $A : (\mathcal{X} \times \mathcal{Y})^n \to \Theta$ — отображение данных в параметры: $D_n \mapsto \hat{\theta}$.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Функция потерь и истинный риск

Определение

Функцией потерь называется отображение

$$\ell : \mathcal{Y} \times \widehat{\mathcal{Y}} \to \mathbb{R}_{\geq 0},$$

где y — истинный ответ, $\hat{y}$ — прогноз (например, число или вероятность).

Пример

Для регрессии часто используется квадратичная потеря

$$\ell(y, \hat{y}) = (y - \hat{y})^2.$$

Для классификации простейший вариант — индикатор ошибки

$$\ell(y, \hat{y}) = \mathbf{1}\{y \neq \hat{y}\}.$$

Определение

Истинным риском модели называется ожидаемая ошибка на новом объекте:

$$\boxed{R(\theta) = \mathbb{E}_{(\mathsf{X}, Y) \sim P_{\mathbf{X}, Y}} \left[\ell(Y, f_\theta(\mathsf{X}))\right]}.$$

Задача Идеальная цель обучения — найти параметры с малым $R(\theta)$.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Эмпирический риск и принцип ERM

Распределение $P_{X,Y}$ неизвестно, поэтому истинный риск $R(\theta)$ непосредственно вычислить нельзя.

Определение

Эмпирическим риском называется средняя ошибка на наблюдаемой выборке:

$$\boxed{\widehat{R}_n(\theta) = \frac{1}{n}\sum_{i=1}^{n} \ell\big(y_i, f_\theta(x_i)\big)}.$$

При фиксированном θ и стандартных условиях закон больших чисел даёт

$$\widehat{R}_n(\theta) \longrightarrow R(\theta), \qquad n \to \infty.$$

Определение

Empirical Risk Minimization (минимизация эмпирического риска):

$$\boxed{\hat{\theta} \in \arg\min_{\theta\in\Theta} \widehat{R}_n(\theta)}.$$

Если $\Theta \subseteq \mathbb{R}^m$, то $\widehat{R}_n : \Theta \to \mathbb{R}$ — функция нескольких переменных.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Обобщающая способность и переобучение

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение

Generalization (обобщающая способность) — способность модели, обученной на D_{train}, сохранять качество на новых объектах из того же распределения.

Практически сравнивают ошибку на обучающей и независимой выборках:

$$\widehat{R}_{\text{train}}(\hat{\theta}), \qquad \widehat{R}_{\text{test}}(\hat{\theta}).$$

Определение

Overfitting (переобучение) обычно проявляется как ситуация, когда

$$\widehat{R}_{\text{train}}(\hat{\theta}) \ll \widehat{R}_{\text{test}}(\hat{\theta}).$$

Underfitting (недообучение) — ситуация, когда обе ошибки остаются большими.

Замечание

Минимизация train loss — средство, а не конечная цель: требуется малый истинный риск $R(\hat{\theta})$. Разность $\widehat{R}_{\text{test}}(\hat{\theta}) - \widehat{R}_{\text{train}}(\hat{\theta})$ называют *разрывом обобщения*; большой положительный разрыв сигнализирует о проблеме.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Train, Validation и Test

Для независимого контроля качества данные разделяют:

$$D = D_{\text{train}} \sqcup D_{\text{validation}} \sqcup D_{\text{test}}.$$

- D_{train} — поиск параметров модели $\hat{\theta}$;
- $D_{\text{validation}}$ — выбор гиперпараметров (настроек, не входящих в θ), архитектуры и варианта модели;
- D_{test} — итоговая оценка качества после завершения выбора.

Замечание

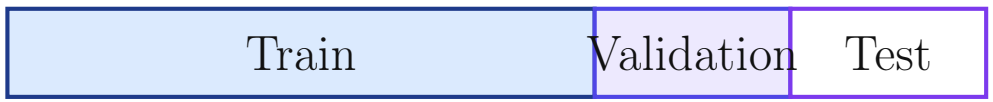
Test-выборка не должна использоваться при подборе модели: иначе она перестаёт быть независимой оценкой качества.

Задача

В следующих главах обозначим $L(\theta) = \widehat{R}_{\text{train}}(\theta)$. Общий цикл:

$$D_{\text{train}} \to \mathcal{F} \to \ell \to \min L(\theta) \to \text{validation} \to \text{test}.$$

Разбиение выборки



Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 2
Линейные модели

Linear Regression: определение модели

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Задача По $x \in \mathbb{R}^d$ предсказать число $y \in \mathbb{R}$.
Определение *Линейная регрессия* (Linear Regression):

$$f_{w,b}(x) = w^T x + b = \sum_{j=1}^{d} w_j x_j + b, \qquad w \in \mathbb{R}^d, \quad b \in \mathbb{R}.$$

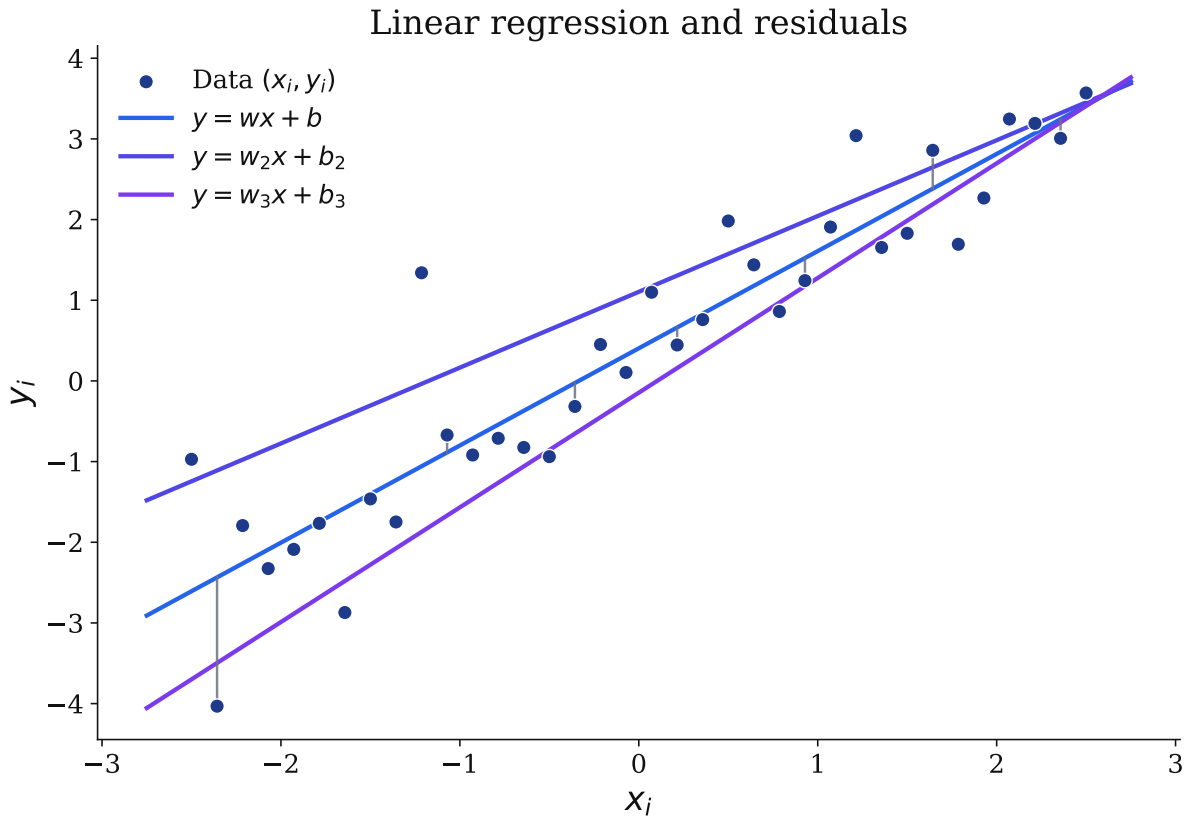
Здесь w_j — коэффициенты признаков, b — свободный член.
Определение Для единой записи вводят *фиктивный признак* $x_0 = 1$:

$$\widetilde{x} = (1, x_1, \ldots, x_d)^T, \qquad \theta = (b, w_1, \ldots, w_d)^T, \qquad f_\theta(\widetilde{x}) = \widetilde{x}^T \theta.$$

Итак, $\widetilde{x}, \theta \in \mathbb{R}^{d+1}$. Для выборки обозначим через $\widetilde{X}$ матрицу строк $\widetilde{x}_i^T$.
Пример При $d = 1$ получаем прямую $\hat{y} = wx + b$; например, $w = 2$, $b = 1$ дают $f(3) = 2 \cdot 3 + 1 = 7$.
Замечание Линейность здесь означает линейность *по параметрам*: $\theta_0 + \theta_1 x + \theta_2 x^2$ также линейна по θ.

Геометрия линейной регрессии: данные и остатки

Каждая точка (x_i, y_i) — наблюдение; линия — прогноз $\hat{y}_i = wx_i + b$. При изменении w, b меняются прогнозы и ошибки.



Замечание Вертикальное отклонение точки от прямой — остаток $r_i = y_i - \hat{y}_i$; минимизировать будем *сумму квадратов* таких отклонений.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Остатки и Mean Squared Error

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Остаток* (residual) на i-м объекте:

$$r_i = y_i - \hat{y}_i = y_i - f_\theta(\widetilde{x}_i).$$

Определение Квадратичная потеря и её среднее по выборке:

$$\ell(y_i, \hat{y}_i) = (y_i - \hat{y}_i)^2, \qquad \boxed{L(\theta) = \mathrm{MSE}(\theta) = \frac{1}{n}\sum_{i=1}^{n} r_i^2}.$$

Пример Пусть $x = (0, 1, 2)$, $y = (1, 2, 2)$, а $f(x) = x + 1$. Тогда

$$\hat{y} = (1, 2, 3), \quad r = (0, 0, -1), \quad L = \frac{0^2 + 0^2 + (-1)^2}{3} = \frac{1}{3}.$$

Замечание Возведение в квадрат убирает знак ошибок и сильнее штрафует большие отклонения: $|r| = 2$ даёт потерю 4, а $|r| = 1$ — 1.

Задача Найти $\hat{\theta} \in \arg\min_\theta L(\theta)$.

Матричная запись MSE

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Расширенная матрица $\widetilde{X}$ содержит единичный первый столбец и d исходных признаков:

$$\widetilde{X} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1d} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n1} & \cdots & x_{nd} \end{pmatrix} \in \mathbb{R}^{n\times(d+1)}, \quad \theta \in \mathbb{R}^{d+1}.$$

Поэтому вектор всех предсказаний и остатков имеет вид

$$\hat{y} = \widetilde{X}\theta \in \mathbb{R}^n, \qquad r = y - \widetilde{X}\theta \in \mathbb{R}^n.$$

Утверждение Поскольку $\|r\|_2^2 = r^T r = \sum_i r_i^2$,

$$\boxed{L(\theta) = \frac{1}{n}\|y - \widetilde{X}\theta\|_2^2 = \frac{1}{n}(y - \widetilde{X}\theta)^T(y - \widetilde{X}\theta)}.$$

Следствие Это функция от $(d+1)$ переменной, а не от объектов выборки: при обучении меняется θ, тогда как X и y зафиксированы.

MSE как функция нескольких переменных

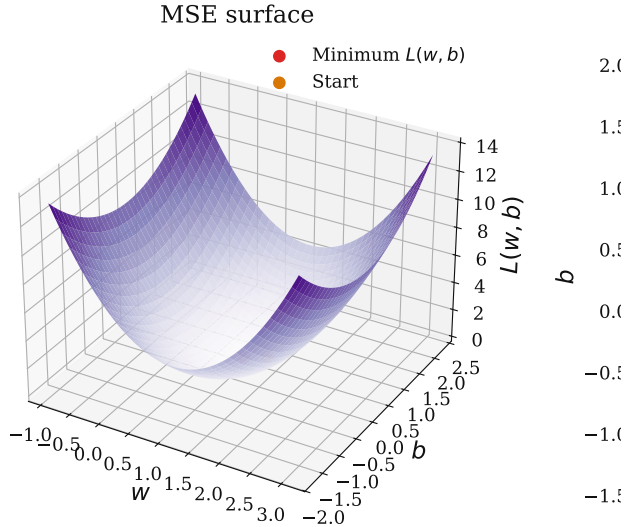
Для единственного признака $\theta = (b, w)$ и

$$L(w, b) = \frac{1}{n} \sum_{i=1}^{n} (y_i - wx_i - b)^2, \qquad L : \mathbb{R}^2 \to \mathbb{R}.$$

При каждом (w, b) выбирается своя прямая и вычисляется её ошибка.

Утверждение $L(w, b)$ — квадратичная функция по двум параметрам; её график — поверхность в пространстве (w, b, L).

Замечание Точки минимума соответствуют параметрам прямой, наилучшей по MSE. Как найти их численно, разберём в главе 3.



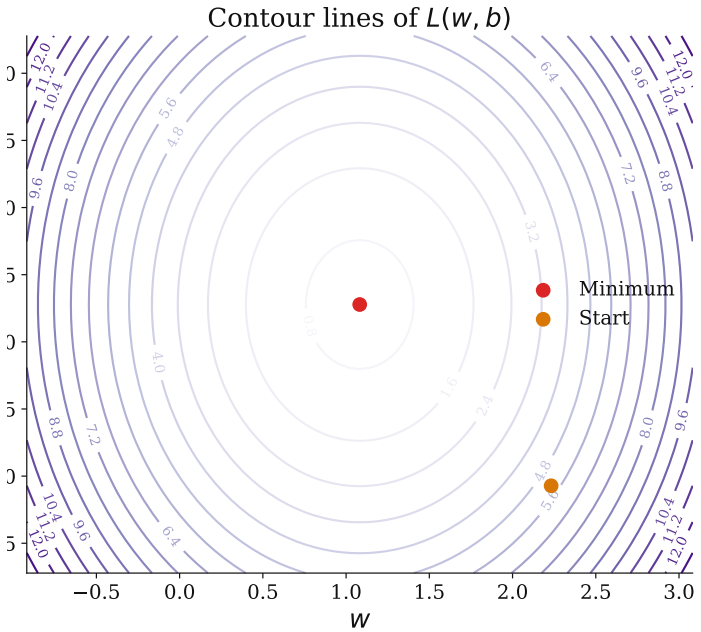
Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Линии уровня MSE: геометрический смысл

Определение *Линия уровня* функции $L(w, b)$ при $c \in \mathbb{R}$:

$$\mathcal{C}_c = \{(w, b) : L(w, b) = c\}.$$

Чем ближе линия уровня к минимуму, тем меньшей сумме квадратов остатков соответствуют параметры.



Замечание В точках, где $\nabla L \neq 0$, градиент перпендикулярен линии уровня: при движении вдоль неё значение L локально не меняется.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Как дифференцировать MSE: случай $d = 1$

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Для $f_{w,b}(x) = wx + b$ положим $e_i = wx_i + b - y_i$. Тогда $L(w, b) = \frac{1}{n}\sum_i e_i^2$.
По *правилу цепочки*, поскольку $\partial e_i/\partial w = x_i$, а $\partial e_i/\partial b = 1$,

$$\frac{\partial e_i^2}{\partial w} = 2e_i x_i, \qquad \frac{\partial e_i^2}{\partial b} = 2e_i.$$

Утверждение Частные производные функции потерь:

$$\boxed{\frac{\partial L}{\partial w} = \frac{2}{n}\sum_{i=1}^{n}(wx_i + b - y_i)x_i},$$

$$\boxed{\frac{\partial L}{\partial b} = \frac{2}{n}\sum_{i=1}^{n}(wx_i + b - y_i)}.$$

Замечание Градиент $\nabla L = (\partial L/\partial b, \partial L/\partial w)^T$ показывает, как ошибка меняется при малом изменении каждого параметра.

Градиент MSE в общем случае

Запишем $e_i = \widetilde{x}_i^T\theta - y_i$; тогда

$$L(\theta) = \frac{1}{n}\sum_{i=1}^{n} e_i^2, \qquad \frac{\partial e_i}{\partial \theta_j} = \widetilde{x}_{ij}, \quad j = 0, \ldots, d.$$

Снова применяем правило цепочки:

$$\frac{\partial L}{\partial \theta_j} = \frac{1}{n}\sum_i 2e_i\frac{\partial e_i}{\partial \theta_j} = \frac{2}{n}\sum_i \widetilde{x}_{ij}(\widetilde{x}_i^T\theta - y_i).$$

Здесь $\widetilde{X}^T(\widetilde{X}\theta - y)$ — вектор, j-я компонента которого равна сумме в правой части без множителя $2/n$.

Утверждение Собирая частные производные, получаем

$$\boxed{\nabla_\theta L(\theta) = \frac{2}{n}\widetilde{X}^T(\widetilde{X}\theta - y)} \quad \in \mathbb{R}^{d+1}.$$

Следствие Минимум гладкой функции (во внутренней точке) может достигаться только при $\nabla_\theta L = 0$.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Logistic Regression: зачем нужна сигмоида

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Задача Предсказать класс $Y \in \{0, 1\}$ и вероятность $p_\theta(x) = P_\theta(Y = 1 \mid X = x)$.

Определение Сначала вычисляется *линейный score*

$$z = w^T x + b = \widetilde{x}^T \theta \in \mathbb{R}.$$

Но z не обязан принадлежать $[0, 1]$, поэтому сам по себе не может быть вероятностью.

Определение *Odds* (шансы) события при вероятности p равны $p/(1-p)$. *Log-odds* — их логарифм:

$$\operatorname{logit}(p) = \log \frac{p}{1-p}.$$

Утверждение В *логистической регрессии* принимают модель

$$\boxed{\operatorname{logit}(p_\theta(x)) = w^T x + b = z}.$$

Пример При $p = 3/4$ шансы равны 3, а log-odds $= \log 3$.

Вывод сигмоиды из log-odds

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Предположим, что $\log \frac{p}{1-p} = z$. Выразим p:

$$\log \frac{p}{1-p} = z \quad \Longrightarrow \quad \frac{p}{1-p} = e^z,$$

$$p = e^z(1-p) \quad \Longrightarrow \quad p(1+e^z) = e^z,$$

$$\boxed{p = \frac{e^z}{1+e^z} = \frac{1}{1+e^{-z}} = \sigma(z)}.$$

Определение $\sigma : \mathbb{R} \to (0,1)$ — *sigmoid* (логистическая функция).
Утверждение $\sigma(0) = 1/2$, $\lim_{z\to-\infty} \sigma(z) = 0$, $\lim_{z\to+\infty} \sigma(z) = 1$.
По правилу цепочки

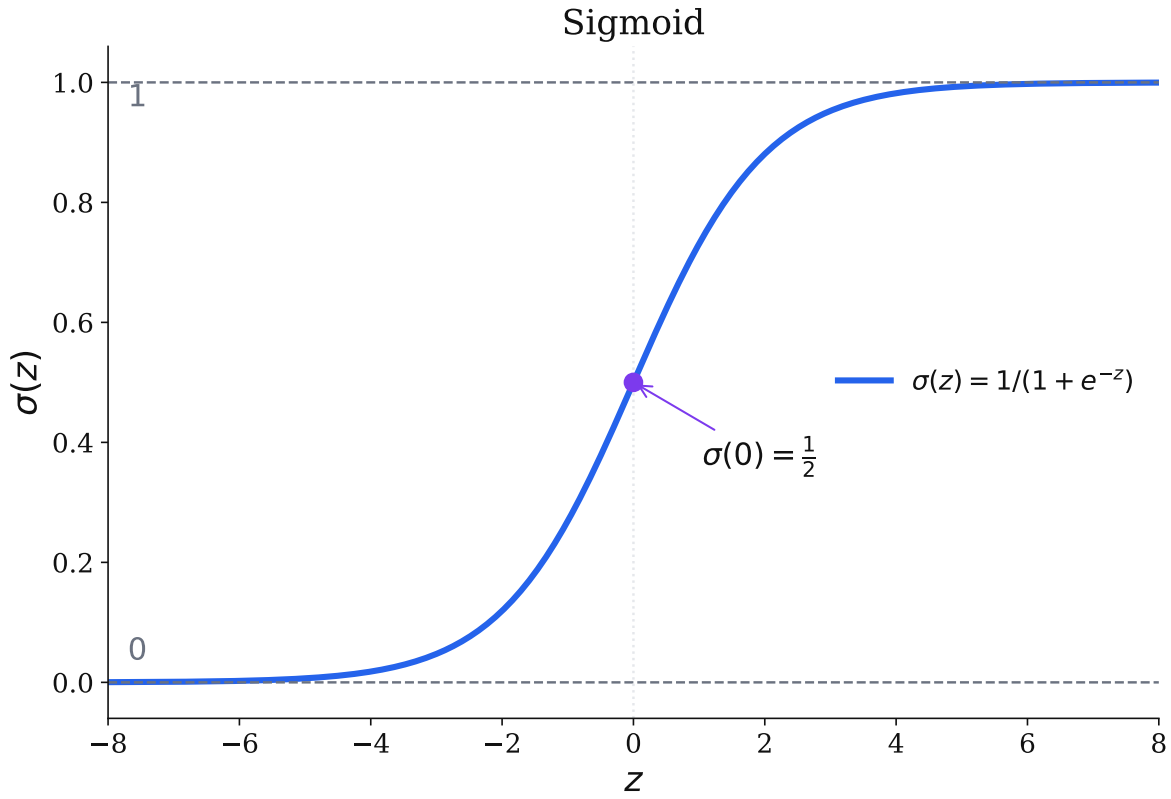
$$\boxed{\sigma'(z) = \frac{e^{-z}}{(1+e^{-z})^2} = \sigma(z)\big(1-\sigma(z)\big) > 0}.$$

Поэтому вероятность класса 1 растёт вместе со score z.

График сигмоиды

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Утверждение Линейный score z переводится в вероятность $p = \sigma(z)$; центральная точка графика имеет координаты $(0, 1/2)$.



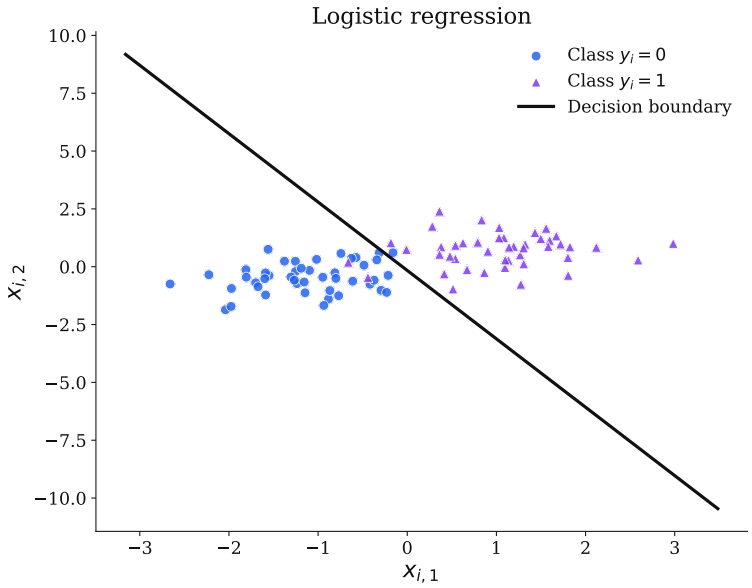
Пример Если $z = \log 3$, то $p = 3/4$; если $z = -\log 3$, то $p = 1/4$.

Геометрия логистической классификации

При пороге $1/2$ и монотонности σ:

$$\widehat{y} = 1 \iff p_\theta(x) \geq \tfrac{1}{2} \iff w^T x + b \geq 0.$$

Определение Граница решения: $\{x : w^T x + b = 0\}$ — гиперплоскость (если $w \neq 0$).



Замечание На графике показана линейная граница, хотя сама вероятность $p_\theta(x) = \sigma(w^T x + b)$ нелинейна по x. Например, для $w = (1, -1)^T$, $b = 0$ граница имеет вид $x_1 = x_2$.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Модель Бернулли и функция правдоподобия

Для объекта x_i обозначим $p_i = \sigma(\widetilde{x}_i^T \theta)$.

Определение При фиксированном x_i модель задаёт

$$Y_i \mid X_i = x_i \sim \text{Bern}(p_i), \qquad P_\theta(Y_i = y_i \mid x_i) = p_i^{y_i}(1 - p_i)^{1-y_i}.$$

Действительно, если $y_i = 1$, получаем p_i; если $y_i = 0$, получаем $1 - p_i$.

При условной независимости ответов *likelihood* (правдоподобие) всей наблюдаемой выборки равно

$$\boxed{\mathcal{L}(\theta) = \prod_{i=1}^{n} p_i^{y_i}(1 - p_i)^{1-y_i}}.$$

Задача *Maximum Likelihood Estimation* (MLE):

$$\hat{\theta} \in \arg\max_{\theta} \mathcal{L}(\theta).$$

Замечание $\mathcal{L}(\theta)$ рассматривается как функция параметров: ответы y_i уже известны, изменяются только p_i.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вывод Binary Cross-Entropy из MLE

Логарифм строго возрастает, поэтому максимумы $\mathcal{L}$ и $\log \mathcal{L}$ достигаются при тех же параметрах.
Применяем $\log(ab) = \log a + \log b$ и $\log(a^c) = c \log a$:

$$\log \mathcal{L}(\theta) = \sum_{i=1}^{n} \Big(y_i \log p_i + (1 - y_i) \log(1 - p_i) \Big).$$

Чтобы получить *задачу минимизации*, меняем знак и делим на n (положительный множитель не меняет оптимум):

$$\boxed{L(\theta) = -\frac{1}{n} \sum_{i=1}^{n} \Big[y_i \log p_i + (1 - y_i) \log(1 - p_i) \Big]}.$$

Определение L — *Binary Cross-Entropy* (BCE), или средняя отрицательная логарифмическая вероятность правильного ответа.
Пример Для одного наблюдения с $y = 1$ потеря равна $-\log p$: прогноз $p = 0.9$ даёт примерно 0.105, а $p = 0.1$ — примерно 2.303. Уверенная ошибка наказывается сильнее.
Следствие $\arg\max_\theta \mathcal{L}(\theta) = \arg\min_\theta L(\theta)$.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Градиент BCE: правило цепочки

Для одного объекта положим $z_i = \widetilde{x}_i^T\theta$, $p_i = \sigma(z_i)$ и

$$\ell_i = -y_i \log p_i - (1 - y_i)\log(1 - p_i).$$

Последовательно дифференцируем:

$$\frac{\partial \ell_i}{\partial p_i} = -\frac{y_i}{p_i} + \frac{1 - y_i}{1 - p_i} = \frac{p_i - y_i}{p_i(1 - p_i)},$$

$$\frac{\partial p_i}{\partial z_i} = p_i(1 - p_i), \qquad \boxed{\frac{\partial \ell_i}{\partial z_i} = p_i - y_i}.$$

Ещё один шаг по правилу цепочки:

$$\frac{\partial z_i}{\partial \theta_j} = \widetilde{x}_{ij} \quad \Longrightarrow \quad \frac{\partial \ell_i}{\partial \theta_j} = (p_i - y_i)\widetilde{x}_{ij}.$$

Утверждение Для всей выборки

$$\boxed{\nabla_\theta L(\theta) = \frac{1}{n}\widetilde{X}^T(p - y)}, \qquad p = (p_1, \ldots, p_n)^T.$$

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 3
Градиентные методы оптимизации

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Зачем нужна численная оптимизация

В предыдущей главе обучение свелось к поиску минимума эмпирического риска:

$$\boxed{\hat{\theta} \in \arg\min_{\theta \in \Theta} L(\theta)}, \qquad L : \mathbb{R}^m \to \mathbb{R}.$$

Пример Для рассмотренных линейных моделей

$$L_{\text{MSE}}(\theta) = \frac{1}{n}\|\widetilde{X}\theta - y\|_2^2,$$

$$L_{\text{BCE}}(\theta) = -\frac{1}{n}\sum_{i=1}^{n}\big[y_i \log p_i + (1 - y_i)\log(1 - p_i)\big].$$

Для MSE функция потерь квадратичная; для BCE общего явного решения нет.

Задача Построить последовательность $\theta_0, \theta_1, \ldots$, вдоль которой значение функции потерь становится меньше.

Идея Если известны частные производные L, можно использовать локальную информацию о её изменении, не решая уравнение минимума явно. Следующий шаг — выбрать направление, в котором линейное приближение L убывает быстрее всего.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Почему именно антиградиент?

Пусть $L : \mathbb{R}^m \to \mathbb{R}$ дифференцируема, а ∇L — вектор её частных производных.

Определение *Производная по направлению* единичного вектора v, $\|v\| = 1$, задаётся равенством

$$D_v L(\theta) = \langle \nabla L(\theta), v \rangle.$$

По неравенству Коши–Буняковского

$$-\|\nabla L(\theta)\| \le D_v L(\theta) \le \|\nabla L(\theta)\|.$$

Утверждение При $\nabla L(\theta) \neq 0$ наибольшее *локальное* убывание среди единичных направлений достигается при

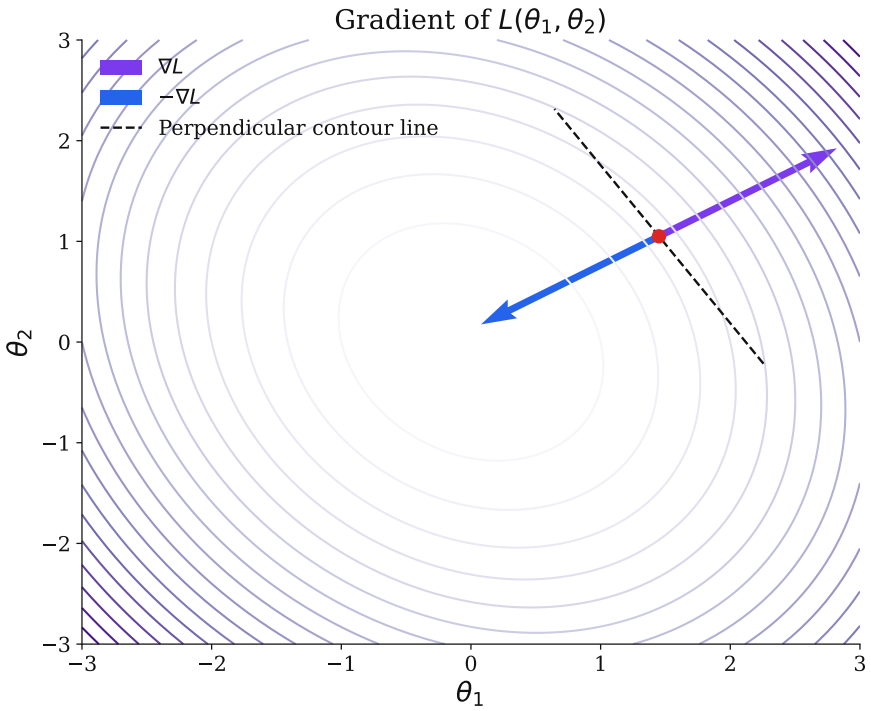
$$\boxed{v_{\min} = -\frac{\nabla L(\theta)}{\|\nabla L(\theta)\|}}.$$

Замечание При $\Delta\theta = -\eta \nabla L(\theta)$ линейное приближение даёт изменение $-\eta\|\nabla L(\theta)\|^2 < 0$ при $\nabla L \neq 0$. Реальный конечный шаг может вести себя иначе: вывод локальный.

Геометрия градиента и линий уровня

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

На карте линий уровня $L(\theta) = c$ градиент в регулярной точке перпендикулярен линии уровня и направлен в сторону возрастания L. Антиградиент показывает направление наиболее быстрого *локального* убывания.



Замечание Изображена геометрия одного шага; траектория метода складывается из многих таких шагов.

Gradient Descent: формула и алгоритм

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Gradient Descent (градиентный спуск)* — итерационный метод, в котором

$$\boxed{\theta_{t+1} = \theta_t - \eta_t \nabla L(\theta_t)}, \qquad \eta_t > 0.$$

Здесь $\theta_t \in \mathbb{R}^m$ — текущие параметры, η_t — *learning rate* (размер шага обучения).

Алгоритм

1. Задать начальное приближение θ_0 и правило выбора η_t.
2. Вычислить $g_t = \nabla L(\theta_t)$.
3. Обновить параметры: $\theta_{t+1} = \theta_t - \eta_t g_t$.
4. Повторять до выполнения критерия остановки.

Замечание Возможные критерии: малость $\|g_t\|$, изменение $L(\theta_t)$ или ограничение числа итераций. Ненулевой шаг сам по себе не гарантирует уменьшения функции.

Пример: несколько итераций вручную

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Пример Минимизируем $L(u) = (u-2)^2$ из точки $u_0 = 0$ при постоянном шаге $\eta = \frac{1}{4}$.

$$L'(u) = 2(u-2), \qquad u_{t+1} = u_t - \tfrac{1}{4}\,2(u_t - 2) = \tfrac{1}{2}u_t + 1.$$

t	u_t	$L'(u_t)$	$L(u_t)$
0	0	-4	4
1	1	-2	1
2	$\frac{3}{2}$	-1	$\frac{1}{4}$
3	$\frac{7}{4}$	$-\frac{1}{2}$	$\frac{1}{16}$

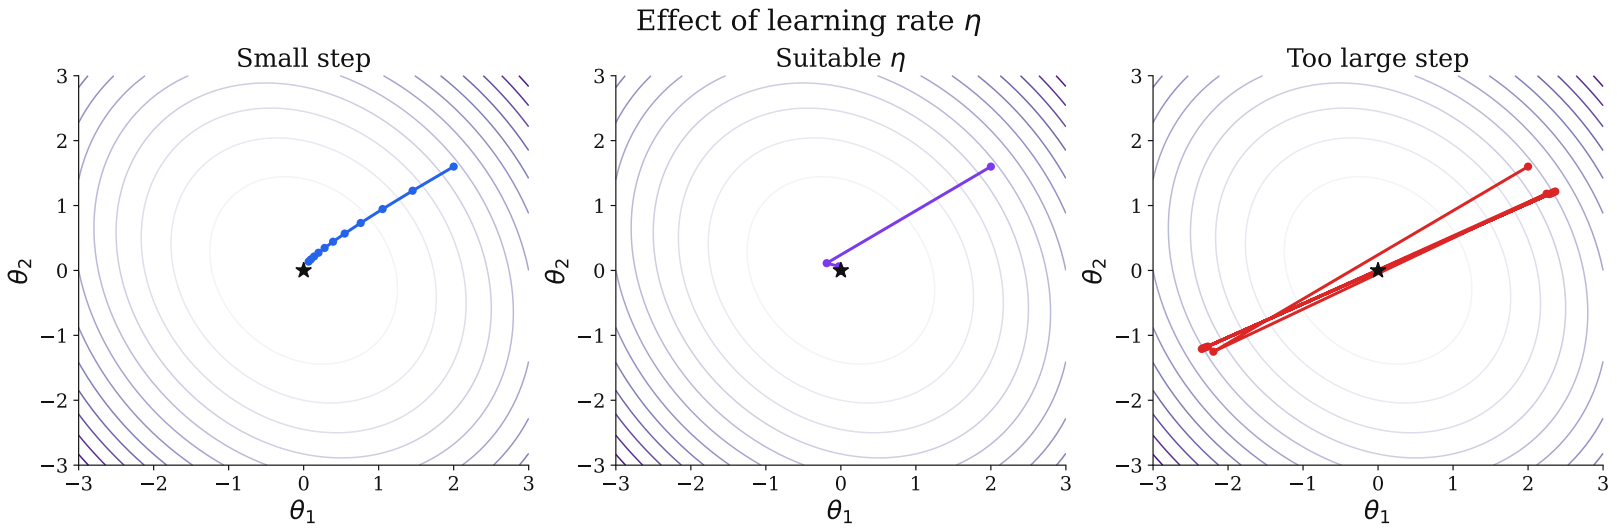
Следствие Каждый шаг сокращает расстояние до $u^* = 2$ вдвое; ошибка по функции уменьшается вчетверо.

$$u_t = 2 - 2\left(\tfrac{1}{2}\right)^t, \qquad L(u_t) = 4\left(\tfrac{1}{4}\right)^t \to 0.$$

Влияние learning rate: иллюстрация

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Слишком малый шаг замедляет движение, слишком большой может приводить к перескакиванию через минимум и расходимости.



Замечание На схеме показаны возможные режимы траекторий; поведение зависит также от геометрии конкретной функции потерь.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Полный и стохастический градиенты

Эмпирический риск является средним по выборке:

$$L(\theta) = \frac{1}{n}\sum_{i=1}^{n} \ell_i(\theta), \qquad \ell_i(\theta) = \ell(y_i, f_\theta(x_i)).$$

Определение При *Batch Gradient Descent* используется градиент всей суммы:

$$g_t = \nabla L(\theta_t) = \frac{1}{n}\sum_{i=1}^{n} \nabla \ell_i(\theta_t).$$

Определение В *Mini-batch SGD* вычисляют приближение по случайной подвыборке индексов B_t:

$$\boxed{g_t = \frac{1}{|B_t|}\sum_{i\in B_t} \nabla \ell_i(\theta_t)}, \qquad \theta_{t+1} = \theta_t - \eta_t g_t.$$

При равномерном выборе индексов такое среднее в среднем направлено как полный градиент.

Замечание Mini-batch дешевле одной полной итерации, но даёт шумное направление. Далее g_t — вычисленный на шаге градиент (полный или по mini-batch).

Momentum: зачем учитывать предыдущие шаги?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вытянутые линии уровня означают разные масштабы изменения функции по разным направлениям. Обычный GD может сильно колебаться поперёк узкой долины и медленно идти вдоль неё.

Идея Сохранять накопленное направление движения, сглаживая изменения градиента между итерациями.

Определение *Momentum (метод момента)*:

$$v_{t+1} = \beta v_t + g_t, \qquad v_0 = 0,$$
$$\theta_{t+1} = \theta_t - \eta v_{t+1}, \qquad 0 \le \beta < 1.$$

Здесь v_t — накопленное направление, β — коэффициент сохранения предыдущего направления.

Замечание Если $\beta = 0$, получаем обычный GD. При близких направлениях градиентов они накапливаются; при чередовании знаков в одной координате — частично компенсируются.

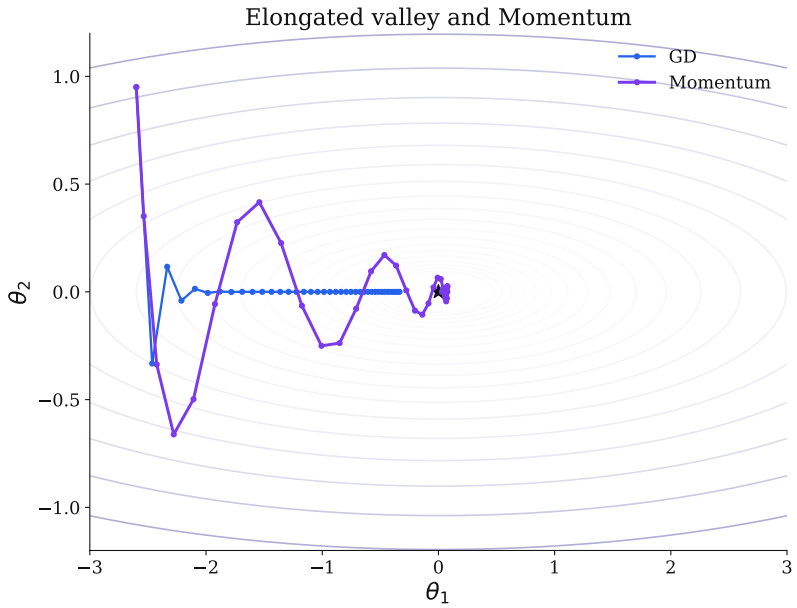
Momentum: геометрия узкой долины

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Пример Для $L(u, v) = 10u^2 + v^2$ имеем

$$\nabla L(u, v) = (20u, 2v)^T.$$

Изменение вдоль координаты u намного резче; обычный GD с заметным шагом может многократно пересекать долину поперёк.



Следствие Momentum накапливает устойчивое направление вдоль долины и частично гасит чередующиеся поперечные шаги.

Nesterov Momentum: шаг с опережением

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Идея Обычный Momentum вычисляет градиент в θ_t, а затем делает инерционный шаг. Метод Нестерова сначала учитывает предполагаемое перемещение по инерции.

Определение *Nesterov Momentum (метод Нестерова)* в одной из стандартных форм записи:

$$\begin{aligned} \theta_t^{\text{look}} &= \theta_t - \eta\beta v_t, \\ g_t &= \nabla L(\theta_t^{\text{look}}), \\ v_{t+1} &= \beta v_t + g_t, \\ \theta_{t+1} &= \theta_t - \eta v_{t+1}. \end{aligned}$$

Для Momentum градиент берётся в θ_t, для Nesterov — в θ_t^{look}.

Замечание При $\beta = 0$ обе формулы переходят в обычный GD. Термин «опережение» описывает *место вычисления градиента*, а не предсказание точного положения минимума.

AdaGrad: накопление квадратов градиентов

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *AdaGrad (адаптивный градиентный метод)* хранит сумму квадратов предыдущих градиентов:

$$G_{t+1} = G_t + g_t \odot g_t, \qquad G_0 = 0,$$
$$\theta_{t+1} = \theta_t - \eta \frac{g_t}{\sqrt{G_{t+1}} + \varepsilon}.$$

Квадратный корень, деление и сложение с $\varepsilon > 0$ выполняются по координатам.

Пример Если первый градиент $g_0 = (2, 1)^T$, то $G_1 = (4, 1)^T$. При малом ε масштабы шага равны приблизительно $\eta/2$ и η.

Следствие Для координаты j эффективный шаг имеет масштаб

$$\eta_{t,j} = \frac{\eta}{\sqrt{G_{t+1,j}} + \varepsilon}.$$

Поскольку $G_{t,j}$ не убывает, этот масштаб может со временем стать очень малым — главный недостаток AdaGrad.

RMSProp: не суммировать всю историю

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Идея В AdaGrad квадрат градиента накапливается навсегда. Заменим сумму *экспоненциальным скользящим средним*, в котором давние градиенты постепенно забываются.

Определение *RMSProp*:

$$s_{t+1} = \rho s_t + (1-\rho)(g_t \odot g_t), \qquad s_0 = 0,$$
$$\theta_{t+1} = \theta_t - \eta \frac{g_t}{\sqrt{s_{t+1}} + \varepsilon}, \qquad 0 \leq \rho < 1.$$

Замечание При постоянном масштабе градиентов s_t стабилизируется, а не растёт без ограничения, как сумма в AdaGrad. Поэтому масштаб шага может сохраняться и на поздних итерациях.

Adam: инерция и адаптивный масштаб

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Идея Momentum сглаживает направление градиента, RMSProp — его покоординатный масштаб. *Adam* объединяет эти идеи.
При $g_t = \nabla L(\theta_t)$, $m_0 = s_0 = 0$:

$$m_{t+1} = \beta_1 m_t + (1 - \beta_1) g_t,$$
$$s_{t+1} = \beta_2 s_t + (1 - \beta_2)(g_t \odot g_t).$$

Поправки на нулевую инициализацию:

$$\widehat{m}_{t+1} = \frac{m_{t+1}}{1 - \beta_1^{t+1}}, \qquad \widehat{s}_{t+1} = \frac{s_{t+1}}{1 - \beta_2^{t+1}}.$$

Определение Шаг Adam ($\varepsilon > 0$):

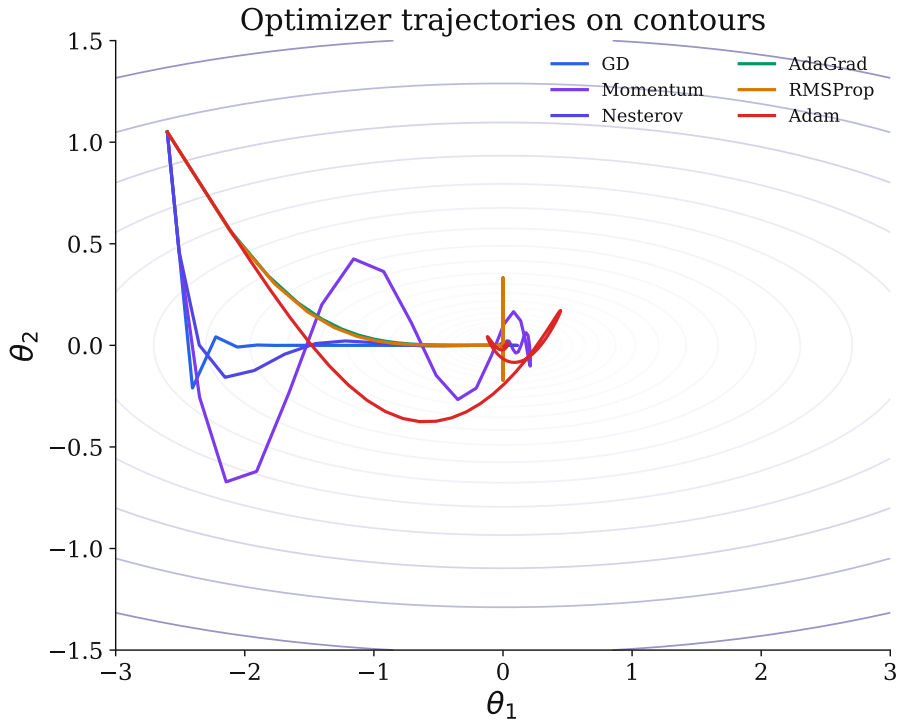
$$\boxed{\theta_{t+1} = \theta_t - \eta \frac{\widehat{m}_{t+1}}{\sqrt{\widehat{s}_{t+1}} + \varepsilon}}.$$

Замечание Все операции с векторами, кроме сложения, выполняются покоординатно. Adam не гарантирует превосходства на любой задаче.

Траектории методов на линиях уровня

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

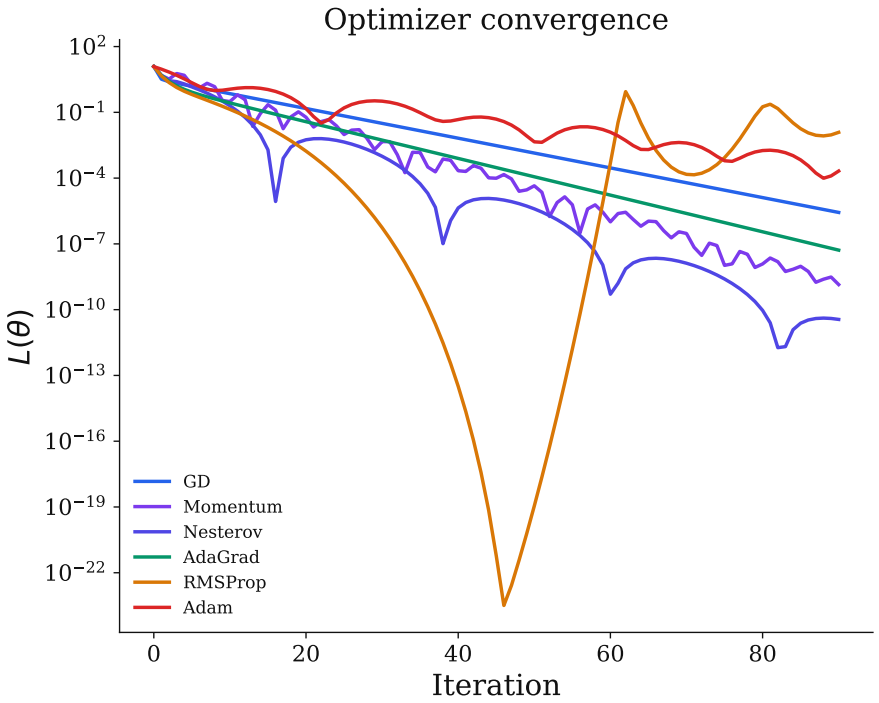
На одной функции и из одной стартовой точки методы могут выбирать разные направления и длины шагов.



Замечание Это учебная иллюстрация конкретного эксперимента, а не доказательство, что один алгоритм всегда быстрее другого.

Сравнение оптимизаторов по функции потерь

Для объективного сравнения задают одинаковые данные, начальную точку и критерий остановки; параметры методов при этом требуют подбора.



Замечание На графике показана зависимость $L(\theta_t)$ от номера итерации для конкретных настроек. Ускорение на этой задаче не гарантирует превосходства метода на другой функции.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 4
Решающие деревья и ансамбли

Что меняется при переходе от линейной модели к дереву?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Задача Построить правило, которое умеет выбирать разные ответы в разных областях пространства признаков.
Линейная модель использует одну формулу $f_\theta(x)$ для всей области. Дерево вместо этого последовательно проверяет условия на признаки:

$$x_j \leq t \quad \text{или} \quad x_j > t.$$

Определение *Решающее дерево* (Decision Tree) — модель из внутренних вершин с условиями и листьев с прогнозами.
Пример Для стоимости жилья: «площадь > 50?» — затем «район центральный?» — в достигнутом листе прогноз среднего значения цены.
Замечание Сами признаки, пороги и структура дерева *выбираются* по обучающей выборке. Это дискретная задача, не похожая на настройку коэффициентов прямой.

Один split: формальное разбиение выборки

Пусть $S \subseteq D_{\text{train}}$ — объекты, попавшие в текущую вершину дерева.

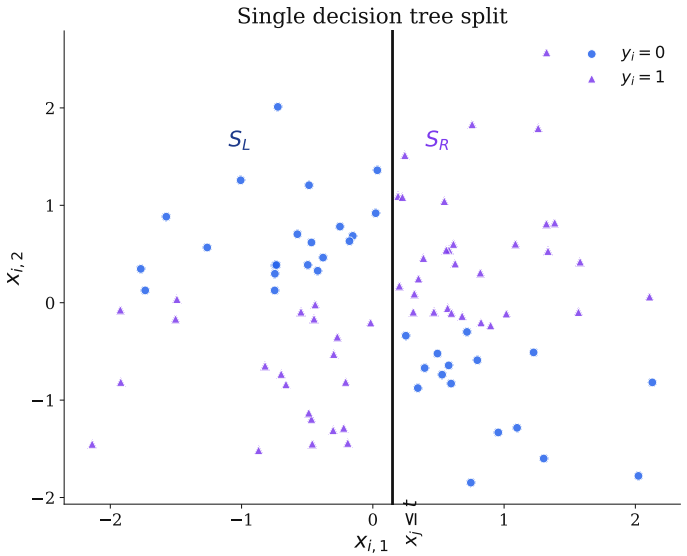
Определение Пара (j, t) определяет два непересекающихся множества:

$$S_L(j,t) = \{(x_i, y_i) \in S : x_{ij} \leq t\},$$

$$S_R(j,t) = \{(x_i, y_i) \in S : x_{ij} > t\}.$$

Вместе они образуют $S = S_L \sqcup S_R$.

Замечание Для числовых признаков достаточно проверять пороги между соседними различными отсортированными значениями признака.



Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Что означает «хорошее разбиение»?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вершина считается однородной, если попавшие в неё ответы мало различаются. Обозначим через $H(S)$ *неоднородность* ответов в S.

Определение *Уменьшение неоднородности* при split (j, t):

$$\boxed{Q(S, j, t) = H(S) - \frac{|S_L|}{|S|} H(S_L) - \frac{|S_R|}{|S|} H(S_R)}.$$

Вес каждого дочернего узла равен его доле объектов: больший узел сильнее влияет на критерий.

Алгоритм Выбрать допустимую пару

$$\boxed{(j^*, t^*) \in \arg\max_{j,t} Q(S, j, t)}.$$

Замечание Это локальный оптимум для одной вершины, а не для всего дерева. Пустые дочерние множества не рассматриваются. Если H — дисперсия или индекс Джини, то $Q \geq 0$ для допустимого разбиения; улучшение оценивается с учётом размеров узлов.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Какие критерии подходят для разных задач?

Регрессия: разброс числовых ответов

$$\bar{y}_S = \frac{1}{|S|}\sum_{i\in I(S)} y_i, \qquad H_{\text{reg}}(S) = \frac{1}{|S|}\sum_{i\in I(S)} (y_i - \bar{y}_S)^2.$$

Прогноз в листе при квадратичной ошибке — средний ответ $\bar{y}_S$.

Классификация: доли классов $p_k(S) = \frac{\#\{i\in I(S): y_i = k\}}{|S|}$.

$$\text{Gini: } H_{\text{Gini}}(S) = 1 - \sum_{k=1}^{K} p_k(S)^2,$$

$$\text{Entropy: } H_{\text{ent}}(S) = -\sum_{k=1}^{K} p_k(S)\log p_k(S).$$

Замечание Здесь $I(S)$ — индексы объектов в вершине; по соглашению $0\log 0 = 0$. В чистой вершине обе меры равны нулю.

Числовой пример критерия Джини

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Пример В корне находятся четыре объекта: два класса 0 и два класса 1.

$$H_{\text{Gini}}(S) = 1 - \left(\tfrac{2}{4}\right)^2 - \left(\tfrac{2}{4}\right)^2 = \tfrac{1}{2}.$$

Предположим, порог разделяет их на *чистые* группы: слева оба объекта класса 0, справа оба класса 1.

$$H(S_L) = H(S_R) = 0, \qquad Q(S, j, t) = \tfrac{1}{2} - 0 = \boxed{\tfrac{1}{2}}.$$

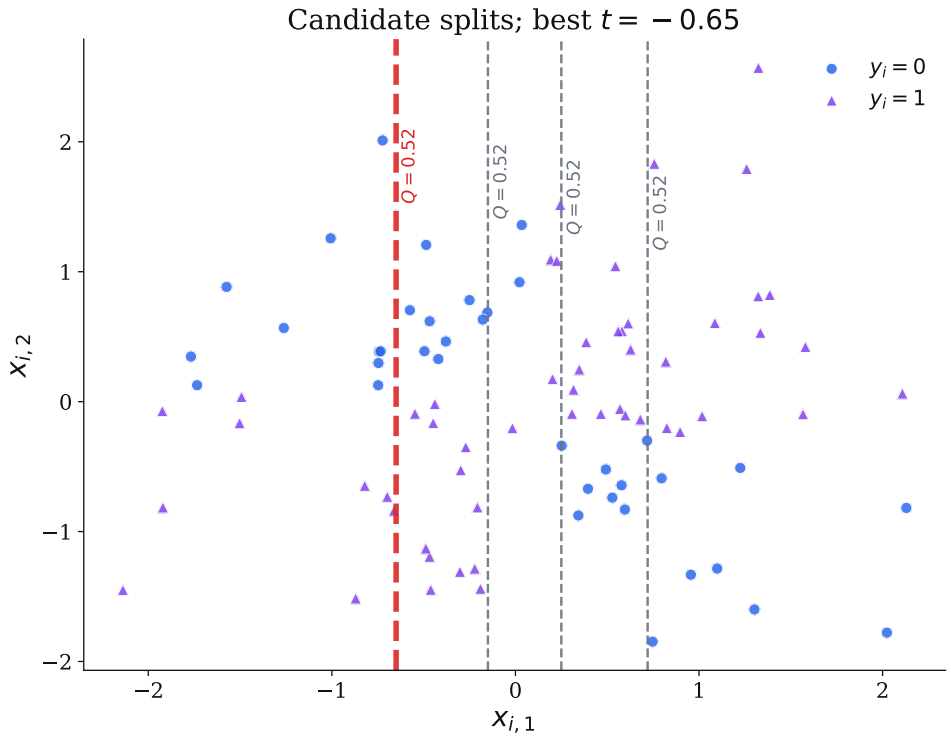
Если же каждый дочерний узел снова содержит по одному объекту каждого класса, то

$$Q(S, j, t) = \tfrac{1}{2} - \tfrac{2}{4} \cdot \tfrac{1}{2} - \tfrac{2}{4} \cdot \tfrac{1}{2} = 0.$$

Следствие Хороший split делает ответы дочерних вершин более однородными. Например, если в одном дочернем узле доли классов $3/4$ и $1/4$, то $H_{\text{Gini}} = 1 - (3/4)^2 - (1/4)^2 = 3/8 < 1/2$.

Как выбирается порог среди кандидатов?

Для фиксированного признака алгоритм сравнивает возможные пороги t и выбирает тот, который сильнее уменьшает неоднородность $H(S)$.



Замечание На рисунке показан один иллюстративный набор данных. Результат сравнения зависит от выбранного критерия и состава вершины.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Как дерево строится: жадный алгоритм

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Алгоритм

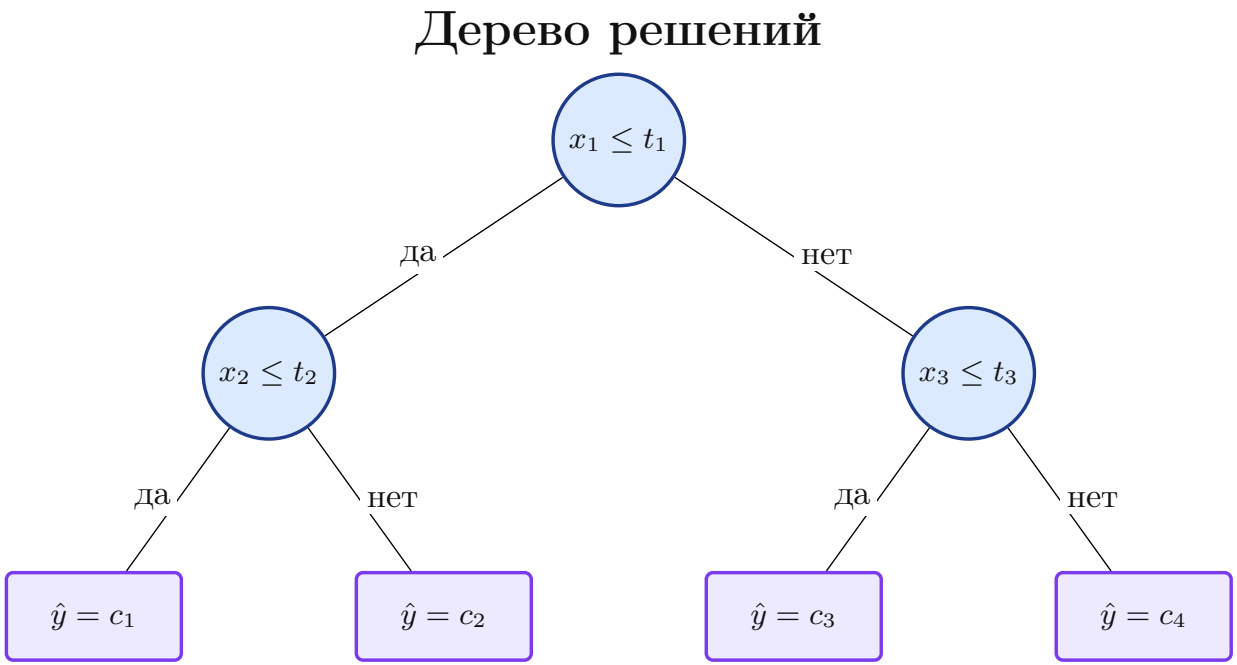
1. Положить $S = D_{\text{train}}$ в корень.
2. В вершине перебрать допустимые признаки j и пороги t.
3. Вычислить $Q(S, j, t)$, выбрать максимальное улучшение.
4. Разделить объекты на S_L и S_R и повторить рекурсивно.
5. Остановиться при малом числе объектов, предельной глубине или отсутствии улучшения.

Замечание В листьях возвращается среднее y для регрессии или наиболее частый класс для классификации. **Следствие** Глубина дерева контролирует сложность модели: слишком глубокое дерево может подогнать и шум обучающей выборки.

Структура обученного дерева

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Внутренняя вершина хранит условие $x_j \leq t$, а лист — прогноз. Для нового объекта последовательно проверяем условия от корня до листа.



Замечание В отличие от линейной регрессии дерево задаёт кусочно-постоянную функцию на областях пространства признаков.

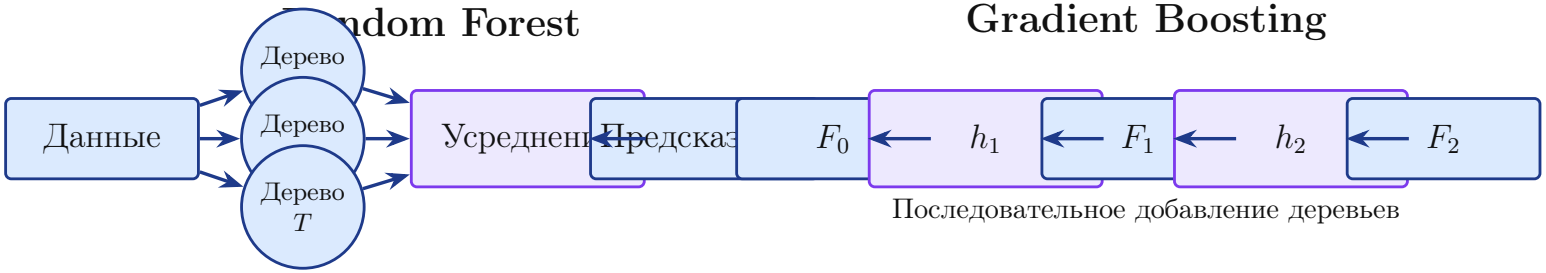
Random Forest и Gradient Boosting: разная логика

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Утверждение *Random Forest* усредняет разнообразные деревья, обученные на bootstrap-выборках со случайным выбором признаков для split. В *Gradient Boosting* каждое дерево исправляет ошибки уже построенной композиции.

$$\text{Forest: } F(x) = \frac{1}{M}\sum_{m=1}^{M} h_m(x),$$

$$\text{Boosting: } F_0 \longrightarrow F_1 \longrightarrow \cdots \longrightarrow F_M.$$



Замечание Лес может усреднять прогнозы или голосовать классами. В бустинге очередная модель зависит от ошибок предыдущей композиции.

Gradient Boosting: последовательное исправление ошибок

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Градиентный бустинг* строит последовательность функций

$$\boxed{F_m(x) = F_{m-1}(x) + \eta h_m(x)}, \qquad \eta > 0,$$

где F_{m-1} — текущий ансамбль, h_m — новое дерево, η — размер добавляемой поправки.

Замечание Здесь аргумент функции потерь — сама модель F, а не вектор θ из главы 3.

Задача Пусть на выборке оптимизируется

$$L(F) = \frac{1}{n} \sum_{i=1}^{n} \ell\big(y_i, F(x_i)\big).$$

Для дифференцируемой потери на шаге m определяют *псевдоостатки*

$$\boxed{r_i^{(m)} = - \left. \frac{\partial \ell(y_i, z)}{\partial z} \right|_{z = F_{m-1}(x_i)}}.$$

Новое дерево h_m обучают *приближать* $r_i^{(m)}$ на обучающих объектах.

При MSE бустинг приближает обычные остатки

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Возьмём квадратичную потерю (как в главе 2):

$$\ell(y,z) = (y-z)^2, \qquad -\frac{\partial \ell(y,z)}{\partial z} = 2(y-z).$$

Следовательно,

$$r_i^{(m)} = 2\big(y_i - F_{m-1}(x_i)\big).$$

Множитель 2 можно учесть при подборе масштаба поправки. Содержательно дерево учится предсказывать остатки текущей модели.

Пример Если $y_i = 10$, а $F_{m-1}(x_i) = 7$, то остаток 3; новое дерево должно предложить положительную поправку.

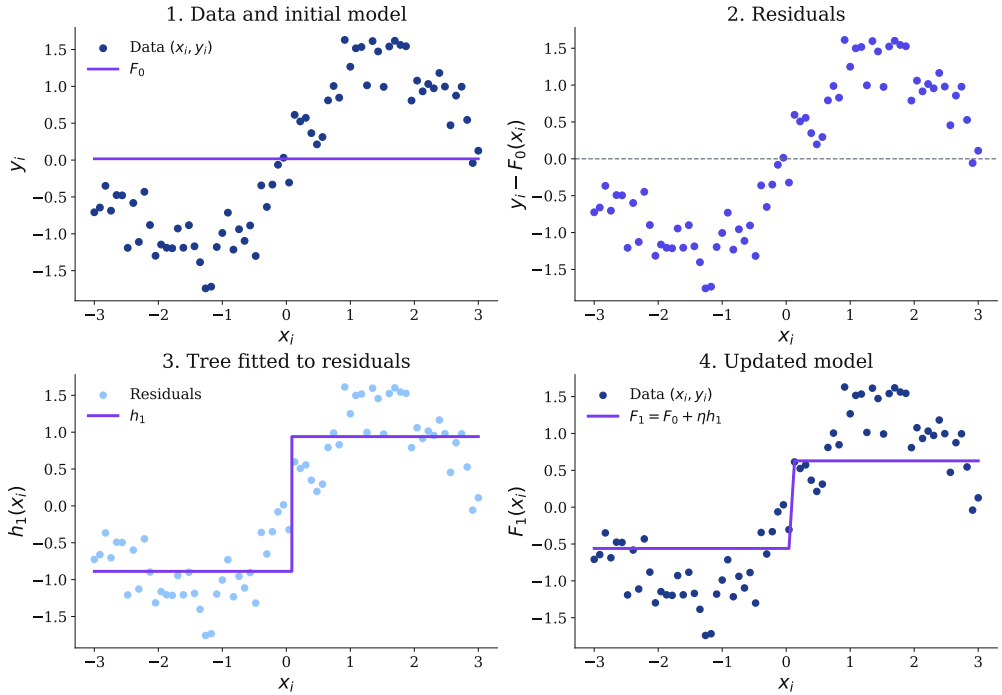
Следствие Обычный GD меняет вектор θ по антиградиенту; Gradient Boosting строит новое направление в пространстве прогнозов посредством дерева h_m.

Gradient Boosting: последовательность поправок

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Идея Начальная функция F_0 постепенно улучшается добавлением новых деревьев h_m:

$$F_m(x) = F_0(x) + \eta \sum_{k=1}^{m} h_k(x).$$

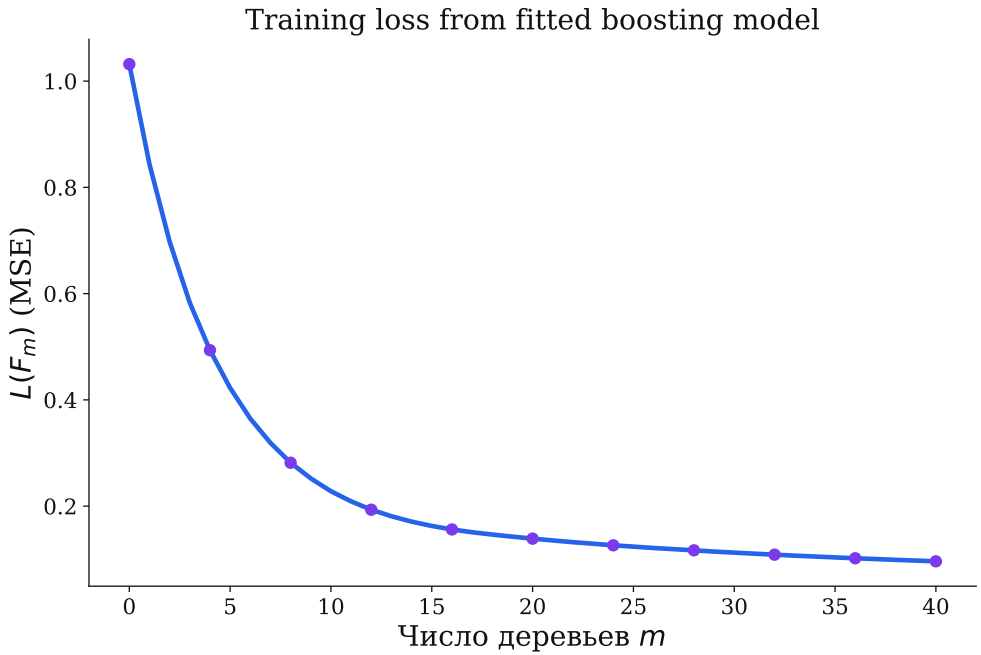


Замечание Каждая поправка обучается на псевдоостатках предыдущей модели.

Gradient Boosting: как меняется ошибка

Качество ансамбля на обучающей выборке оценивают той же функцией эмпирического риска:

$$L(F_m) = \frac{1}{n} \sum_{i=1}^{n} \ell\big(y_i, F_m(x_i)\big).$$



Замечание График иллюстрирует один эксперимент. Убывание ошибки на каждой итерации не гарантировано для произвольного шага и структуры деревьев.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 5
Нейронные сети

От линейной модели к искусственному нейрону

В главе 2 предсказание имело вид $w^T x + b$. *Искусственный нейрон* добавляет к этой величине нелинейное преобразование:

$$\boxed{z = w^T x + b, \qquad a = \varphi(z)}.$$

Определение w — веса признаков, b — смещение (bias), φ — *функция активации*.

Пример $x = (2, 1)^T$, $w = (0.5, -1)^T$, $b = 0.5$:

$$z = 0.5 \cdot 2 - 1 \cdot 1 + 0.5 = 0.5.$$

При $\varphi(z) = \max(0, z)$ получаем $a = 0.5$.

Замечание Веса и смещения будут обучаемыми параметрами; вектор всех параметров по-прежнему обозначается θ. По правилу цепочки для дифференцируемой φ:

$$\nabla_w a = \varphi'(z) x, \qquad \frac{\partial a}{\partial b} = \varphi'(z).$$

Так простая модель уже требует производных для настройки своих весов.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Почему нейрону нужна нелинейная активация?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Композиция двух аффинных преобразований остаётся аффинной:

$$z_1 = W_1 x + b_1, \qquad z_2 = W_2 z_1 + b_2,$$

$$z_2 = (W_2 W_1)x + (W_2 b_1 + b_2).$$

Без активаций несколько слоёв эквивалентны одному.
Определение Примеры активаций:

$$\mathrm{ReLU}(z) = \max(0, z), \qquad \sigma(z) = \frac{1}{1 + e^{-z}},$$

$$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}.$$

Следствие Нелинейности позволяют сети выражать зависимости, которые нельзя представить одной линейной моделью исходных признаков. **Замечание** Для сигмоиды $\sigma'(z) = \sigma(z)(1 - \sigma(z))$; для ReLU производная равна 0 при $z < 0$ и 1 при $z > 0$ (в нуле обычная производная не существует).

Многослойная сеть: последовательность функций

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Multilayer Perceptron* (MLP) — композиция слоёв, каждый из которых применяет линейное преобразование и нелинейность.

Обозначим вход $a^{(0)} = x$. Для слоя $\ell = 1, \ldots, L$:

$$\boxed{z^{(\ell)} = W^{(\ell)} a^{(\ell-1)} + b^{(\ell)}},$$

$$\boxed{a^{(\ell)} = \varphi_\ell(z^{(\ell)})}.$$

Размеры: $W^{(\ell)} \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$, $b^{(\ell)} \in \mathbb{R}^{d_\ell}$.

Замечание Все $W^{(\ell)}$ и $b^{(\ell)}$ составляют один вектор параметров θ.

Например, для двух слоёв:

$$f_\theta(x) = \varphi_2\Big(W^{(2)}\varphi_1(W^{(1)}x + b^{(1)}) + b^{(2)}\Big).$$

Выход $f_\theta(x)$ — результат последнего слоя.

Пример: задача XOR и роль скрытого слоя

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Пусть $x_1, x_2 \in \{0, 1\}$. Требуется получить $y = 1$, если входы различны, и $y = 0$, если совпадают.

(x_1, x_2)	$(0,0)$	$(0,1)$	$(1,0)$	$(1,1)$
y	0	1	1	0

Утверждение Эти четыре точки нельзя разделить одной прямой по классам.

Пример Для ReLU можно взять два скрытых выхода

$$h_1 = \mathrm{ReLU}(x_1 + x_2), \quad h_2 = \mathrm{ReLU}(x_1 + x_2 - 1),$$

$$\boxed{f(x) = h_1 - 2h_2}.$$

Проверка: при сумме входов $0, 1, 2$ результат соответственно $0, 1, 0$.

Следствие Даже небольшая нелинейная сеть может решить задачу, недоступную одной линейной границе.

Пример архитектуры: распознавание цифр

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Изображение 28×28 в оттенках серого представляют вектором $x \in \mathbb{R}^{784}$ (например, яркости от 0 до 1).
Возможная MLP-архитектура:

$$\boxed{784 \longrightarrow 128 \longrightarrow 64 \longrightarrow 10}.$$

Определение 784 — размер входа, 128 и 64 — числа нейронов скрытых слоёв, 10 — числа выходных оценок классов.
Пример Количество обучаемых весов и смещений:

$$(784 \cdot 128 + 128) + (128 \cdot 64 + 64) + (64 \cdot 10 + 10) = 109\,386.$$

Замечание Это лишь пример архитектуры из исходного материала по нейросетям, а не требование для распознавания цифр. Большая сеть не гарантирует лучшего качества.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Выход сети и функция потерь

Тип выходного слоя выбирают в соответствии с задачей.

- *Регрессия:* одно число $\hat{y} = f_\theta(x)$; можно использовать MSE из главы 2.
- *Бинарная классификация:* вероятность $p = \sigma(z)$ и BCE.
- *Многоклассовая классификация:* K оценок $z_1, \ldots, z_K$ переводятся в вероятности функцией softmax.

Определение Для $k = 1, \ldots, K$:

$$\boxed{p_k = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}}}, \qquad \sum_{k=1}^{K} p_k = 1.$$

Для правильного класса $y \in \{1, \ldots, K\}$ кросс-энтропийная потеря равна

$$\ell(y, p) = -\log p_y = -z_y + \log\Big(\sum_{j=1}^{K} e^{z_j}\Big).$$

Замечание Вновь сохраняется схема: предсказание $\to$ потеря $\to$ минимизация эмпирического риска.

Обучение сети: тот же Gradient Descent

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Обозначим θ совокупность всех весов и смещений, а $L(\theta)$ — среднюю потерю на обучающей выборке.

$$\hat{\theta} \in \arg\min_{\theta} L(\theta).$$

Алгоритм Одна итерация обучения:

1. Прямой проход (forward pass): получить $f_{\theta_t}(x_i)$.
2. Посчитать ошибку $\ell(y_i, f_{\theta_t}(x_i))$.
3. Обратный проход (backpropagation): получить $g_t \approx \nabla L(\theta_t)$.
4. Обновить веса, например, $\theta_{t+1} = \theta_t - \eta g_t$ (GD или Adam).

Определение *Эпоха* (epoch) — проход по всей обучающей выборке. На случайном mini-batch B_t оптимизируют приближённую потерю

$$L_{B_t}(\theta) = \frac{1}{|B_t|} \sum_{i \in B_t} \ell(y_i, f_\theta(x_i)).$$

Это связывает обучение нейросети с Mini-batch SGD из главы 3.

Backpropagation: применение правила цепочки

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Backpropagation* (обратное распространение ошибки) — эффективное вычисление градиентов по весам сети с помощью правила цепочки.

Пример Для цепочки

$$h = \tanh(wx + b), \quad \hat{y} = vh + c, \quad \ell = (\hat{y} - y)^2$$

вклад веса w в ошибку составляет

$$\frac{\partial \ell}{\partial w} = \underbrace{2(\hat{y} - y)}_{\partial \ell / \partial \hat{y}} \cdot \underbrace{v}_{\partial \hat{y} / \partial h} \cdot \underbrace{(1 - h^2)}_{\partial h / \partial (wx+b)} \cdot \underbrace{x}_{\partial (wx+b) / \partial w}.$$

Следствие Производные передаются от выхода к ранним слоям; промежуточные вычисления переиспользуются.

Замечание Backpropagation *вычисляет* градиент, а оптимизатор *обновляет* параметры по нему.

Backpropagation: производные целого слоя

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Для многослойной сети введём *ошибку слоя* $\delta^{(\ell)} = \partial \ell / \partial z^{(\ell)}$. Пусть $\odot$ обозначает покоординатное произведение.

Утверждение Если активации применяются покоординатно, то правило цепочки даёт

$$\boxed{\delta^{(\ell)} = \left(W^{(\ell+1)}\right)^T \delta^{(\ell+1)} \odot \varphi_\ell'\left(z^{(\ell)}\right)}.$$

Из $z^{(\ell)} = W^{(\ell)} a^{(\ell-1)} + b^{(\ell)}$ следует

$$\boxed{\frac{\partial \ell}{\partial W^{(\ell)}} = \delta^{(\ell)} \left(a^{(\ell-1)}\right)^T}, \qquad \frac{\partial \ell}{\partial b^{(\ell)}} = \delta^{(\ell)}.$$

Замечание Так градиенты вычисляются от выхода сети ко входу; их усредняют по mini-batch и передают оптимизатору из главы 3.

Почему в глубоких сетях затухает градиент?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Затухание градиента* (vanishing gradient) — ситуация, когда производные ошибки по параметрам ранних слоёв становятся очень малы.

Идея При многократном применении правила цепочки возникает произведение производных последующих слоёв:

$$\frac{\partial \ell}{\partial h_1} = \frac{\partial \ell}{\partial h_L} \prod_{j=2}^{L} \frac{\partial h_j}{\partial h_{j-1}} \qquad \text{(для скалярной цепочки)}.$$

Если множители по модулю меньше 1, произведение может быстро уменьшаться. Например, $0.5^{10} \approx 0.001$ — за десять слоёв масштаб градиента уменьшился почти в тысячу раз.

Замечание В векторной сети здесь участвуют матрицы Якоби. Не всякая глубокая сеть страдает от затухания градиента, но эффект существенно осложняет обучение.

ResNet: остаточные связи и путь для градиента

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Остаточный блок* (residual block) вычисляет

$$\boxed{h_{\ell+1} = h_\ell + F_\ell(h_\ell)},$$

где F_ℓ — несколько обучаемых преобразований.
В скалярном случае производная по входу блока:

$$\frac{dh_{\ell+1}}{dh_\ell} = 1 + F'_\ell(h_\ell).$$

Слагаемое 1 соответствует обходному (shortcut) пути; оно помогает передавать информацию и градиент через блок.
Замечание Идея ResNet помогает обучать глубокие сети, но сама по себе не гарантирует отсутствие любых проблем оптимизации.

CNN: локальные фильтры и общие веса

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Convolutional Neural Network* (свёрточная сеть, CNN) использует одни и те же обучаемые фильтры для обработки локальных участков входа.
Для входной матрицы пикселей A и фильтра $K \in \mathbb{R}^{r\times r}$ одно выходное значение (без смещения) имеет вид

$$\boxed{B_{u,v} = \sum_{i=0}^{r-1}\sum_{j=0}^{r-1} K_{ij} A_{u+i,v+j}}.$$

Замечание В ML такая операция обычно реализуется как *кросс-корреляция* (без переворота ядра), хотя слой называют свёрточным. Для входа $H \times W$ без дополнения и при шаге 1 выход имеет размер $(H - r + 1) \times (W - r + 1)$; один фильтр использует всего r^2 общих весов.

Пример Фильтр $K = \begin{pmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 1 & 0 & -1 \end{pmatrix}$ выявляет различие между левой и правой частями участка изображения.

Как CNN получает итоговый ответ

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Определение *Карта признака* (feature map) — значения отклика фильтра во всех доступных положениях. Несколько фильтров дают несколько карт.
Обычно вслед за фильтрами применяют ReLU, а размер карт иногда уменьшают с помощью *pooling*.
Пример Max pooling по области 2×2:

$$\begin{pmatrix} 1 & 3 \\ 0 & 2 \end{pmatrix} \longmapsto \max\{1, 3, 0, 2\} = 3.$$

Следствие Слои CNN постепенно формируют признаки от локальных штрихов к более сложным структурам, а последний классификационный слой (например, с softmax) выдаёт распределение по классам.
Замечание Фильтры и выходные слои обучаются совместно методом backpropagation и оптимизатором из главы 3.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Глава 6
Дополнительные методы

PCA: зачем уменьшать размерность?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Задача Заменить d исходных признаков меньшим числом признаков, сохранив как можно больше изменчивости данных.

Определение *Principal Component Analysis* (PCA, метод главных компонент) выбирает ортогональные направления с наибольшей дисперсией проекций.

Для начала данные центрируют: $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$, $x_i^c = x_i - \bar{x}$.

Пример Если данные лежат около диагональной прямой на плоскости, то вместо (x_1, x_2) часто достаточно одной координаты вдоль этой прямой.

Замечание PCA — метод *без учителя*: целевые значения y_i для поиска направлений не используются. Алгоритм ищет структуру самих x_i, а не зависимость y от x.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

PCA: задача максимальной дисперсии

Пусть $X_c \in \mathbb{R}^{n \times d}$ — матрица центрированных признаков. Положим

$$C = \frac{1}{n} X_c^T X_c.$$

Для единичного направления w проекция i-го объекта равна $z_i = w^T x_i^c$, а её эмпирическая дисперсия

$$\frac{1}{n} \sum_{i=1}^{n} z_i^2 = w^T C w.$$

Определение Первая главная компонента — решение задачи

$$\boxed{w_1 \in \arg\max_{\|w\|_2 = 1} w^T C w}.$$

Утверждение Максимум достигается на собственном векторе C, отвечающем наибольшему собственному значению.

Замечание Следующие компоненты выбирают ортогонально предыдущим. Если $W_k = (w_1, \ldots, w_k) \in \mathbb{R}^{d \times k}$, то новые признаки всех объектов равны

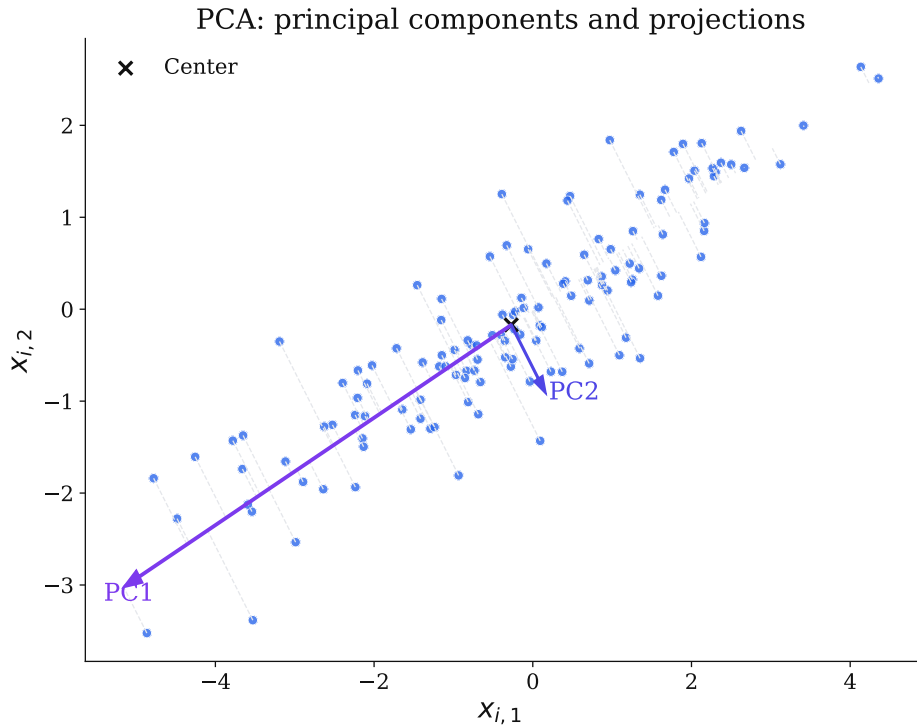
$$Z = X_c W_k \in \mathbb{R}^{n \times k}, \qquad k < d.$$

Так получается уменьшение размерности с d до k.

PCA: геометрическая иллюстрация

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Проекция на направление наибольшей дисперсии сохраняет основной разброс точек; проекция на перпендикулярное направление часто содержит мало информации.



Замечание Максимальная дисперсия не обязательно равна максимальной информативности для *конкретной* задачи классификации.

Monte Carlo: интеграл как математическое ожидание

Задача Приближённо найти $I = \int_a^b f(x)\,dx$.
Пусть $U \sim \mathrm{Unif}[a, b]$, то есть плотность равна $1/(b-a)$ на $[a, b]$.
Тогда

$$\mathbb{E}[f(U)] = \frac{1}{b-a}\int_a^b f(x)\,dx, \qquad I = (b-a)\mathbb{E}[f(U)].$$

Определение Метод Монте-Карло использует независимые точки $U_1, \ldots, U_N$:

$$\boxed{\widehat{I}_N = \frac{b-a}{N}\sum_{i=1}^{N} f(U_i)}.$$

Пример Для $\int_0^1 x^2\,dx = 1/3$ и точек $0.2, 0.5, 0.8$:

$$\widehat{I}_3 = \frac{0.2^2 + 0.5^2 + 0.8^2}{3} = 0.31.$$

Утверждение При существовании ожидания оценка несмещённая: $\mathbb{E}[\widehat{I}_N] = I$. С ростом N случайные отклонения в среднем компенсируются.

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Monte Carlo: почему выборочное среднее работает?

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Утверждение При $\mathbb{E}|f(U)| < \infty$ по закону больших чисел

$$\widehat{I}_N \longrightarrow I \quad (\text{при } N \to \infty, \text{ почти наверное}).$$

Если дисперсия $\mathrm{Var}(f(U)) = \sigma_f^2$ конечна, то

$$\mathrm{Var}(\widehat{I}_N) = \frac{(b-a)^2 \sigma_f^2}{N},$$

поэтому характерный масштаб случайной ошибки убывает как $1/\sqrt{N}$.

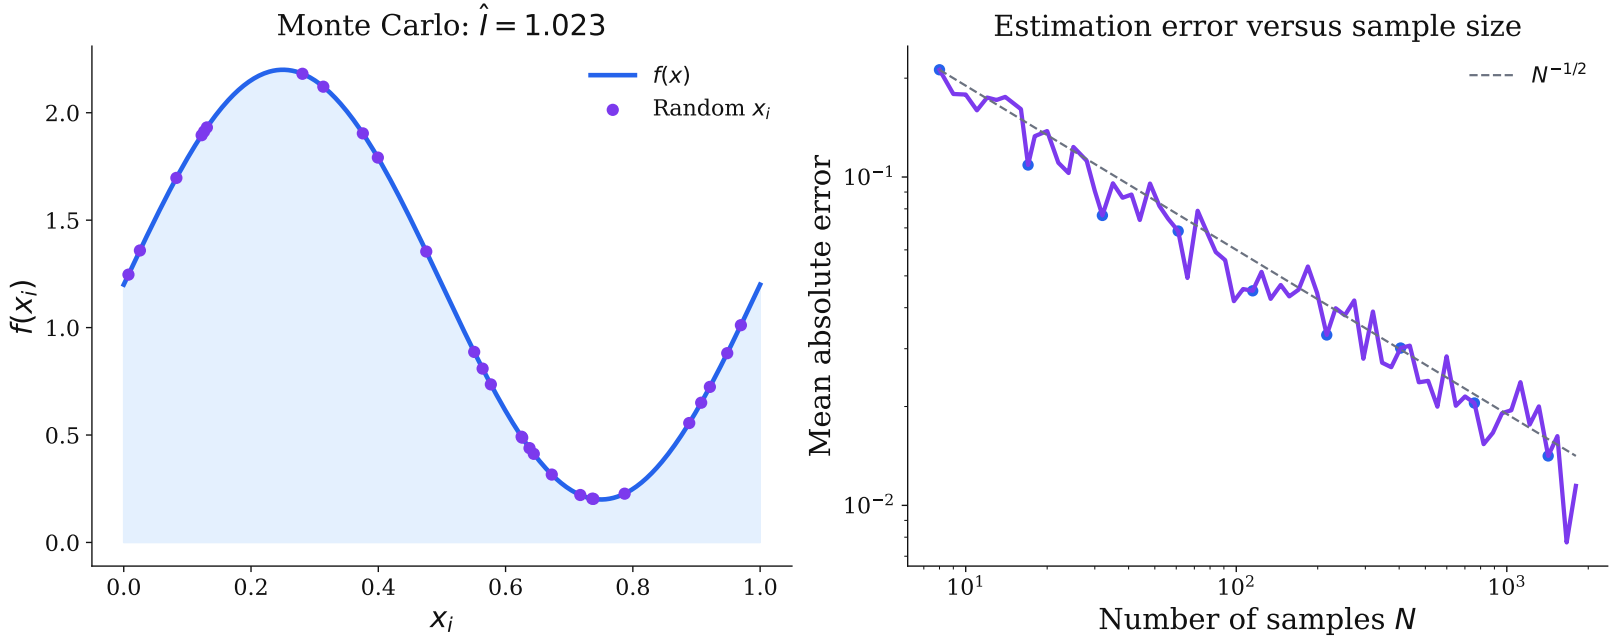
Пример Чтобы уменьшить типичный масштаб ошибки примерно в 10 раз, при прочих равных понадобится около 100 раз больше случайных точек.

Замечание Метод применим и к многомерным интегралам, однако высокая точность может потребовать много вычислений.

Monte Carlo: иллюстрация сходимости

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Слева показано случайное выборочное приближение интеграла, справа — изменение ошибки при увеличении числа точек.



Замечание Ошибка для случайной выборки не обязана уменьшаться на каждом шаге. Скорость $N^{-1/2}$ характеризует типичный статистический масштаб.

Ant Colony Optimization: вероятностный выбор маршрута

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Задача На взвешенном графе найти короткий маршрут, проходящий через все требуемые вершины (например, задача коммивояжёра).

Определение *Ant Colony Optimization* (муравьиный алгоритм) — стохастический метаэвристический метод: вероятность ребра зависит от накопленного феромона $\tau_{ij} > 0$ и привлекательности $\nu_{ij} > 0$.

$$\boxed{P_{ij} = \frac{\tau_{ij}^{\alpha} \nu_{ij}^{\beta}}{\sum_{k \in A_i} \tau_{ik}^{\alpha} \nu_{ik}^{\beta}}}, \qquad A_i \text{ — допустимые продолжения.}$$

Пример Для расстояний $d_{ij} > 0$ берут $\nu_{ij} = 1/d_{ij}$. Если два ребра имеют $\tau_1 = 2$, $\tau_2 = 1$, $\nu_1 = \nu_2 = 1$, $\alpha = \beta = 1$, то $P_1 = \frac{2}{2+1} = \frac{2}{3}$.

Замечание Параметры $\alpha, \beta \geq 0$ управляют влиянием феромона и длины. В отличие от GD здесь оптимизируется дискретный маршрут, а не дифференцируемая функция параметров.

Ant Colony Optimization: обновление феромона

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

После построения маршрутов на итерации t уровни феромона меняются:

$$\boxed{\tau_{ij}^{(t+1)} = (1 - \rho_{\text{evap}})\tau_{ij}^{(t)} + \Delta\tau_{ij}^{(t)}},$$

где $0 < \rho_{\text{evap}} < 1$ — доля испарения, $\Delta\tau_{ij}^{(t)}$ — добавка от найденных маршрутов.

Пример В простой версии для построенных маршрутов π_k длины L_k:

$$\Delta\tau_{ij}^{(t)} = \sum_{k:\,(i,j)\in\pi_k} \frac{\kappa}{L_k}.$$

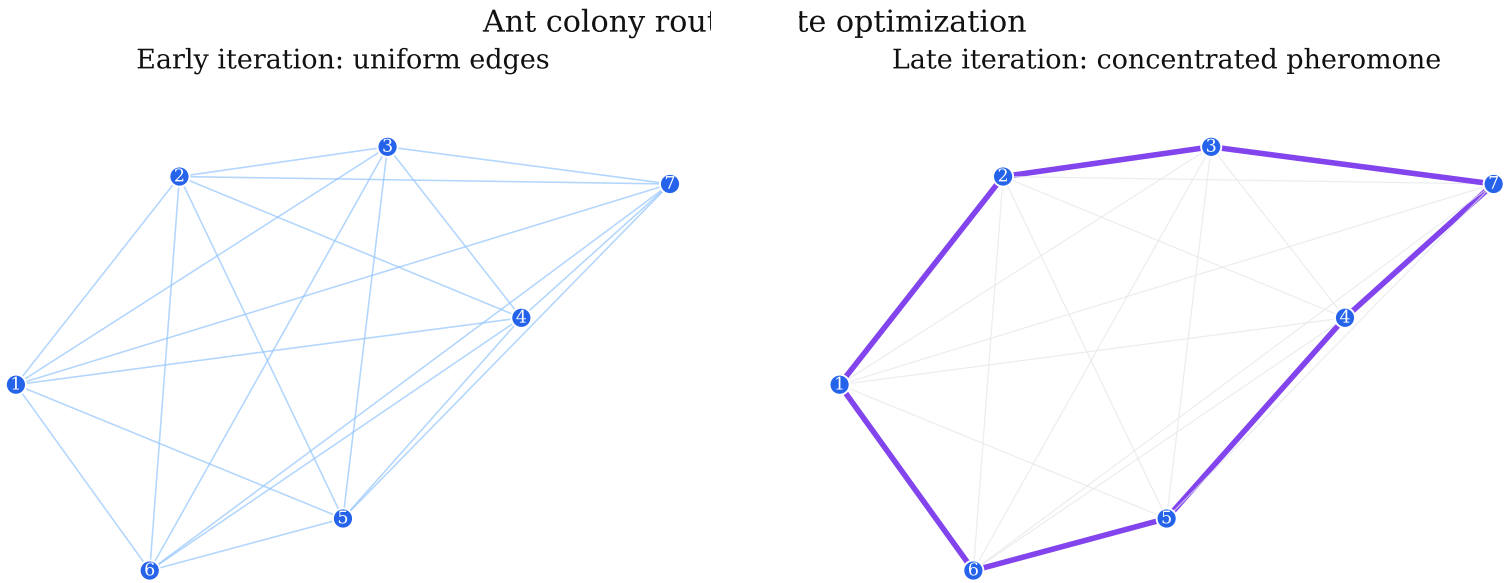
Для маршрутов длины 4 и 8 вклад каждого ребра первого вдвое больше. Так короткие пути получают подкрепление.

Следствие Случайный поиск сочетает исследование новых маршрутов и усиление уже найденных удачных решений.

Муравьиный алгоритм: как усиливается маршрут

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

В начале поиск распределён по многим рёбрам; после нескольких итераций усиливаются пути, чаще встречающиеся в удачных маршрутах.



Начальные значения феромона Усиленный найденный маршрут

Замечание Из-за случайного выбора алгоритм не гарантирует глобально кратчайший путь за конечное число шагов.

Итоги: единая математическая логика

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

1. *Постановка:* данные D_{train}, модель f_θ, потеря ℓ и задача $\min_\theta L(\theta)$.
2. *Линейные модели:* MSE и BCE приводят к градиентам по параметрам.
3. *Оптимизация:* GD и его модификации используют локальную информацию о $L(\theta)$.
4. *Деревья и ансамбли:* дискретные разбиения и функциональная идея антиградиента в бустинге.
5. *Нейросети:* композиции функций, правило цепочки и обратное распространение градиента.
6. *Другие методы:* PCA использует дисперсию, Monte Carlo — математическое ожидание, ACO — вероятностный поиск.

Следствие Математический анализ связывает построение моделей и методы их обучения: от производной функции нескольких переменных до цепочки производных в нейросети.

Основные источники

- Школа анализа данных Яндекса. *Учебник по машинному обучению*.
- Броиловский А. *Обзор задач машинного обучения*. ШАД СПб, 2026.
- Овчаров С. *Линейная регрессия и основы оптимизации*. ШАД СПб, 2026.
- Овчаров С. *Логистическая регрессия и классификация*. ШАД СПб, 2026.
- Zhang A., Lipton Z. C., Li M., Smola A. J. *Dive into Deep Learning*. Разделы об оптимизации, MLP, CNN и ResNet.
- Материалы проекта *«Математический анализ в методах машинного обучения»* и визуализации участников.

Материалы проекта на GitHub

Вейгандт В.
Зайцев Н.
Горобец О.
Козлов В.
Шагеев Э.

Исходный код и дополнительные материалы

https://github.com/Z4Y4T/ml_project