Введение в машинное обучение

Что такое машинное обучение и зачем оно нужно

Машинное обучение — это наука об алгоритмах, которые автоматически улучшаются благодаря опыту. Оно нужно там, где человеку задача даётся легко, а написать для неё программу почти невозможно: перевести текст, поставить диагноз, найти мошенническую операцию по карте, оценить цену квартиры. Правила здесь не выписать, зато есть много примеров правильных ответов.

Поэтому правило ищут по данным. Набор объектов с известными ответами называют обучающей выборкой, ответ для объекта — таргетом, а функцию, которая сопоставляет объекту предсказание, — моделью. Задачи, в которых правильные ответы на обучающих объектах известны заранее, относятся к обучению с учителем. Именно им мы и будем заниматься.

Классификация и регрессия

Задачу обучения с учителем можно описать как поиск отображения из множества объектов X в множество ответов Y. От вида Y зависит тип задачи:

- классификация: $X \to \{0, 1, \ldots, K\}$, каждому объекту нужно поставить в соответствие номер класса;
- регрессия: $X \to \mathbb{R}$, каждому объекту нужно поставить в соответствие вещественное число.

Возьмём множество банковских операций: каждый объект — вся информация об операции (дата, сумма перевода, …). Если мы хотим поставить 0 законной операции и 1 подозрительной, это классификация. Теперь возьмём множество мест, каждое из которых описано местоположением, размером и другими свойствами. Если мы хотим каждому месту сопоставить количество нефти, которое предположительно там находится, это регрессия.

Модель работает с числами, поэтому каждый объект сначала нужно записать набором чисел.

Что мы будем делать

Искать отображение среди всех возможных функций бессмысленно, поэтому заранее выбирают семейство функций с несколькими настраиваемыми параметрами, а потом подбирают их по обучающей выборке. Для этого нужно сделать три шага:

1) выбрать семейство функций — у нас это будут линейные функции, а позже и решающие деревья;

2) выбрать функцию потерь, то есть меру ошибки модели;

3) найти параметры, при которых ошибка минимальна.

Качество модели проверяют на тестовой выборке, которой не было в обучении. Иначе мы оценим, насколько хорошо модель запомнила данные, а не насколько она умеет обобщать.